

Justificación de la implementación

Pronóstico del éxito y del abandono en los títulos de grado de la UJI

AUTORA

María José Morte Ruiz

TUTOR

Raúl Parada · UOC

FECHA

8/5/2026

Cifras clave del proyecto

33.621

REGISTROS

Dataset modelable

30.872

ESTUDIANTES

Únicos 2010–2020

32

TITULACIONES

Grados UJI

7

FASES

Pipeline ML

0,956

AUC TEST

roc-auc

0,833

F1 TEST

criterio elegido

80

MODELOS

AutoML + manual

LightGBM

GANADOR

sin balanceo

1. Resumen del proyecto

El TFM aborda la predicción del abandono universitario en la Universitat Jaume I mediante técnicas de aprendizaje automático aplicadas sobre datos institucionales de las cohortes 2010–2020 (33.621 registros, 30.872 estudiantes únicos, 32 titulaciones de grado). El proyecto incluye análisis exploratorio, ingeniería de variables, comparativa sistemática de 80 modelos a través de seis frameworks AutoML, evaluación de equidad algorítmica con *fairlearn*, interpretabilidad con SHAP/LIME/DiCE y despliegue en una aplicación web interactiva con Streamlit.

La presente entrega corresponde a la **versión 2.0** del proyecto, con arquitectura dinámica: una única fuente de verdad regenera automáticamente el modelo ganador, las métricas, la app y la documentación ante cualquier cambio en los datos. Esta arquitectura garantiza trazabilidad y reproducibilidad totales.

2. Acceso al código y a la app

Todo el código fuente del proyecto está disponible públicamente en GitHub. La app desplegada permite la revisión interactiva sin necesidad de ejecutar nada localmente.

Repositorio (V2.0)

https://github.com/mortemj/AU_UJI_v2

App desplegada

<https://tfm-abandono-dinamico.streamlit.app/>

Documentación web

https://mortemj.github.io/AU_UJI_v2/

Versión 1.0 (línea base)

https://github.com/mortemj/AU_UJI

Web personal de la autora

<https://mortemj.github.io/>

Para quien desee **reproducir el pipeline en su propio ordenador**, el repositorio incluye un **manual de inicio paso a paso** diseñado para personas sin conocimientos previos de informática. Es accesible desde el botón  **Empezar aquí** de la página principal de la documentación web (https://mortemj.github.io/AU_UJI_v2/). El proyecto incorpora además un conjunto de **datos de prueba ficticios (50 alumnos)** en `data/demo/` que permiten ejecutar el pipeline completo sin acceso a los datos institucionales reales (protegidos por RGPD).

3. Estructura del pipeline

El proyecto está organizado en fases secuenciales, con notebooks reproducibles que documentan cada paso. Cada fase está completada y disponible en su carpeta correspondiente del repositorio.

#	Fase	Contenido	
1	Preparación de datos	Ingesta, limpieza, integración de fuentes UJI	✓
2	EDA inicial	Análisis exploratorio: variables, distribuciones, correlaciones	✓
3	Feature engineering	Generación de variables derivadas, codificaciones, selección	✓
+	AutoML	Baselines automáticos (AutoGluon, PyCaret, H2O, LazyPredict)	✓
4	EDA final	Refinamiento del dataset, perfiles de riesgo, selección final	✓
5	Modelado	80 modelos × 3 estrategias de balanceo · 5-Fold CV · Optuna	✓
6	Interpretabilidad	SHAP · LIME · DiCE · fairlearn · errores · robustez · calibración	✓
7	Despliegue	App Streamlit interactiva con 7 páginas dinámicas	✓

Cada fase tiene su carpeta dedicada en el repositorio (notebooks/fase1_* a notebooks/fase7_*) con los notebooks ejecutados y documentados.

4. Cómo revisar la implementación

Se proponen tres rutas de revisión según el nivel de detalle deseado:

Nivel	Acción recomendada	Tiempo
Vista rápida	Visitar la app desplegada y navegar por las 7 páginas	~10 min
Vista intermedia	Revisar la documentación web (informes HTML por fase)	~30 min
Vista detallada	Clonar el repositorio y abrir los notebooks de cada fase	~2 h

Para facilitar la **vista detallada** a personas sin conocimientos previos de informática, el proyecto incorpora un **manual de inicio paso a paso**, accesible desde la página principal de la documentación web (botón  **Empezar aquí**). El manual guía en seis pasos: descarga del código desde GitHub, instalación de Anaconda, instalación de librerías, obtención de los datos (Excel real o Excel de prueba con 50 alumnos incluido en el repositorio), validación automática de la estructura de los datos y, finalmente, ejecución del orquestador maestro mediante el botón  **Comenzar Fase 1**. La validación previa garantiza que el pipeline solo se lanza si los datos cumplen el contrato esperado, evitando errores en cascada.

María José Morte Ruiz ·