

Anexos

UOC

Pronóstico del éxito y del abandono en los títulos de grado de la Universitat Jaume I

Universitat Oberta de Catalunya

María José Morte Ruiz

Área 5 - Data Science in Social Systems, Smart Cities and Urban Data



Índice

Anexo A. Información complementaria del Capítulo 1	1
A.1. Análisis desagregado del abandono según trayectoria	1
A.2. Sistema de Gestión Documental: aplicación de sostenibilidad, ética social y diversidad	1
A.3. Confluence como herramienta institucional para la documentación técnica	3
A.4. Plan UJI-ODS 2030	4
A.5. Transferencia, impacto institucional y mejora continua	5
A.6. Fases principales del proyecto y secuencia temporal	6
A.7. Visión general del proceso de minería de datos	7
A.8. Desarrollo expandido de los hitos del cronograma (M1-M5)	7
A.9. Cronograma día a día del proyecto	11
Anexo B. Hiperparámetros y arquitectura del modelo seleccionado	13
B.1. Hiperparámetros completos del modelo	13
B.2. Arquitectura del modelo entrenado	15
B.3. Justificación metodológica de los hiperparámetros clave	16
B.4. Importancia interna del modelo (feature importance)	17
Anexo C. Diccionario detallado de las 24 features	20
C.1. Nota sobre la codificación interna de las variables categóricas	20
C.2. Tabla resumen de las 24 features	21
C.3. Bloque 1. Variables académicas (8 features)	22
C.4. Bloque 2. Variables demográficas (4 features)	26
C.5. Bloque 3. Variables socioeconómicas (4 features)	27
C.6. Bloque 4. Variables administrativas (3 features)	29
C.7. Bloque 5. Variables de rendimiento (3 features)	30
C.8. Bloque 6. Variable contextual (1 feature)	31
C.9. Bloque 7. Variable de origen académico (1 feature)	32
C.10. Flags de imputación: las 3 variables _missing	32
C.11. Variable objetivo: abandono	33
Anexo D. Configuración y arquitectura de la fase AutoML	34
D.1. Arquitectura modular de la fase AutoML	34
D.2. Configuración común a todos los módulos	35
D.3. Resultados consolidados por framework	36
D.4. Análisis específico de TabPFN v2	37

D.5. Baseline establecido para la Fase 5	38
D.6. Infraestructura de ejecución y orquestación	39
Anexo E. Definiciones formales de las métricas de equidad	41
E.1. Notación común	41
E.2. Demographic Parity Difference (DPD)	42
E.3. Equal Opportunity Difference (EOD)	43
E.4. Disparate Impact Ratio (DIR)	44
E.5. Umbrales de interpretación adoptados	44
E.6. Limitaciones y advertencias metodológicas	45
Anexo F. Librerías, entornos y estructura del repositorio	47
F.1. Entorno técnico de referencia	47
F.2. Librerías Python por categoría funcional	47
F.3. Entornos conda del proyecto	51
F.4. Ficheros requirements disponibles	52
F.5. Estructura del repositorio público	53
F.6. Instrucciones de reproducción	54
Anexo G. Capturas adicionales de la aplicación institucional	56
G.1. p00 — Página de inicio	56
G.2. p01 — Vista institucional	57
G.3. p02 — Vista por titulación	59
G.4. p03 — Pronóstico de prospectos	61
G.5. p04 — Pronóstico de alumnado matriculado	65
G.6. p05 — Equidad y diversidad	66
G.7. p06 — Guía semántica y transparencia	70
Anexo H. Encuesta sobre los motivos de abandono	74
Bloque 1. Identificación y trayectoria	¡Error! Marcador no definido.
Bloque 2. Dificultades	¡Error! Marcador no definido.
Bloque 3. Abandono	¡Error! Marcador no definido.
Bloque 4. Trabajo	¡Error! Marcador no definido.
Bloque 5. Motivación	¡Error! Marcador no definido.



Bloque 6. Valoración de la UJI

¡Error! Marcador no definido.

Bloque 7. Datos sociodemográficos

¡Error! Marcador no definido.

Notas metodológicas

74

Anexo A. Información complementaria del Capítulo 1

Nota: este Anexo recoge material desplazado desde el cuerpo del Capítulo 1 para optimizar el número de páginas, conservando los contenidos que aportan valor documental, técnico o institucional al Trabajo de Fin de Máster.

A.1. Análisis desagregado del abandono según trayectoria




Ilustración A.1. Abandono de Grado — detalle por trayectoria.

La Ilustración A.1, basada en datos del Sistema Universitario Español (SUE), ofrece una visión detallada sobre las trayectorias de abandono en los estudios de grado, diferenciando entre el cambio de titulación, la salida del sistema y el abandono total. Más allá de su función descriptiva, esta representación permite profundizar en el análisis del fenómeno, identificar patrones relevantes y orientar el enfoque predictivo del estudio.

Origen: Capítulo 1, sección 1.1 (Contexto y justificación).

A.2. Sistema de Gestión Documental: aplicación de sostenibilidad, ética social y diversidad

La integración de los principios de sostenibilidad, ética social y diversidad en el Sistema de Gestión Documental (SGD) de la UJI permite organizar y manejar la información de forma eficiente, segura y colaborativa, alineando el trabajo académico con los valores institucionales y los Objetivos de Desarrollo Sostenible.

En el caso de la UJI, el SGD se apoya en herramientas como Confluence, que facilitan la documentación de procesos, la trazabilidad de los datos y el trabajo compartido entre áreas. Esta

plataforma institucional está disponible para el personal académico y técnico a través del entorno Confluence UJI.

El SGD contribuye a:

- **Almacenamiento seguro.** Protege la información sensible sobre el alumnado y los factores asociados al abandono.
- **Acceso controlado.** Garantiza que solo personas autorizadas accedan a los datos, respetando la privacidad y la confidencialidad.
- **Colaboración eficiente.** Facilita el trabajo en equipo entre investigadores, docentes y personal técnico.
- **Automatización de procesos.** Optimiza la recolección y el análisis de datos, reduciendo errores y aumentando la eficiencia.
- **Monitoreo continuo.** Permite realizar un seguimiento constante de los indicadores académicos y evaluar el impacto de las medidas implementadas.

Recomendaciones para aplicar el SGD en el proyecto:

- **Evaluación inicial.** Analizar las necesidades específicas del estudio, los tipos de documentos, los flujos de trabajo y las personas usuarias implicadas.
- **Selección del software adecuado.** Asegurar que el sistema sea escalable, seguro y compatible con otras herramientas institucionales.
- **Planificación y diseño.** Definir la estructura de la base de datos, la clasificación documental y los permisos de acceso.
- **Capacitación del personal.** Formar a las personas usuarias en el uso del SGD y en buenas prácticas de gestión documental y seguridad.
- **Control de versiones y trazabilidad.** Implementar un sistema que registre los cambios realizados, garantizando la integridad de la información.
- **Seguridad y permisos.** Establecer políticas claras de acceso y protección de datos sensibles.
- **Monitoreo y evaluación continua.** Realizar auditorías periódicas para revisar la eficacia del sistema y ajustar los procesos según sea necesario.

Origen: Capítulo 1, sección 1.3.2 (Aplicar al SGD sostenibilidad, ética social y diversidad).

A.3. Confluence como herramienta institucional para la documentación técnica

La documentación técnica es un componente esencial en este TFM, no solo para garantizar la reproducibilidad del estudio, sino también para facilitar su transferencia institucional. En este contexto, se emplea Confluence como herramienta oficial de la UJI para la gestión documental, permitiendo registrar cada fase del trabajo de forma estructurada, transparente y colaborativa.

El uso de Confluence contribuye a la sostenibilidad del proyecto en varios niveles:

- **Sostenibilidad técnica.** Permite organizar los módulos del flujo de trabajo de forma escalable y reutilizable, reduciendo la duplicación de esfuerzos y facilitando la mejora continua.
- **Sostenibilidad institucional.** Facilita la trazabilidad de decisiones, versiones y resultados, lo que permite auditar el proceso y adaptarlo a nuevas titulaciones o cohortes.
- **Sostenibilidad colaborativa.** Promueve la participación de distintos perfiles (personal docente, técnico e investigador) en la revisión y validación del proyecto, generando conocimiento compartido.

La estructura documental incluye:

- Registro de versiones y cambios en los scripts y modelos.
- Justificación de cada variable incluida en el análisis.
- Enlaces entre módulos, fuentes de datos y resultados.
- Comentarios técnicos y pedagógicos para facilitar la revisión por expertos.
- Referencias cruzadas con los ODS, especialmente el ODS 4 sobre Educación de calidad.

Este enfoque modular y documentado refuerza el compromiso de la UJI con la transparencia, la eficiencia y la mejora continua, alineando el trabajo académico con los valores institucionales de sostenibilidad, ética social y diversidad.

Origen: Capítulo 1, sección 1.3.3 (Documentación técnica y de sostenibilidad).

A.4. Plan UJI-ODS 2030



Il·lustració A.2. Objectivos de Desarrollo Sostenible (ODS) (Oficina de Cooperació al Desenvolupament i Solidaritat, 2025).

En la UJI, aplicando los Objetivos de Desarrollo Sostenible que se recogen en la Ilustración A.2, se ha creado, desde la Cátedra de Cooperación y Desarrollo Sostenible, una hoja de ruta para colaborar en la Agenda 2030 aprobada por las Naciones Unidas a finales de 2015. Esta agenda implica tres grandes ámbitos —sostenibilidad ambiental, económica y social—, cinco esferas —Planeta, Personas, Prosperidad, Paz y Alianzas— y 17 ODS.

Para ello se toma como base el **Plan UJI-ODS 2030**, documento que pretende ser la guía de implantación del plan en la universidad. Este TFM se vincula especialmente con los objetivos relacionados con la educación de calidad (ODS 4), la igualdad de género (ODS 5) y la reducción de las desigualdades (ODS 10), contribuyendo a una universidad más justa, inclusiva y sostenible.

Origen: Capítol 1, secció 1.3 (apartado sobre Il·lustració A.2).

A.5. Transferencia, impacto institucional y mejora continua

Este Trabajo de Fin de Máster no solo busca analizar el abandono universitario desde una perspectiva ética, sostenible y diversa, sino también generar un impacto real en la mejora de las políticas institucionales. El enfoque modular, reproducible y documentado del proyecto permite su transferencia a otras titulaciones, cohortes y contextos, facilitando su adaptación por parte de equipos docentes, técnicos y de gestión universitaria. La trazabilidad del proceso, garantizada mediante el uso del SGD y herramientas como Confluence, permite que el trabajo pueda ser revisado, replicado y ampliado.

Este TFM puede contribuir a:

- **Diseño de estrategias inclusivas.** Los resultados del modelo predictivo pueden orientar la creación de programas de apoyo específicos para colectivos vulnerables.
- **Optimización de recursos institucionales.** Al identificar factores clave del abandono, se pueden redirigir esfuerzos y presupuestos hacia medidas más eficaces.
- **Mejora de la permanencia y el éxito académico.** La implementación de medidas basadas en evidencia puede reducir la deserción y mejorar la experiencia estudiantil.
- **Fortalecimiento del compromiso institucional con los ODS.** El trabajo se alinea con los objetivos de educación de calidad, igualdad de género y reducción de desigualdades.
- **Generación de conocimiento transferible.** La documentación técnica y la trazabilidad permiten que el proyecto sirva como base para futuras investigaciones, colaboraciones interdepartamentales o iniciativas institucionales.

Origen: Capítulo 1, sección 1.3.4 (Transferencia, impacto y mejora continua). Limpieza aplicada: eliminadas las frases que repetían ideas ya presentes en A.2 y A.3 sobre trazabilidad y modularidad.

A.6. Fases principales del proyecto y secuencia temporal




Ilustración A.3. Fases principales del proyecto y su secuencia temporal.

La Ilustración A.3 representa las cinco fases clave del proyecto (M1-M5) y su secuencia temporal. Esta visualización complementa el diagrama de Gantt presentado en la Ilustración 5 del cuerpo principal, ofreciendo una perspectiva más sintética del flujo del proyecto desde la planificación inicial hasta la defensa pública.

Origen: Capítulo 1, sección 1.5 (Planificación del trabajo, Ilustración A.3).

A.7. Visión general del proceso de minería de datos




Ilustración A.4. Visión de los pasos del proceso de minería de datos. Adaptado de Witten, Frank y Hall (2011). Nota: la imagen reproduce la terminología original de la fuente, donde «data cruda» es calco del inglés «raw data»; en el cuerpo del trabajo se emplea siempre el término «datos originales».

La Ilustración A.4 muestra cómo la minería de datos permite integrar la información, descubrir tendencias, generar indicadores y representar los resultados mediante gráficos y estadísticas. Estas visualizaciones facilitan la comprensión del problema y apoyan la toma de decisiones estratégicas. Esta representación complementa el proceso KDD detallado en la Ilustración 4 del cuerpo principal (sección 1.4), ofreciendo una visión más amplia del ciclo completo de análisis de datos.

Origen: Capítulo 1, sección 1.5.1 (Análisis del abandono mediante aprendizaje automático, Ilustración A.4).

A.8. Desarrollo expandido de los hitos del cronograma (M1-M5)

Este apartado recoge el desarrollo detallado de cada uno de los cinco hitos del proyecto, con sus objetivos específicos, fuentes consultadas, entregables intermedios y consideraciones particulares.

M1 — Definición y planificación del trabajo final

Esta primera fase del proyecto se centra en la elección del tema, el enfoque metodológico y la interacción con el tutor, así como en la coordinación con personal técnico y responsables institucionales para la acreditación y desarrollo del TFM.

El problema abordado es el abandono universitario en la UJI, una cuestión que afecta a múltiples niveles:

- **Personal.** Frustración de la persona estudiante al no alcanzar sus objetivos, con implicaciones económicas directas.
- **Social.** Pérdida de recursos privados, tiempo invertido y posible impacto en la reputación institucional.
- **Institucional.** Coste en recursos públicos y afectación a indicadores de calidad académica.

Objetivos del hito M1:

- Analizar el perfil del estudiantado de grado en la UJI para identificar los factores que influyen en la intención de abandono.
- Determinar si el problema tiene origen institucional, social o personal.
- Emitir un informe alineado con la normativa de la UJI, que recoja los factores clave y proponga recomendaciones para abordar el abandono universitario.

Durante esta fase se ha realizado:

- La presentación de la PEC1, junto con la preparación de la entrega inicial.
- Una búsqueda bibliográfica en bases de datos especializadas.
- La elaboración de un cuestionario institucional, dirigido al alumnado objeto de estudio.
- La definición de dimensiones analíticas como intención de abandono, rendimiento académico y datos previos de acceso.

La metodología aplicada es de tipo cuantitativo no experimental, con análisis de datos del total del estudiantado universitario. Se han solicitado los permisos pertinentes en materia de protección de datos.

M2 — Estado del arte

Esta fase se centra en el estado del arte y en la recopilación de antecedentes relevantes sobre el abandono universitario, tanto a nivel nacional como internacional. El objetivo es construir una base teórica y empírica que sustente el diseño del modelo y la interpretación de los resultados.

Se ha realizado una panorámica de estudios previos, identificando investigaciones, informes y datos institucionales que abordan el fenómeno desde distintas perspectivas: académica, social, económica e institucional.

Fuentes consultadas:

- Bases de datos internacionales: Scopus, Web of Science (WoS).
- Repositorios nacionales: Dialnet, Índices CSIC, Teseo.
- Organismos públicos: Ministerio de Universidades, Sistema Integrado de Información Universitaria (SIIU), Conferencia de Rectores de las Universidades Españolas (CRUE), Sistema de Información Universitario Valenciano Público (SIUVP).

Palabras clave utilizadas en la búsqueda:

- «Abandono universitario»
- «Rendimiento académico»
- «Deserción estudiantil»
- «Factores institucionales»
- «Análisis predictivo en educación superior»

Esta fase permite contextualizar el problema en el marco de la literatura científica y de los datos oficiales, identificando vacíos, tendencias y enfoques metodológicos que orientan el diseño del trabajo.

M3 — Diseño e implementación

Esta fase se centra en la construcción progresiva del proyecto, aplicando técnicas de minería de datos sobre los datos reales de la UJI. Los hitos intermedios permiten avanzar de forma acumulativa hacia el resultado final, integrando fuentes y herramientas.

Fuentes e integración de datos. Para la ejecución técnica, se han consultado diversas fuentes institucionales como el Vicerrectorado de Investigación, el Gabinete de Planificación (OPP), la OIATI y la UADTI, entre otras. Los datos se han recibido originalmente en formatos diversos (xls, doc, dat) a través de herramientas como Oracle Discoverer.

Actualización técnica. Al disponer de la información fragmentada en diversos ficheros Excel, la primera etapa del preprocesamiento consiste en la integración y consolidación de datos mediante un proceso de unión utilizando el identificador único anonimizado del alumnado. Esto garantiza la integridad de la serie histórica 2010-2021 antes de iniciar la limpieza del dataset.

Nota: la metodología técnica detallada de modelado, evaluación y selección de algoritmos se desarrolla en el Capítulo 3 (Diseño e implementación).

M4 — Redacción y presentación de la memoria

Esta fase se centra en la elaboración de la memoria final del Trabajo de Fin de Máster y en la preparación de su presentación ante la Comisión de Evaluación. Constituye el cierre técnico y académico del proyecto, y se articula en tres momentos clave:

- **Redacción de la memoria (entrega preliminar).** Se elabora un borrador con el avance del proyecto, que servirá como base para la redacción final. Este documento recoge los resultados obtenidos, las herramientas utilizadas y las decisiones metodológicas justificadas.
- **Redacción de la memoria (entrega final).** Se redacta el documento definitivo del TFM, estructurado según los criterios académicos de la UJI. Incluye introducción, marco teórico, metodología, resultados, discusión, conclusiones y recomendaciones.
- **Presentación audiovisual del trabajo.** Se diseña una presentación clara y didáctica para acompañar la defensa. Esta presentación resume los objetivos, el enfoque seguido, los resultados obtenidos y el impacto institucional del estudio.

Durante esta fase se mantiene una comunicación continua con el tutor, que proporciona *feedback* constructivo para mejorar la calidad del documento y afinar la exposición. Esta interacción bidireccional permite consolidar habilidades técnicas, comunicativas y académicas.

M5 — Defensa del proyecto

La fase final del proyecto consiste en la preparación y defensa del Trabajo de Fin de Máster ante la Comisión de Evaluación. Este hito marca el cierre académico del proceso, y se articula en dos momentos clave:

1. Preparación de la defensa.

- Se realiza la entrega definitiva del documento final del TFM, en formato informe o contribución académica.

- Se prepara una presentación audiovisual que sintetiza los objetivos, metodología, resultados y conclusiones del trabajo.
- Se revisan los criterios de evaluación establecidos por la UJI para asegurar la adecuación formal y técnica del material entregado.

2. Defensa pública.

- Se lleva a cabo en modalidad online ante el tribunal evaluador, en el periodo junio-julio 2026.
- La presentación se estructura de forma clara y didáctica, destacando el impacto institucional del estudio, la validez técnica del modelo y las recomendaciones propuestas.
- Se responde a las preguntas del tribunal, justificando cada decisión metodológica y cada resultado obtenido.

Este hito representa no solo la culminación del trabajo técnico, sino también la consolidación de competencias comunicativas, éticas y académicas, en coherencia con los valores institucionales de la UJI.

Origen: Capítulo 1, sección 1.6 (Hitos del cronograma del proyecto). Limpieza aplicada: eliminado el marco ético detallado del Módulo M3 (Artículo 33, CEISH, CBPID), que ya se desarrolla en sección 1.7 del cuerpo principal. La Tabla 3 con sub-fases 8.1-8.6 del Módulo 3 se ha eliminado: su contenido metodológico se reformula y desarrolla en el Capítulo 3 con la metodología real del proyecto.

A.9. Cronograma día a día del proyecto




Ilustración A.5. Cronograma día a día del proyecto.

La Ilustración A.5 muestra un cronograma detallado con las tareas distribuidas día a día, desde el inicio del proyecto el 19/02/2026 hasta su finalización en junio-julio de 2026. Se incluyen fechas de inicio y fin, duración estimada y asignación por módulos, lo que permite ajustar el avance según los objetivos definidos.

Origen: Capítulo 1, sección 1.6 (Ilustración A.5).

Anexo B. Hiperparámetros y arquitectura del modelo seleccionado

El presente anexo documenta de forma exhaustiva la configuración del modelo final del proyecto, LightGBM con estrategia 'none', seleccionado en la Fase 5 según el procedimiento descrito en el Anexo A. La información recogida proviene íntegramente de la introspección directa del fichero serializado `LightGBM__none.pkl` mediante las APIs estándar de scikit-learn y LightGBM (`get_params()`, atributos post-fit y `dump_model()` del booster interno), garantizando que cada valor reportado corresponde con exactitud al modelo desplegado en producción en la aplicación institucional.

La estructura del fichero es un objeto `sklearn.pipeline.Pipeline` que contiene un único paso, denominado 'model', instanciado como `LGBMClassifier`. Esta arquitectura ligera responde a una decisión de diseño consciente: el preprocesamiento (imputación, codificación de categóricas y generación de flags `_missing`) se realiza en un `ColumnTransformer` separado y persistido aparte (`pipeline_preprocesamiento.pkl`), de modo que el modelo y la preparación de datos puedan versionarse y actualizarse de forma independiente.

B.1. Hiperparámetros completos del modelo

La Tabla B.1 recoge los veinte hiperparámetros del clasificador `LGBMClassifier` con su valor exacto y su función dentro del proceso de boosting. La selección de valores no por defecto responde a una estrategia conservadora orientada a la robustez frente al sobreajuste: tasa de aprendizaje moderada (`learning_rate` = 0,05), profundidad acotada (`max_depth` = 6), submuestreo de filas y columnas (`subsample` = `colsample_bytree` = 0,8), y regularización combinada L1 + L2 (`reg_alpha` = 0,1; `reg_lambda` = 1,0). Estos valores se identificaron como óptimos durante la experimentación de Fase 5, mediante validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento.

Parámetro	Valor	Función
<code>boosting_type</code>	<code>gbdt</code>	Algoritmo de boosting. 'gbdt' (Gradient Boosting Decision Tree) construye árboles secuencialmente, cada uno corrigiendo errores del anterior.

Parámetro	Valor	Función
n_estimators	300	Número máximo de árboles del ensemble. Determina la capacidad del modelo y se controla junto a learning_rate.
learning_rate	0,05	Tasa de aprendizaje (shrinkage). Reduce la contribución de cada árbol al ensemble; un valor menor exige más árboles pero mejora la generalización.
max_depth	6	Profundidad máxima de cada árbol. Limita explícitamente la complejidad y reduce el sobreajuste.
num_leaves	31	Número máximo de hojas por árbol. Junto con max_depth controla la complejidad estructural.
min_child_samples	20	Número mínimo de observaciones en una hoja. Evita hojas con muestras insuficientes para generalizar.
min_child_weight	0,001	Suma mínima del peso de los gradientes (Hessian) en una hoja. Aporta regularización adicional sobre observaciones difíciles.
min_split_gain	0	Ganancia mínima requerida para realizar una nueva partición. Si no se alcanza, el nodo se convierte en hoja.
subsample	0,8	Fracción del conjunto de entrenamiento muestreada (sin reemplazo) para cada árbol. Introduce aleatoriedad y reduce varianza.
subsample_freq	0	Frecuencia (en árboles) con la que se aplica subsample. 0 desactiva subsampling; >0 lo activa.
subsample_for_bin	200000	Tamaño de la muestra que LightGBM usa para construir los bins de histograma con los que discretiza variables continuas.
colsample_bytree	0,8	Fracción de features muestreadas por árbol. Aporta diversidad y regularización al ensemble.
reg_alpha	0,1	Regularización L1 sobre los pesos de las hojas. Penaliza valores grandes y produce esparsidad.
reg_lambda	1	Regularización L2 sobre los pesos de las hojas. Penaliza valores grandes en magnitud cuadrática.
class_weight	None	Ponderación de clases para conjuntos desbalanceados. 'None' trata las clases por igual.
objective	None	Función objetivo. 'None' se infiere automáticamente como 'binary' al detectar dos clases en el target.
importance_type	split	Tipo de importancia reportado por feature_importances_: 'split' cuenta apariciones, 'gain' pondera la ganancia acumulada.

Parámetro	Valor	Función
n_jobs	-1	Número de hilos de ejecución paralela. -1 utiliza todos los núcleos disponibles del procesador.
random_state	42	Semilla aleatoria. Garantiza reproducibilidad exacta del entrenamiento.
verbose	-1	Nivel de verbosidad de los logs durante el entrenamiento. -1 silencia mensajes informativos.

Tabla B.1. Hiperparámetros del modelo *LightGBM* con estrategia 'none', extraídos directamente del fichero serializado mediante el método `get_params()` de *scikit-learn*. Los nombres de parámetro y valores siguen la nomenclatura oficial del paquete *LightGBM*. Fuente: introspección de *LightGBM__none.pkl*.

B.2. Arquitectura del modelo entrenado

Mientras que la Tabla B.1 documenta la configuración antes del entrenamiento, la Tabla B.2 reporta los atributos del modelo una vez ajustado a los datos. Esta información permite verificar que el entrenamiento se completó según lo previsto, sin interrupciones por early stopping ni desviaciones respecto al diseño original.

De los datos extraídos cabe destacar tres aspectos. En primer lugar, el ensemble alcanzó las 300 iteraciones de boosting completas configuradas en `n_estimators`, sin que se activara mecanismo alguno de parada temprana, lo que indica que el modelo no se entrenó con un conjunto de validación separado para early stopping. En segundo lugar, todos los árboles del ensemble alcanzaron exactamente la profundidad máxima permitida (6 niveles), lo que sugiere que la cota de complejidad establecida en `max_depth` está activa de forma sistemática y constituye, por tanto, el factor regulador efectivo de la capacidad del modelo. En tercer lugar, el número de hojas por árbol presenta una mediana de 31, coincidente con el valor configurado en `num_leaves`, mientras que la media (28,02) revela que algunos árboles se construyen con menos hojas, probablemente por aplicación de la regla de `min_child_samples` sobre regiones del espacio con pocas observaciones.

Atributo	Valor real
Tipo de objeto serializado	<code>sklearn.pipeline.Pipeline</code> (un único step: 'model' → <code>LGBMClassifier</code>)
Versión de LightGBM (entrenamiento)	Booster v4 (formato registrado en el fichero serializado)

Atributo	Valor real
Versión de scikit-learn (entrenamiento)	1.6.1
Tamaño del fichero serializado	932,7 KB (LightGBM__none.pkl)
Formato de serialización	joblib (compress=3)
Función objetivo entrenada	binary
Número de clases	2
Número de features de entrada	27 (24 features + 3 flags _missing)
Número total de árboles	300
Iteraciones de boosting completadas	300 de 300 configuradas (sin early stopping)
Profundidad real de los árboles	min 6 max 6 media 6,00 mediana 6
Hojas por árbol	min 10 max 31 media 28,02 mediana 31
Total de nodos hoja del ensemble	8406

Tabla B.2. Arquitectura real del modelo `LightGBM__none` tras el entrenamiento, extraída del booster interno mediante `dump_model()` y los atributos post-fit del clasificador. Fuente: introspección de `LightGBM__none.pkl`.

B.3. Justificación metodológica de los hiperparámetros clave

La configuración seleccionada responde a un equilibrio entre capacidad expresiva del modelo y control del sobreajuste, especialmente relevante en un contexto educativo donde el patrón temporal de la cohorte 2020 (afectada por la pandemia COVID-19) introduce ruido específico. A continuación se justifican los cuatro grupos de decisiones más relevantes.

La pareja `learning_rate = 0,05` y `n_estimators = 300` implementa el principio de aprendizaje lento del gradient boosting (Friedman, 2001): cada árbol contribuye con una fracción reducida al ensemble, lo que exige más iteraciones pero produce un modelo más estable y mejor calibrado. La literatura sobre LightGBM y XGBoost (Ke et al., 2017; Chen y Guestrin, 2016) sugiere valores de `learning_rate` entre 0,01 y 0,1 como rango óptimo para problemas tabulares de tamaño moderado, apoyado en la regularización implícita que el shrinkage proporciona.

La cota de complejidad estructural se establece mediante `max_depth = 6` y `num_leaves = 31`. La combinación es deliberada: `max_depth` limita la profundidad máxima y `num_leaves` controla la cardinalidad de hojas por árbol, asegurando que aunque los árboles puedan crecer hasta seis

niveles, no superen treinta y una hojas. Valores más permisivos (por ejemplo, $\text{max_depth} \geq 10$) tienden a memorizar particularidades del conjunto de entrenamiento y degradar la generalización en datasets con menos de cien mil observaciones (Bentéjac et al., 2021), como es el caso del presente proyecto.

El submuestreo combinado ($\text{subsample} = \text{colsample_bytree} = 0,8$) constituye una forma de regularización estocástica heredada de Random Forest (Breiman, 2001) y adoptada de forma estándar en gradient boosting. Cada árbol se entrena sobre el 80 % de las observaciones y el 80 % de las features, lo que introduce diversidad en el ensemble y reduce la varianza del modelo final. El parámetro $\text{subsample_freq} = 0$, sin embargo, desactiva el muestreo por filas en la configuración actual, manteniendo solo el muestreo por columnas; se trata de un detalle técnico documentado por completitud.

La regularización explícita combina penalización L1 ($\text{reg_alpha} = 0,1$) y L2 ($\text{reg_lambda} = 1,0$) sobre los pesos de las hojas. La componente L1 fomenta esparsidad estructural —algunas hojas tienden a peso cero, equivalente a podarlas—, mientras que la L2 atenúa los pesos extremos sin anularlos. La combinación elegida prioriza la regularización L2, consistente con la observación empírica de que en boosting con árboles poco profundos la penalización cuadrática suele ser más efectiva (Hastie et al., 2009).

B.4. Importancia interna del modelo (feature importance)

LightGBM proporciona dos métricas internas de importancia de variables, complementarias a los valores SHAP reportados en la sección 4.6 del Capítulo 4. La importancia ‘split’ contabiliza el número de veces que una feature se utiliza para particionar un nodo en cualquier árbol del ensemble, reflejando su frecuencia de uso. La importancia ‘gain’ acumula la mejora del criterio de pureza (reducción de la pérdida) producida por las particiones que utilizan esa feature, midiendo así la contribución cuantitativa al rendimiento del modelo.

La Tabla B.3 presenta los rankings top-15 de ambas métricas en columnas paralelas, permitiendo contrastar la frecuencia de uso (split) con la contribución acumulada (gain).

#	Feature (importancia ‘split’)	Splits	#	Feature (importancia ‘gain’)	Gain
1	cred_superados_anio_1er	967	1	cred_superados_anio_1er	54223,48
2	nota_1er_anio	710	2	n_anios_trabajando	27508,75

#	Feature (importancia 'split')	Splits	#	Feature (importancia 'gain')	Gain
3	nota_acceso	684	3	cred_repetidos	22126,83
4	tasa_abandono_titulacion	591	4	situacion_laboral	20372,00
5	anios_sin_beca	581	5	nota_1er_anio	16800,50
6	n_anios_trabajando	530	6	n_anios_beca	13952,98
7	cred_repetidos	429	7	anios_sin_beca	12530,37
8	nota_selectividad	425	8	n_anios_sin_notas	12448,26
9	edad_entrada	420	9	nota_acceso	9078,25
10	n_anios_beca	408	10	tasa_repeticion	8500,57
11	n_anios_sin_notas	384	11	tasa_abandono_titulacion	6326,35
12	situacion_laboral	306	12	edad_entrada	3574,31
13	via_acceso	271	13	via_acceso	3150,68
14	tasa_repeticion	236	14	nota_selectividad	2037,28
15	rama	224	15	cupos	1381,89

Tabla B.3. Importancia interna de variables del modelo `LightGBM__none` según los criterios 'split' (frecuencia de uso) y 'gain' (mejora acumulada del criterio de pureza). Top-15 features de cada métrica. Las tres flags `_missing` (`nota_1er_anio_missing`, `nota_acceso_missing`, `nota_selectividad_missing`) y las features con menor representación quedan fuera del top-15 mostrado. Fuente: `feature_importances_` y `booster.feature_importance(importance_type='gain')`.

La comparación entre ambos rankings revela que la feature `cred_superados_anio_1er` es dominante en ambas métricas (primer puesto en split y gain), confirmando su rol central en la predicción del abandono. Sin embargo, aparecen reordenamientos relevantes en posiciones intermedias: `nota_1er_anio` ocupa el segundo puesto en split (710 particiones) pero desciende al quinto en gain (16.800), mientras que `n_anios_trabajando`, situada sexta en split (530 usos), sube al segundo puesto en gain (27.508). Esta divergencia es un fenómeno habitual en gradient boosting (Lundberg et al., 2020) y se interpreta del siguiente modo: variables como `nota_1er_anio` se utilizan con frecuencia alta porque proporcionan particiones útiles de pequeña magnitud en muchas regiones del espacio de features (uso disperso pero modesto), mientras que `n_anios_trabajando` se usa menos veces pero produce ganancias mayores cuando interviene (uso concentrado de alto impacto).

Conviene subrayar que estos rankings internos del modelo no sustituyen al análisis SHAP del Capítulo 4. Las importancias 'split' y 'gain' son métricas globales y agregadas, sesgadas hacia

variables con mayor cardinalidad o variabilidad, y no permiten interpretar predicciones individuales (Lundberg y Lee, 2017). Por ello, la sección 4.6 del Capítulo 4 utiliza SHAP como criterio principal de interpretabilidad y este Anexo B presenta las importancias internas únicamente como información complementaria sobre la mecánica del modelo.

Anexo C. Diccionario detallado de las 24 features

El presente anexo recoge la descripción técnica detallada de las veinticuatro variables predictoras (features) utilizadas por el modelo final del proyecto, conforme a la composición del dataset modelable `dataset_final_tfm.parquet` (33.621 registros × 25 columnas, donde la columna restante corresponde a la variable objetivo abandono). El diccionario está estructurado en siete bloques temáticos que reflejan la naturaleza informativa de cada grupo de variables: académicas, demográficas, socioeconómicas, administrativas, de rendimiento, contextuales y de origen académico.

Los estadísticos numéricos reportados en cada ficha (mínimos, máximos, medianas y conteos de valores nulos) se han extraído por introspección directa del fichero `dataset_final_tfm.parquet` mediante las funciones `describe()` e `isna()` de pandas, garantizando que cada cifra reportada corresponde con exactitud al insumo del modelado supervisado. La sección C.10 documenta adicionalmente las tres flags binarias `_missing` generadas durante el preprocesamiento de la Fase 5 para señalar la ausencia de información en las tres variables de calificación, sumando un total de veintisiete inputs técnicos efectivos al modelo.

C.1. Nota sobre la codificación interna de las variables categóricas

Las variables categóricas del dataset (sexo, rama, vía de acceso, país, provincia, cupo, situación laboral, indicador de interrupción y universidad de origen) se almacenan codificadas como números enteros, no como cadenas de texto. Esta decisión responde a tres motivos prácticos: en primer lugar, los algoritmos de gradient boosting empleados (LightGBM, XGBoost, CatBoost) requieren entradas numéricas y aplican internamente sus propias estrategias de tratamiento de variables categóricas; en segundo lugar, la representación entera reduce el consumo de memoria y acelera la lectura del fichero `parquet` en producción; en tercer lugar, la trazabilidad código-categoría se preserva mediante diccionarios versionados en `src/config_datos.py`, garantizando reproducibilidad.

En las fichas individuales que siguen, cada variable categórica documenta tanto el rango numérico observado como su correspondencia textual literal. Las correspondencias se han

verificado mediante cruce directo entre `dataset_final_tfm.parquet` y `meta_test_app.parquet` (que conserva la versión textual de las categorías), garantizando coherencia entre la representación interna del modelo y la presentación en la aplicación institucional.

C.2. Tabla resumen de las 24 features

La Tabla C.1 sintetiza las veinticuatro features ordenadas por bloque temático, indicando para cada una su nombre técnico, una descripción concisa y su tipo estructural. Las fichas detalladas se desarrollan en las secciones C.3 a C.9.

#	Nombre técnico	Bloque	Descripción	Tipo
1	cred_superados_anio_1er	Académica	Créditos superados en el primer año académico	Numérica
2	anios_gap	Académica	Años entre fin de estudios previos e inicio del grado	Numérica
3	nota_1er_anio	Académica	Nota media ponderada del primer curso (escala 5–10)	Numérica
4	nota_acceso	Académica	Nota de acceso a la titulación (escala 5–14)	Numérica
5	nota_selectividad	Académica	Nota de la EvAU/PAU (escala 5–14)	Numérica
6	via_acceso	Académica	Vía de acceso a la universidad (11 categorías)	Categórica
7	rama	Académica	Rama de conocimiento (5 categorías: TE, HU, SO, SA, EX)	Categórica
8	indicador_interrupcion	Académica	Indicador binario de interrupción de estudios previa	Binaria
9	pais_nombre	Demográfica	País de nacionalidad agrupado en 5 categorías	Categórica
10	provincia	Demográfica	Provincia de residencia agrupada en 6 categorías	Categórica
11	edad_entrada	Demográfica	Edad en años en el momento de la primera matrícula	Numérica
12	sexo	Demográfica	Sexo declarado (Hombre / Mujer)	Binaria
13	n_anios_beca	Socioeconómica	Número de cursos con beca concedida	Numérica

#	Nombre técnico	Bloque	Descripción	Tipo
14	anios_sin_beca	Socioeconómica	Número de cursos sin beca concedida	Numérica
15	situacion_laboral	Socioeconómica	Situación laboral declarada (4 categorías)	Categórica
16	n_anios_trabajando	Socioeconómica	Número de cursos con situación laboral activa	Numérica
17	cupo	Administrativa	Cupo de admisión a la universidad (8 categorías)	Categórica
18	max_pagos	Administrativa	Número máximo de pagos fraccionados de la matrícula	Numérica
19	orden_preferencia	Administrativa	Orden de preferencia de la titulación en la solicitud	Numérica
20	cred_repetidos	Rendimiento	Créditos repetidos a lo largo del expediente	Numérica
21	tasa_repeticion	Rendimiento	Tasa de repetición sobre créditos matriculados	Numérica
22	n_anios_sin_notas	Rendimiento	Número de cursos sin calificaciones registradas	Numérica
23	tasa_abandono_titulacion	Contextual	Tasa histórica de abandono de la titulación	Numérica
24	universidad_origen	Origen	Universidad de procedencia (6 categorías)	Categórica

Tabla C.1. Resumen estructurado de las 24 features del dataset modelable `dataset_final_tfm.parquet` (33.621×25), agrupadas en siete bloques temáticos. La tabla excluye la variable objetivo `abandono`, descrita en C.11. Fuente: elaboración propia a partir de la Fase 3 del proyecto.

C.3. Bloque 1. Variables académicas (8 features)

El bloque académico recoge las ocho variables relacionadas con el itinerario formativo de la persona estudiante: créditos superados, gaps temporales, calificaciones, vía de acceso, rama y antecedentes de interrupción. Es el bloque más representado en el modelo final y, según los análisis SHAP de la sección 4.6 del Capítulo 4, concentra los principales drivers predictivos.

C.3.1. `cred_superados_anio_1er`

Atributo	Valor
Nombre técnico	<code>cred_superados_anio_1er</code>

Tipo	Numérica continua (float64)
Descripción	Número total de créditos académicos superados durante el primer año de estudios. Considerada en la literatura como el predictor temprano más relevante del riesgo de abandono universitario (Aulck et al., 2016; Berens et al., 2019).
Rango / valores	Mínimo 0,00 — Máximo 252,00 — Mediana 54,00. Una matrícula completa anual estándar corresponde a 60 créditos ECTS; valores muy elevados se deben a estudiantado que matricula varios cursos simultáneamente o a registros con créditos convalidados.
Codificación	Sin codificación adicional. Se mantiene la unidad ECTS original.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.2. anios_gap

Atributo	Valor
Nombre técnico	anios_gap
Tipo	Numérica entera (int64)
Descripción	Número de años transcurridos entre la finalización de los estudios previos (Bachillerato, FP u otros) y el inicio de la titulación de grado. Aproxima la dimensión de continuidad o reincorporación al sistema educativo.
Rango / valores	Mínimo 0 — Máximo 8 — Mediana 0. La mayoría del estudiantado accede de forma inmediata; valores superiores a cero identifican perfiles de reincorporación.
Codificación	Conteo entero de años naturales. Valores de cero indican acceso continuo.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.3. nota_1er_anio

Atributo	Valor
Nombre técnico	nota_1er_anio
Tipo	Numérica continua (float64)
Descripción	Nota media ponderada por créditos del primer curso académico de la titulación. Refleja el rendimiento inicial y constituye un indicador robusto del ajuste académico temprano (Tinto, 1975; Himmel, 2002).
Rango / valores	Mínimo 5,00 — Máximo 10,00 — Mediana 6,79. Escala oficial española de calificaciones; el mínimo de 5,00 corresponde al aprobado.
Codificación	Escala oficial 5,00-10,00. No se imputa la nota al estudiantado sin calificaciones registradas; en su lugar se genera la flag binaria nota_1er_anio_missing (véase C.10).

Nulos en dataset	2.353 (7,00 %), señalizados con la flag nota_1er_anio_missing.
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.4. nota_acceso

Atributo	Valor
Nombre técnico	nota_acceso
Tipo	Numérica continua (float64)
Descripción	Nota de acceso a la titulación. Combina expediente académico previo y, en su caso, calificaciones de pruebas específicas, en función de la vía de acceso del estudiantado.
Rango / valores	Mínimo 5,00 — Máximo 13,81 — Mediana 8,22. La escala extendida hasta 14,00 se aplica cuando se contabilizan asignaturas específicas de la fase voluntaria de la EvAU.
Codificación	Escala oficial 5,00-14,00. Se genera flag nota_acceso_missing para registros sin valor (véase C.10).
Nulos en dataset	2.567 (7,64 %), señalizados con la flag nota_acceso_missing.
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.5. nota_selectividad

Atributo	Valor
Nombre técnico	nota_selectividad
Tipo	Numérica continua (float64)
Descripción	Nota obtenida en la prueba de selectividad (PAU/EvAU/Logse, según el periodo histórico). Es complementaria a nota_acceso pero puede no estar presente para vías de acceso que no requieren prueba específica.
Rango / valores	Mínimo 5,00 — Máximo 12,54 — Mediana 6,57.
Codificación	Escala oficial 5,00-14,00. Se genera flag nota_selectividad_missing (véase C.10).
Nulos en dataset	3.118 (9,27 %), señalizados con la flag nota_selectividad_missing.
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.6. via_acceso

Atributo	Valor
Nombre técnico	via_acceso
Tipo	Categorica (codificada como int64)
Descripción	Vía administrativa por la que el estudiantado accede a la titulación. La sección 4.7 del Capítulo 4 identifica esta variable como uno de los tres atributos sensibles del análisis de equidad, dado que correlaciona con la oportunidad educativa previa.

Rango / valores	11 categorías observadas en el dataset, codificadas con valores enteros no consecutivos. Categorías textuales: 'Pruebas acceso Bachiller Logse' (mayoritaria), 'Ciclo Formativo de Grado superior o equivalente', 'Pruebas acceso mayores 25 años', 'Pruebas acceso mayores 40 años', 'Pruebas acceso mayores 45 años', 'Titulados Universitarios', 'Adaptación a Grado', 'Traslado', 'Extranjeros CEE', 'Extranjeros no CEE' y 'Deportistas de élite'.
Codificación	Codificación entera no ordinal heredada del sistema de gestión académica original. La correspondencia código → nombre está documentada en src/config_datos.py.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.7. rama

Atributo	Valor
Nombre técnico	rama
Tipo	Categorica (codificada como int64)
Descripción	Rama de conocimiento de la titulación según la clasificación oficial española. Constituye uno de los tres atributos sensibles considerados en el análisis de equidad (sección 4.7 del Capítulo 4) por las posibles disparidades disciplinares.
Rango / valores	5 categorías: TE (Ingeniería y Arquitectura), HU (Artes y Humanidades), SO (Ciencias Sociales y Jurídicas), SA (Ciencias de la Salud) y EX (Ciencias).
Codificación	Codificación entera no ordinal: 1=TE, 2=HU, 3=SO, 4=SA, 5=EX. La correspondencia se documenta en src/config_datos.py mediante el diccionario RAMA_MAP.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.3.8. indicador_interrupcion

Atributo	Valor
Nombre técnico	indicador_interrupcion
Tipo	Binaria (codificada como int64)
Descripción	Indicador binario que señala si el expediente del estudiantado registra alguna interrupción previa de los estudios. Captura la dimensión de discontinuidad académica como factor de riesgo.
Rango / valores	Dos valores posibles: 0 (sin interrupción registrada) y 1 (con interrupción registrada).
Codificación	0 = No, 1 = Sí.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.4. Bloque 2. Variables demográficas (4 features)

El bloque demográfico recoge cuatro variables que caracterizan el perfil sociodemográfico básico del estudiantado. Dos de ellas (sexo y, con lectura matizada, rama) se utilizan como atributos sensibles en el análisis de equidad de la sección 4.7 del Capítulo 4.

C.4.1. pais_nombre

Atributo	Valor
Nombre técnico	pais_nombre
Tipo	Categórica (codificada como int64)
Descripción	País de nacionalidad del estudiantado, agrupado en 5 categorías por frecuencia debido a la elevada cardinalidad original (45 países distintos en el dataset, con frecuencias muy desiguales).
Rango / valores	5 categorías: 1=España (mayoritaria, 31.303 registros), 2=resto de países europeos agrupados, 3=América Latina agrupada, 4=Asia agrupada, 5=África agrupada.
Codificación	Agrupación por área geográfica para reducir cardinalidad y evitar sobreajuste sobre nacionalidades minoritarias. La granularidad original (nombre del país) se conserva en meta_test_app.parquet para consulta.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.4.2. provincia

Atributo	Valor
Nombre técnico	provincia
Tipo	Categórica (codificada como int64)
Descripción	Provincia de residencia declarada en el momento de la matrícula, agrupada en 6 categorías por frecuencia. Las cuatro provincias mayoritarias se mantienen individualmente y el resto se consolidan en categorías agregadas.
Rango / valores	6 categorías: 0=Estrangers (residencia fuera de España), 1=Castelló (mayoritaria), 2=València, 3=Alacant, 4=Tarragona, 5=Terol. La granularidad original recoge 41 provincias distintas, conservada en meta_test_app.parquet.
Codificación	Agrupación por frecuencia y proximidad geográfica al campus de la UJI.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.4.3. edad_entrada

Atributo	Valor
Nombre técnico	edad_entrada
Tipo	Numérica entera (int64)
Descripción	Edad del estudiantado en años cumplidos en el momento de la primera matrícula en la titulación.
Rango / valores	Mínimo 5 — Máximo 68 — Mediana 19. Los valores extremos corresponden a casos atípicos del registro administrativo y se conservan tras la limpieza para preservar la trazabilidad del histórico.
Codificación	Sin codificación adicional. Edad en años naturales.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.4.4. sexo

Atributo	Valor
Nombre técnico	sexo
Tipo	Binaria (codificada como int64)
Descripción	Sexo declarado en el sistema administrativo. Constituye uno de los tres atributos sensibles del análisis de equidad (sección 4.7 del Capítulo 4), alineado con el ODS 5 (Igualdad de género).
Rango / valores	Dos valores: 0=Mujer, 1=Hombre.
Codificación	0 = Mujer, 1 = Hombre. Codificación heredada del sistema de gestión académica.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.5. Bloque 3. Variables socioeconómicas (4 features)

El bloque socioeconómico capta la dimensión de apoyo institucional (becas) y de carga económica externa (situación laboral) durante el itinerario formativo. La sección 4.6 del Capítulo 4 evidencia que tres de las cuatro variables de este bloque figuran entre las quince más relevantes del modelo según SHAP.

C.5.1. n_anios_beca

Atributo	Valor
Nombre técnico	n_anios_beca

Tipo	Numérica entera (int64)
Descripción	Número de cursos académicos en los que el estudiantado ha disfrutado de beca concedida. Aproxima la dimensión de apoyo institucional sostenido como factor protector frente al abandono.
Rango / valores	Mínimo 0 — Máximo 9 — Mediana 1.
Codificación	Conteo entero de cursos.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.5.2. `anios_sin_beca`

Atributo	Valor
Nombre técnico	<code>anios_sin_beca</code>
Tipo	Numérica entera (int64)
Descripción	Número de cursos académicos sin beca concedida. Variable complementaria a <code>n_anios_beca</code> , captura la dimensión de exposición a esfuerzo económico individual.
Rango / valores	Mínimo 0 — Máximo 11 — Mediana 1.
Codificación	Conteo entero de cursos.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.5.3. `situacion_laboral`

Atributo	Valor
Nombre técnico	<code>situacion_laboral</code>
Tipo	Catórica (codificada como int64)
Descripción	Situación laboral declarada por el estudiantado. Constituye un proxy del tiempo disponible para los estudios y de la presión socioeconómica.
Rango / valores	4 categorías observadas: 0, 1, 2, 3.
Codificación	0 = Sin datos / No declarado, 1 = No trabaja (inactivo o desempleado), 2 = Trabaja a tiempo parcial, 3 = Trabaja a tiempo completo. Correspondencia documentada en <code>src/config_datos.py</code> mediante <code>SITUACION_LABORAL_MAP</code> .
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.5.4. `n_anios_trabajando`

Atributo	Valor
Nombre técnico	<code>n_anios_trabajando</code>

Tipo	Numérica entera (int64)
Descripción	Número de cursos académicos en los que el estudiantado declara situación laboral activa. Indicador acumulado complementario a situacion_laboral.
Rango / valores	Mínimo 0 — Máximo 6 — Mediana 1.
Codificación	Conteo entero de cursos.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.6. Bloque 4. Variables administrativas (3 features)

El bloque administrativo recoge tres variables relacionadas con el procedimiento formal de admisión y matrícula. A pesar de su naturaleza aparentemente burocrática, el orden de preferencia y el cupo de admisión presentan correlaciones moderadas con el abandono temprano.

C.6.1. cupo

Atributo	Valor
Nombre técnico	cupo
Tipo	Categorica (codificada como int64)
Descripción	Cupo de admisión a la universidad por el que el estudiantado obtuvo plaza, según la clasificación oficial.
Rango / valores	8 categorías codificadas: 0/1=General (mayoritaria), 2=Mayor 25 Años, 3=Titulados, 4=Mayor 40 años, 5=Mayor 45 años, 6=Personas con discapacidad reconocida, 7=Deportistas de Alto Nivel.
Codificación	Codificación entera heredada del sistema de admisión. Los códigos 0 y 1 corresponden ambos a 'General' por motivos históricos del registro.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.6.2. max_pagos

Atributo	Valor
Nombre técnico	max_pagos
Tipo	Numérica continua (float64)
Descripción	Número máximo de plazos en los que el estudiantado fraccionó la matrícula a lo largo de su expediente. Aproxima la dimensión de gestión económica administrativa.

Rango / valores	Mínimo 1,00 — Máximo 7,00 — Mediana 2,00.
Codificación	Conteo entero de pagos. Conservada como float por la presencia residual de tres registros con valor nulo no imputado.
Nulos en dataset	3 (0,01 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.6.3. orden_preferencia

Atributo	Valor
Nombre técnico	orden_preferencia
Tipo	Numérica entera (int64)
Descripción	Posición de la titulación en la lista de preferencias declaradas por el estudiantado en su solicitud de admisión. Refleja el grado de coincidencia entre la titulación cursada y la opción preferida.
Rango / valores	Mínimo 0 — Máximo 20 — Mediana 1. Un valor de 1 indica que la titulación cursada era la primera opción declarada.
Codificación	Posición ordinal directa.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.7. Bloque 5. Variables de rendimiento (3 features)

El bloque de rendimiento complementa las calificaciones del bloque académico con tres indicadores acumulados de dificultad y desconexión académica. A diferencia de las calificaciones puntuales, estas variables capturan el patrón a lo largo del expediente completo.

C.7.1. cred_repetidos

Atributo	Valor
Nombre técnico	cred_repetidos
Tipo	Numérica continua (float64)
Descripción	Suma acumulada de créditos repetidos a lo largo del expediente académico. Indicador robusto de dificultad académica recurrente.
Rango / valores	Mínimo 0,00 — Máximo 324,00 — Mediana 0,00. La mediana cero indica que la mayoría del estudiantado no repite créditos.
Codificación	Sin codificación adicional. Unidad ECTS.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.7.2. tasa_repeticion

Atributo	Valor
Nombre técnico	tasa_repeticion
Tipo	Numérica continua (float64)
Descripción	Ratio entre créditos repetidos y créditos matriculados totales, normalizando cred_repetidos por la dedicación académica de cada persona estudiante.
Rango / valores	Mínimo 0,00 — Máximo 135,00 — Mediana 0,00. Valores por encima de 1,00 corresponden a casos en los que se han repetido créditos en múltiples ocasiones, conservados sin truncar para preservar la información del expediente.
Codificación	Ratio decimal sin truncar.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.7.3. n_anios_sin_notas

Atributo	Valor
Nombre técnico	n_anios_sin_notas
Tipo	Numérica entera (int64)
Descripción	Número de cursos académicos sin calificaciones registradas en el expediente. Indicador potencial de desconexión académica progresiva, complementario a la nota media.
Rango / valores	Mínimo 0 — Máximo 7 — Mediana 0.
Codificación	Conteo entero de cursos.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.8. Bloque 6. Variable contextual (1 feature)

El bloque contextual contiene una única variable que recoge información agregada del entorno de la titulación. Su función es proporcionar al modelo conocimiento sobre el comportamiento histórico de cada titulación sin recurrir directamente a la variable nominal titulacion, excluida del modelado por su alta cardinalidad y por el riesgo de fuga de información asociado.

C.8.1. tasa_abandono_titulacion

Atributo	Valor
Nombre técnico	tasa_abandono_titulacion

Tipo	Numérica continua (float64)
Descripción	Tasa histórica de abandono de la titulación a la que pertenece el registro, calculada en una ventana temporal previa al curso de inicio del estudiantado. Esta variable contextual incorpora al modelo el comportamiento agregado de la titulación, evitando el uso directo de la variable nominal titulacion (excluida por riesgo de fuga de información, sección 3.5.3 del Capítulo 3).
Rango / valores	Mínimo 0,00 — Máximo 0,60 — Mediana 0,28. Valores en escala 0,00-1,00 (proporción).
Codificación	Proporción decimal calculada sobre el histórico previo de cada titulación.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.9. Bloque 7. Variable de origen académico (1 feature)

El bloque de origen contiene una única variable que identifica la universidad de procedencia para perfiles de traslado o adaptación, completando así la trazabilidad institucional del itinerario.

C.9.1. universidad_origen

Atributo	Valor
Nombre técnico	universidad_origen
Tipo	Categórica (codificada como int64)
Descripción	Universidad de procedencia en caso de traslado o adaptación a la titulación de la UJI. Registra la institución de origen para perfiles que no acceden directamente desde Bachillerato o FP.
Rango / valores	6 categorías observadas: 0, 1, 18, 27, 40, 55.
Codificación	0 = Otra universidad / sin datos, 1 = UJI (Universitat Jaume I), 18 = UV (Universitat de València), 27 = UA (Universidad de Alicante), 40 = UPV (Universitat Politècnica de València), 55 = UMH (Universidad Miguel Hernández de Elche). Códigos no consecutivos heredados del registro institucional original; correspondencia documentada en src/config_datos.py mediante UNIVERSIDAD_ORIGEN_MAP.
Nulos en dataset	0 (0,00 %).
Fuente	Sistemas de gestión académica de la UJI (OPP / UADTI).

C.10. Flags de imputación: las 3 variables _missing

Durante el preprocesamiento de la Fase 5, las tres variables de calificación con tasas de nulos no despreciables (nota_1er_anio, nota_acceso y nota_selectividad) se acompañan de una

variable binaria adicional que señala la ausencia de información. Este patrón de diseño se conoce como missing indicator y permite al modelo aprender que la propia ausencia de calificación es informativa per se, distinguiendo entre estudiantado con calificación baja y estudiantado sin calificación registrada.

La imputación numérica de la variable original se realiza con la mediana del conjunto de entrenamiento, mientras que la flag binaria asociada conserva la información de ausencia. Las tres flags resultantes son `nota_1er_anio_missing`, `nota_acceso_missing` y `nota_selectividad_missing`, codificadas con 0 cuando la calificación está presente y 1 cuando ha sido imputada. Su inclusión eleva el número de inputs técnicos del modelo de 24 a 27.

La sección B.4 del Anexo B muestra que las tres flags `_missing` no figuran entre las quince variables más importantes según los criterios split y gain, lo que indica que su contribución al modelo es secundaria pero metodológicamente correcta: actúan como variables de control que permiten al algoritmo distinguir el origen de los valores imputados sin amplificar artificialmente su peso.

C.11. Variable objetivo: abandono

La variable objetivo del modelo binario es abandono, definida en la sección 3.1.4 del Capítulo 3 conforme al criterio operativo de Himmel (2002): se considera que el estudiantado ha abandonado cuando no se vuelve a matricular durante dos cursos consecutivos en la misma titulación y universidad. La codificación es 0 (no abandono) frente a 1 (abandono), con una distribución global del 70,75 % frente al 29,25 % sobre el dataset modelable de 33.621 registros.

Esta proporción se mantiene de forma equivalente en los conjuntos de entrenamiento ($n = 26.896$) y test ($n = 6.725$) tras la división estratificada descrita en la sección 3.8 del Capítulo 3, garantizando la representatividad del desbalance en la fase de evaluación.

Anexo D. Configuración y arquitectura de la fase AutoML

El presente anexo documenta la configuración técnica de la fase de validación AutoML descrita en la sección 4.3 del Capítulo 4. La estrategia metodológica responde a la propuesta de Erickson et al. (2020), quienes recomiendan utilizar el AutoML como techo de referencia rápido y objetivo antes de invertir tiempo en optimización manual de hiperparámetros. La fase se estructura en siete módulos secuenciales (denominados M01 a M07) que comparten el mismo dataset, la misma división train/test y un protocolo de evaluación equivalente, garantizando la comparabilidad entre frameworks.

De los siete módulos, cinco corresponden a frameworks AutoML propiamente dichos (LazyPredict, PyCaret, H2O AutoML y AutoGluon, junto con el modelo preentrenado TabPFN v2 incorporado a propuesta del tutor como diferenciador metodológico orientado a la calificación cum laude), uno establece la referencia mínima mediante baselines clásicos con validación cruzada estratificada (M01) y el último (M07) consolida los resultados en un ranking global. Esta arquitectura modular, con un módulo independiente por framework, permite ejecutar cada uno en su entorno conda óptimo y publicar informes HTML autocontenidos navegables que documentan la trazabilidad completa del proceso.

D.1. Arquitectura modular de la fase AutoML

La Tabla D.1 sintetiza los siete módulos de la fase AutoML, indicando el framework empleado, el entorno conda asociado y la descripción técnica de su funcionalidad.

ID	Módulo	Entorno	Descripción técnica
M01	Baselines	tfm_abandono	DummyClassifier, LogisticRegression, RandomForest, GradientBoosting y XGBoost con validación cruzada estratificada de 5 pliegues. Establece la referencia mínima de rendimiento.
M02	LazyPredict	env_lazypredict	Screening rápido de aproximadamente 30 clasificadores de scikit-learn con parámetros por defecto. Sin validación cruzada, orientado a identificar familias prometedoras.
M03	PyCaret	env_pycaret	AutoML con compare_models() sobre aproximadamente 15 algoritmos con CV=5

ID	Módulo	Entorno	Descripción técnica
			estratificada y preprocesamiento automático integrado.
M04	H2O AutoML	env_h2o	AutoML distribuido con GBM, XGBoost, DRF, GLM y StackedEnsemble. Validación cruzada 5-fold y optimización automática de hiperparámetros. Requiere Java 8+.
M05	AutoGluon	env_autogluon	Stacking multi-capas automático con LightGBM, CatBoost, XGBoost, RandomForest, ExtraTrees, NeuralNetworks y WeightedEnsemble. Configurado en preset best_quality con time_limit=600s.
M06	TabPFN v2	tfm_abandono	Transformer preentrenado (Hollmann et al., 2024) que realiza inferencia bayesiana aproximada sin entrenamiento. Incorporado a propuesta del tutor como diferenciador metodológico.
M07	Comparativa	tfm_abandono	Consolidación de resultados M01-M06 en un ranking global. Identifica el baseline definitivo que la Fase 5 debe superar.

Tabla D.1. Arquitectura modular de la fase AutoML del proyecto. Cada módulo se ejecuta como un notebook Jupyter independiente con su propio kernel asociado a un entorno conda específico. Esta separación garantiza que las dependencias incompatibles entre frameworks no se contaminen entre sí. Fuente: elaboración propia a partir de los notebooks `fautoml_m00_indice.ipynb` a `fautoml_m07_comparativa.ipynb` del repositorio.

D.2. Configuración común a todos los módulos

Para garantizar la comparabilidad de los resultados entre frameworks, todos los módulos comparten un protocolo de evaluación y un dataset de entrada idénticos. La Tabla D.2 documenta los aspectos comunes.

Aspecto compartido	Configuración
Dataset de entrada	data/automl/dataset_final_tfm.parquet — 33.621 expedientes × 24 features + variable objetivo abandono.
División train/test	70 % entrenamiento / 30 % test, estratificada por la variable abandono. División idéntica para M01-M06.
Variable objetivo	abandono (binaria, 0 = no abandono / 1 = abandono). Tasa global de abandono 29,25 %.

Aspecto compartido	Configuración
Criterio de ordenación	F1-score sobre el conjunto de test, complementado con AUC-ROC, Precision, Recall, MCC, Kappa y log-loss.
Salida estandarizada	Cada módulo genera un fichero results_*.parquet en data/automl/ y un informe HTML autocontenido en docs/html/fase_automl/.
Consolidación	El módulo M07 lee todos los results_*.parquet, construye el ranking global y produce automl_top_modelos.parquet con el mejor modelo de cada framework.

Tabla D.2. Configuración compartida por todos los módulos AutoML. La estandarización de la división train/test y de los criterios de ordenación es condición necesaria para que el ranking global del módulo M07 sea estadísticamente comparable. Fuente: elaboración propia a partir de los notebooks de la fase AutoML.

D.3. Resultados consolidados por framework

La Tabla D.3 recoge el mejor modelo identificado por cada uno de los seis módulos evaluativos, ordenados por F1-score sobre el conjunto de test. Los datos provienen directamente de los ficheros results_*.parquet generados por cada notebook y consolidados en el módulo M07. En total se evaluaron 80 modelos individuales a través de los seis módulos.

#	Framework	Mejor modelo	N modelos	F1	AUC	Precision	Recall
1	TabPFN v2	TabPFN v2	1	0,8496	0,9644	0,8946	0,8088
2	AutoGluon	WeightedEnsemble_L2	10	0,833	0,9580	0,8815	0,7895
3	Baselines	XGBoost	6	0,8296	0,9532	0,8676	0,7949
4	LazyPredict	XGBClassifier	27	0,8296	0,8724	0,8676	0,7949
5	H2O AutoML	GBM_grid	21	0,8296	0,9544	0,8730	0,7902
6	PyCaret	Light Gradient Boosting Machine	15	0,8284	0,9521	0,8681	0,7924

Tabla D.3. Mejor modelo identificado por cada módulo evaluativo, ordenados por F1-score sobre el conjunto de test ($n = 6.725$, sin filtrado B-LIGERA aplicado en evaluación final). La columna 'N modelos' indica el número total de modelos evaluados por cada framework. Fuente: elaboración propia a partir de los ficheros results_baselines.parquet, results_lazypredict.parquet, results_pycaret.parquet, results_h2o.parquet, results_autogluon.parquet y results_tabpfm.parquet del repositorio.

La diferencia de rendimiento entre frameworks (excluyendo TabPFN v2) resultó marginal, con todos los valores F1 comprendidos en el intervalo [0,8284 — 0,833]. Esta convergencia confirma la idoneidad de la familia algorítmica Gradient Boosting para el problema y reforzó la decisión metodológica de pasar al modelado clásico estructurado de la Fase 5 con un espacio de hiperparámetros controlado, en lugar de continuar la búsqueda dentro de AutoML.

D.4. Análisis específico de TabPFN v2

Los resultados de la Tabla D.3 destacan a TabPFN v2 como el framework con mejor rendimiento métrico bruto: F1 = 0,850 y AUC = 0,964 sobre el conjunto de test. Este resultado, superior tanto al baseline AutoGluon como al modelo final seleccionado en la Fase 5 (LightGBM__none, F1 = 0,833), exige una discusión específica sobre los criterios que llevaron a no adoptarlo como modelo de producción del proyecto.

TabPFN v2 (Hollmann et al., 2024) representa el estado del arte actual en clasificación tabular. Se trata de un transformer preentrenado en millones de datasets sintéticos que realiza inferencia bayesiana aproximada en una única pasada hacia delante, sin ajuste de hiperparámetros ni proceso de entrenamiento sobre los datos de la persona usuaria. Esta arquitectura le permite obtener rendimientos competitivos sin invertir tiempo en optimización, pero introduce restricciones operativas significativas que deben evaluarse caso por caso.

La Tabla D.4 contrasta los criterios técnicos relevantes para la decisión entre TabPFN v2 y el modelo finalmente seleccionado, LightGBM con estrategia 'none' identificado en la Fase 5.

Criterio	TabPFN v2	LightGBM__none (Fase 5)
F1 sobre test	0,8496	0,833
AUC-ROC	0,9644	0,956
Tiempo de inferencia	26.230,8 segundos (~7,3 horas)	0,148 segundos para 6.725 alumnos
Tiempo de entrenamiento	Sin entrenamiento (modelo preentrenado)	25,15 segundos
Tamaño del modelo serializado	≈ varios cientos de MB (transformer)	932,7 KB
Despliegue en producción ligera	Inviabile (requiere transformer en memoria)	Viable (Streamlit Cloud, despliegue inmediato)
Interpretabilidad SHAP nativa	No disponible (caja negra)	Disponible (TreeExplainer)

Criterio	TabPFN v2	LightGBM__none (Fase 5)
Reproducibilidad bit-a-bit	Depende del backend del transformer	Total (random_state fijado)
Coste energético (sostenibilidad)	Alto (uso prolongado de GPU/CPU)	Mínimo (segundos de CPU)

Tabla D.4. Comparativa entre TabPFN v2 y LightGBM__none según los criterios relevantes para la selección del modelo de producción del proyecto. Fuente: elaboración propia a partir de results_tabpfn.parquet, LightGBM__none.pkl y la sección 4.8 del Capítulo 4 (robustez y sostenibilidad).

El criterio decisivo para no adoptar TabPFN v2 como modelo de producción es operativo: el sistema debe desplegarse como aplicación web institucional (Streamlit Cloud) accesible al servicio de orientación de la UJI con tiempos de respuesta de pocos segundos. El tiempo de inferencia de TabPFN v2 sobre el conjunto de test (26.230,8 segundos, equivalente a 7,3 horas) lo hace inviable en este contexto, mientras que LightGBM__none completa la misma tarea en 0,148 segundos. Adicionalmente, TabPFN v2 carece de interpretabilidad SHAP nativa y presenta un coste energético muy superior, en contradicción con el principio de sostenibilidad documentado en la sección 4.8 del Capítulo 4.

La incorporación de TabPFN v2 en la fase AutoML responde a la propuesta del tutor del proyecto de incluir el estado del arte tabular como referencia metodológica orientada a la calificación cum laude. Su inclusión documenta que el rendimiento del modelo final del proyecto se sitúa razonablemente cerca del techo teórico actual ($\Delta F1 = 0,0162$; $\Delta AUC = 0,0080$), validando la solidez técnica del trabajo, pero también confirma que en contextos de producción educativa con restricciones operativas, los modelos clásicos bien optimizados como LightGBM siguen siendo la opción más adecuada.

D.5. Baseline establecido para la Fase 5

Excluyendo TabPFN v2 por las razones operativas descritas en D.4, el baseline objetivo establecido para la Fase 5 fue el mejor modelo de AutoGluon: WeightedEnsemble_L2, con un F1 de 0,833 y un AUC de 0,9580 sobre el conjunto de test. Este modelo combina mediante un ensemble ponderado los mejores algoritmos individuales evaluados por AutoGluon (LightGBM, CatBoost, XGBoost y RandomForest), todos ellos con bagging interno.

La convergencia de los cinco frameworks AutoML hacia familias de árboles ensamblados (Gradient Boosting, Random Forest y sus variantes con stacking) confirmó la idoneidad de esta categoría algorítmica para el problema, dada la naturaleza tabular y mixta (numérica-categorica) de las features y la presencia de relaciones no lineales documentadas en el análisis exploratorio. La diferencia de rendimiento entre frameworks resultó marginal (rangos de F1 entre 0,8284 y 0,833), lo que reforzó la decisión de pasar al modelado clásico estructurado en la Fase 5 en lugar de continuar la búsqueda dentro de AutoML.

El modelo final del proyecto, LightGBM con estrategia 'none' identificado en la Fase 5 y descrito en los Anexos A y B, alcanza un F1 de 0,833 frente al 0,833 de WeightedEnsemble_L2 ($\Delta F1 = +0,0004$) y un AUC de 0,956 frente a 0,9580 ($\Delta AUC = -0,0016$). Aunque la diferencia métrica respecto al baseline es marginal, LightGBM__none ofrece ventajas operativas sustanciales que justifican su selección: un único modelo serializable de menos de 1 MB frente al ensemble pesado de AutoGluon, interpretabilidad SHAP nativa y tiempo de inferencia un orden de magnitud inferior. Esta combinación de rendimiento equiparable y operatividad superior constituye la argumentación central del proyecto para validar la estrategia de modelado clásico optimizado frente a AutoML genérico.

D.6. Infraestructura de ejecución y orquestación

La fase AutoML se diseñó originalmente con cinco entornos conda separados (tfm_abandono como entorno principal y env_lazypredict, env_pycaret, env_h2o y env_autogluon como entornos especializados) debido a la incompatibilidad de dependencias entre algunos frameworks. La instalación de cada entorno se documenta en el fichero entornos_automl.md del repositorio del proyecto, que recoge los comandos exactos de creación, instalación y registro de kernel reproducibles.

La orquestación de la fase se realiza mediante el notebook fautoml_m00_ejecucion.ipynb, que ejecuta secuencialmente cada módulo utilizando nbconvert con un timeout de 3.600 segundos por celda y registra el estado de cada ejecución en una tabla de progreso interactiva basada en ipywidgets. Si un módulo falla, el orquestador continúa con el siguiente y registra el error en un informe HTML de estado, evitando que un fallo aislado bloquee la fase completa.

La separación de entornos resulta especialmente relevante para H2O (que requiere Java 8 o superior instalado en el sistema) y para AutoGluon (que en sistemas Windows debe utilizar rutas

locales fuera del directorio sincronizado de OneDrive para evitar conflictos durante el guardado de los modelos temporales). Estas particularidades técnicas se documentan exhaustivamente en `entornos_automl.md` como referencia de reproducibilidad para cualquier auditoría posterior del proyecto.

Anexo E. Definiciones formales de las métricas de equidad

La sección 4.7 del Capítulo 4 reporta los valores de tres métricas de equidad algorítmica para los tres atributos sensibles considerados en este proyecto (sexo, rama de conocimiento y vía de acceso). El presente anexo recoge la definición matemática formal de cada una de estas métricas, su fundamento conceptual dentro de la taxonomía de fairness en aprendizaje automático y los umbrales de interpretación adoptados, todo ello en consonancia con la formulación canónica de Mehrabi et al. (2021).

La elección de tres métricas complementarias responde a la imposibilidad demostrada formalmente de satisfacer simultáneamente todas las definiciones de equidad cuando las tasas base difieren entre grupos (Chouldechova, 2017; Kleinberg et al., 2017). Por ello, en lugar de optimizar una métrica única, se reportan tres criterios que iluminan diferentes aspectos del comportamiento del modelo: la paridad de las predicciones (DPD), la equidad de las oportunidades (EOD) y el impacto adverso proporcional (DIR).

E.1. Notación común

Las tres métricas se formulan sobre un clasificador binario que predice una variable objetivo Y a partir de un vector de features X . Adicionalmente, cada persona estudiante posee un atributo sensible A que define su pertenencia a un grupo demográfico o sociológico. La Tabla E.1 recoge la notación común empleada en las definiciones formales que siguen.

Símbolo	Definición
Y	Variable objetivo real (0 = no abandono; 1 = abandono).
$\hat{Y}$	Predicción binaria del modelo (0 = no riesgo; 1 = riesgo de abandono), obtenida tras umbralizar la probabilidad estimada con $t = 0,5$.
A	Atributo sensible del alumnado (sexo, rama de conocimiento o vía de acceso, según el análisis).
a, a'	Valores específicos del atributo sensible que definen los grupos a comparar (por ejemplo, $a = \text{'Mujer'}$ y $a' = \text{'Hombre'}$).
$P(\cdot)$	Probabilidad empírica calculada sobre el conjunto de test. Por ejemplo, $P(\hat{Y} = 1 \mid A = a)$ es la proporción de personas estudiantes del grupo a a quienes el modelo predice abandono.
TPR_a	Tasa de verdaderos positivos del grupo a (también recall o sensibilidad): proporción de personas que abandonan y son correctamente identificadas.

Símbolo	Definición
FPR_a	Tasa de falsos positivos del grupo a: proporción de personas que no abandonan pero el modelo identifica erróneamente como en riesgo.

Tabla E.1. Notación común de las métricas de equidad evaluadas en la sección 4.7 del Capítulo 4. Adaptada de Mehrabi et al. (2021) y Verma y Rubin (2018).

E.2. Demographic Parity Difference (DPD)

Definición formal

La paridad demográfica establece que la probabilidad de recibir una predicción positiva (en este caso, ser identificada como en riesgo de abandono) debe ser equivalente entre los distintos grupos del atributo sensible. Su versión cuantificada como diferencia se define como:

$$DPD = | P(\hat{Y} = 1 \mid A = a) - P(\hat{Y} = 1 \mid A = a') |$$

donde a y a' representan dos valores del atributo sensible A . El valor del DPD se sitúa en el intervalo $[0, 1]$ y es directamente interpretable como la diferencia absoluta de tasas de predicción positiva entre ambos grupos.

Interpretación

Un $DPD = 0$ indica paridad demográfica perfecta: el modelo predice riesgo de abandono con la misma frecuencia para todos los grupos. Valores positivos indican que un grupo recibe predicciones positivas con mayor frecuencia que el otro, sin que esta diferencia esté justificada por la métrica en sí (no se contrasta con la tasa real).

Esta métrica está alineada con el principio de impacto independiente del grupo y resulta especialmente relevante en contextos donde las predicciones positivas conllevan asignación de recursos (becas, tutorías, programas de mentoría). Su limitación principal, ampliamente documentada en la literatura (Hardt et al., 2016), es que no contempla la posibilidad de tasas base reales distintas entre grupos: si un colectivo presenta efectivamente mayor incidencia del fenómeno predicho, exigir paridad demográfica perfecta implicaría asumir errores de clasificación adicionales.

E.3. Equal Opportunity Difference (EOD)

Definición formal

La equidad de oportunidades, propuesta por Hardt et al. (2016), establece que la tasa de verdaderos positivos (sensibilidad o recall) debe ser equivalente entre grupos. En el contexto del presente proyecto, esto significa que la capacidad del modelo para detectar correctamente el abandono debe ser similar para hombres y mujeres, para todas las ramas de conocimiento y para las distintas vías de acceso. Su formulación como diferencia es:

$$\text{EOD} = | \text{TPR}_a - \text{TPR}_{a'} |$$

o, expresada con notación probabilística completa:

$$\text{EOD} = | P(\hat{Y} = 1 \mid Y = 1, A = a) - P(\hat{Y} = 1 \mid Y = 1, A = a') |$$

El valor del EOD se sitúa también en el intervalo $[0, 1]$ y es directamente interpretable como la diferencia absoluta de sensibilidades entre ambos grupos.

Interpretación

Un $\text{EOD} = 0$ indica que el modelo identifica con la misma eficacia a las personas que abandonan, con independencia de su grupo. A diferencia del DPD, el EOD condiciona la métrica a los casos reales positivos ($Y = 1$), por lo que sí tiene en cuenta la tasa base de cada grupo y se considera una formulación más justificable estadísticamente cuando las tasas reales difieren (Hardt et al., 2016; Mehrabi et al., 2021).

Esta es la métrica de equidad más relevante para sistemas de detección temprana del abandono universitario, dado que penaliza directamente las diferencias en la capacidad del modelo para identificar a quien efectivamente está en riesgo. Una situación con EOD elevado significaría que el sistema falla sistemáticamente en detectar el abandono en uno de los grupos, dejándolo sin acceso a las intervenciones preventivas.

E.4. Disparate Impact Ratio (DIR)

Definición formal

El ratio de impacto desigual, también conocido como Disparate Impact, se inspira en la doctrina jurídica estadounidense del impacto adverso (Feldman et al., 2015) y mide la proporcionalidad relativa de las tasas de predicción positiva entre grupos:

$$\text{DIR} = P(\hat{Y} = 1 \mid A = a) / P(\hat{Y} = 1 \mid A = a')$$

El valor del DIR es estrictamente positivo. La interpretación se realiza respecto a la unidad: un valor de 1,00 indica paridad perfecta, valores menores indican que el grupo a recibe predicciones positivas con menor frecuencia que el grupo a' , y valores mayores indican lo contrario. Por convención, el grupo a' del denominador es el grupo de referencia o privilegiado.

Interpretación

La métrica DIR se evalúa según la regla de los cuatro quintos (4/5 rule), heredada de la Equal Employment Opportunity Commission (EEOC, 1978). Esta regla práctica establece que un ratio inferior a 0,80 (o superior a 1,25 en su recíproco) debe interpretarse como indicio de impacto adverso sobre el grupo desfavorecido. Aunque el origen de la regla es jurídico-laboral, su uso se ha extendido a la auditoría de sistemas algorítmicos (Bellamy et al., 2018; Bird et al., 2020).

El DIR es complementario al DPD: ambas métricas miden disparidades en la tasa de predicción positiva, pero la primera lo hace en términos relativos (ratio) y la segunda en términos absolutos (diferencia). Esta complementariedad es relevante en contextos con tasas base bajas: una diferencia absoluta del 5 % puede ser asumible si las tasas son del orden del 50 %, pero refleja un sesgo grave si las tasas son del orden del 10 % (en cuyo caso el DIR sería de 1,5 o superior).

E.5. Umbrales de interpretación adoptados

La literatura aplicada propone umbrales empíricos de tolerancia para clasificar los resultados como aceptables, de alerta o problemáticos. La Tabla E.2 recoge los umbrales adoptados en el presente proyecto, alineados con la práctica habitual de las herramientas de auditoría algorítmica de mayor difusión (IBM AI Fairness 360, Microsoft Fairlearn).

Métrica	Umbral aceptable	Justificación / referencia
DPD	$\leq 0,10$	Diferencias inferiores a 10 puntos porcentuales se consideran asumibles en la literatura aplicada (Bellamy et al., 2018; Bird et al., 2020). Valores entre 0,10 y 0,20 son zona de alerta; valores $> 0,20$ indican sesgo manifiesto.
EOD	$\leq 0,10$	Idéntica regla práctica al DPD. Diferencias en la sensibilidad superiores a 10 p.p. entre grupos comprometen la equidad operativa del sistema de detección temprana.
DIR	[0,80; 1,25]	Regla del cuatro quintos (4/5 rule), originaria de la Equal Employment Opportunity Commission de EE. UU. (Feldman et al., 2015). Valores fuera de este intervalo se consideran indicio de impacto adverso.

Tabla E.2. Umbrales de interpretación adoptados para las tres métricas de equidad. Estos umbrales se aplican como guía orientativa y no como criterio dicotómico de validación o rechazo del modelo: los hallazgos del Capítulo 4 sección 4.7 se interpretan caso a caso, considerando además el tamaño muestral de cada subgrupo y el contexto institucional. Fuente: elaboración propia a partir de Bellamy et al. (2018), Bird et al. (2020) y Feldman et al. (2015).

E.6. Limitaciones y advertencias metodológicas

La interpretación de las métricas anteriores debe acompañarse de tres advertencias fundamentales documentadas en la literatura especializada y conscientes en este proyecto.

En primer lugar, los teoremas de imposibilidad de Chouldechova (2017) y Kleinberg et al. (2017) demuestran que cuando las tasas base de la variable objetivo difieren entre grupos —como ocurre inevitablemente en el problema del abandono universitario— no es posible satisfacer simultáneamente la paridad demográfica, la equidad de oportunidades y la calibración. Esta imposibilidad formal exige adoptar criterios mixtos y aceptar compromisos razonados, como se hace en este trabajo.

En segundo lugar, las métricas de equidad evaluadas son criterios estadísticos agregados y no contemplan la equidad individual ni la equidad contrafactual. Una persona estudiante puede recibir un trato globalmente equitativo según las métricas, pero sufrir un sesgo individual no detectado por agregación. El proyecto incorpora análisis SHAP y casos canónicos en la sección 4.6 del Capítulo 4 para complementar este enfoque agregado con interpretabilidad individual.

En tercer lugar, los umbrales presentados en la Tabla E.2 son orientativos y no constituyen criterios absolutos. Un valor situado en zona de alerta puede ser asumible si el subgrupo afectado dispone de una muestra reducida (lo que dispara la varianza del estimador) o si la diferencia se explica por factores legítimos no asociados al atributo sensible. La interpretación final corresponde al análisis cualitativo realizado en la sección 4.7 del Capítulo 4 y se complementa con las recomendaciones institucionales

Anexo F. Librerías, entornos y estructura del repositorio

El presente anexo documenta el entorno técnico y las dependencias software del proyecto, garantizando la reproducibilidad bit a bit del modelo final y la trazabilidad de la generación de cada uno de los artefactos del trabajo. La información se estructura en cuatro bloques: las librerías de Python con sus versiones exactas pinned, los entornos conda utilizados, los ficheros de requirements disponibles para las distintas fases del proyecto y el árbol de directorios del repositorio público que aloja el código completo.

Toda la información reportada en este anexo se ha verificado mediante introspección directa de los ficheros del repositorio (`requirementsautoml.txt`, `requirements_proyecto.txt` y `entornos_automl.md`), sin recurrir a memoria ni a versiones supuestas. Las cotas con el operador `==` reflejan la versión exacta empleada en el entrenamiento del modelo final, mientras que las cotas con `>=` corresponden a las dependencias mínimas funcionales documentadas en los ficheros por fase.

F.1. Entorno técnico de referencia

El proyecto se desarrolló en un sistema Windows 10 con Python 3.11.14 y la distribución Anaconda como gestor de entornos virtuales. La elección de Python 3.11 responde a su estabilidad, compatibilidad con todas las librerías del proyecto y mejoras de rendimiento del intérprete respecto a versiones anteriores.

Para garantizar la reproducibilidad del modelo final y de los análisis de la fase AutoML, las dependencias se gestionan mediante la herramienta pip dentro de entornos conda dedicados. La fijación de versiones (pinning) sigue la convención `==` para el entorno principal de producción y `>=` para los entornos auxiliares de desarrollo.

F.2. Librerías Python por categoría funcional

Las librerías del proyecto se agrupan en nueve categorías funcionales que reflejan los grandes bloques metodológicos del trabajo. Cada tabla recoge el nombre técnico del paquete, la versión exacta empleada y la función específica que cumple dentro del proyecto.

F.2.1. Núcleo científico

Librería	Versión	Función
numpy	2.3.5	Operaciones numéricas y arrays multidimensionales.
pandas	2.3.3	Manipulación y análisis de datos tabulares.
scipy	1.15.3	Algoritmos científicos, estadística y optimización.
scikit-learn	1.6.1	Versión utilizada en el entrenamiento del modelo final. Pipelines, métricas, preprocesamiento.
statsmodels	0.14.6	Modelos estadísticos clásicos y tests de hipótesis.
joblib	1.5.3	Serialización del modelo final (formato .pkl) con compresión.
patsy	1.0.2	Especificación de fórmulas estadísticas para statsmodels.

F.2.2. Machine Learning clásico

Librería	Versión	Función
lightgbm	4.6.0	Algoritmo del modelo final del proyecto. Booster v4.
xgboost	3.1.2	Algoritmo competidor del modelo final, segundo en el ranking de la Fase 5.
catboost	1.2.10	Algoritmo evaluado en Fase 5 y baseline de AutoGluon (CatBoost_BAG_L2).
imbalanced-learn	0.14.1	Estrategias de manejo del desbalance de clases (SMOTE).
optuna	4.7.0	Optimización bayesiana de hiperparámetros (Fase 5).
aplr	10.22.0	Automatic Piecewise Linear Regression — modelo evaluado en la fase exploratoria.

F.2.3. Frameworks AutoML

Librería	Versión	Función
lazypredict	—	Screening rápido de aproximadamente 30 clasificadores (módulo M02).
pycaret	—	AutoML con compare_models() y validación cruzada (módulo M03).

Librería	Versión	Función
h2o	—	AutoML distribuido con StackedEnsemble (módulo M04). Requiere Java 8+.
autogluon	—	Stacking multi-capa automático (módulo M05).
tabpfn	7.1.1	Transformer preentrenado para clasificación tabular (módulo M06).
tabpfn-client	0.2.8	Cliente complementario para TabPFN.
tabpfn-common-utils	0.2.19	Utilidades compartidas del ecosistema TabPFN.

Nota: Las versiones de *LazyPredict*, *PyCaret*, *H2O* y *AutoGluon* no se reportan con pin exacto porque su instalación se gestionó originalmente en entornos conda independientes (*env_lazypredict*, *env_pycaret*, *env_h2o*, *env_autogluon*) cuyos requirements completos se documentan en el fichero *entornos_automl.md* del repositorio. Tras la consolidación posterior en el entorno principal *tfm_abandono*, las versiones operativas son las disponibles en PyPI al cierre del proyecto.

F.2.4. Interpretabilidad y equidad

Librería	Versión	Función
shap	0.51.0	Explicaciones SHAP del modelo final (sección 4.6 del Capítulo 4).
lime	0.2.0.1	Explicaciones locales como técnica complementaria a SHAP.
dice_ml	0.12	Explicaciones contrafactuales DiCE (Mohtilal et al., 2020).
interpret	0.7.6	InterpretML para Explainable Boosting Machine (EBM).
fairlearn	0.13.0	Métricas de equidad algorítmica y mitigación de sesgos.
raiutils	0.4.2	Responsible AI Utilities (Microsoft).
codecarbon	3.2.3	Medición del impacto ambiental del entrenamiento (sostenibilidad).

F.2.5. Visualización

Librería	Versión	Función
matplotlib	3.10.7	Gráficos estáticos base.
seaborn	0.13.2	Gráficos estadísticos sobre matplotlib.

Librería	Versión	Función
plotly	6.5.0	Gráficos interactivos en HTML para los informes y la app.
altair	6.0.0	Visualización declarativa basada en Vega-Lite.
dash	2.18.2	Aplicaciones interactivas (uso puntual).
folium	0.20.0	Mapas interactivos basados en Leaflet.
missingno	0.5.2	Visualización de valores faltantes.
sweetviz	2.3.1	Reportes automáticos de EDA.
plotnine	0.15.3	Gramática de gráficos al estilo ggplot2.
pyvis	0.3.2	Visualización interactiva de redes.
pywaffle	1.1.1	Gráficos waffle para visualización proporcional.
dash_cytoscape	1.0.2	Componentes Cytoscape para Dash.

F.2.6. Aplicación web y despliegue

Librería	Versión	Función
streamlit	1.55.0	Framework de la aplicación web institucional desplegada.
pydantic	2.12.5	Validación de datos y modelos en la app.
Flask	3.0.3	Microframework web para utilidades complementarias.

F.2.7. Deep Learning (dependencias indirectas)

Librería	Versión	Función
torch	2.11.0	Backend PyTorch utilizado por TabPFN v2.
einops	0.8.2	Operaciones tensoriales declarativas.
numba	0.64.0	Compilación JIT para acelerar bucles numéricos.

F.2.8. Datos y formatos

Librería	Versión	Función
pyarrow	22.0.0	Lectura y escritura de ficheros Parquet.
openpyxl	3.1.5	Lectura y escritura de ficheros Excel originales (Fase 1).
omegaconf	2.3.0	Gestión de configuraciones jerárquicas.
xarray	2026.2.0	Arrays multidimensionales con etiquetas.

Librería	Versión	Función
xxhash	3.6.0	Hashing rápido para deduplicación.

F.2.9. Utilidades del entorno y notebooks

Librería	Versión	Función
jinja2	3.1.6	Plantillas HTML para los informes generados por los notebooks.
jupyter	1.1.1	Plataforma interactiva de notebooks.
jupyterlab	4.5.1	Entorno de trabajo principal de los notebooks del TFM.
ipykernel	7.1.0	Kernel Python para Jupyter.
ipywidgets	8.1.8	Widgets interactivos en notebooks (orquestador).
nbconvert	7.16.6	Conversión y ejecución programática de notebooks.
tqdm	4.67.1	Barras de progreso en bucles.
rich	14.0.0	Salida formateada en terminal.
ruff	0.15.10	Linter de código Python.
graphviz	0.21	Renderizado de grafos.
networkx	3.6.1	Análisis de grafos.
pillow	11.1.0	Procesamiento de imágenes.
scikit-image	0.26.0	Procesamiento de imágenes científicas.
sqlalchemy	2.0.48	Acceso a bases de datos relacionales.
gitpython	3.1.46	Interacción programática con Git.
huggingface_hub	1.10.1	Descarga de modelos preentrenados (TabPFN).
pyyaml	6.0.3	Lectura y escritura YAML.
requests	2.32.5	Cliente HTTP.
packaging	25.0	Utilidades de versionado.

F.3. Entornos conda del proyecto

La fase AutoML se diseñó originalmente con cinco entornos conda separados para evitar conflictos de dependencias entre frameworks que comparten librerías core (numpy, scikit-learn) en versiones distintas. La Tabla F.X recoge la nomenclatura utilizada y el propósito de cada entorno. La definición exacta de cada uno se recoge en el fichero entornos_automl.md del

repositorio del proyecto, que documenta los comandos de creación, instalación y registro de kernel reproducibles.

Entorno conda	Propósito y notas técnicas
tfm_abandono	Entorno principal del proyecto. Contiene todas las librerías necesarias para Fases 1 a 7 completas, incluyendo el entrenamiento del modelo final LightGBM, los análisis de interpretabilidad SHAP/LIME/DiCE, el módulo M01 de baselines AutoML y los módulos M02-M07 tras la unificación final de dependencias.
env_lazypredict	Entorno especializado original para el módulo M02 (LazyPredict). Las librerías se consolidaron posteriormente en tfm_abandono. La definición se mantiene en entornos_automl.md como referencia histórica reproducible.
env_pycaret	Entorno especializado original para el módulo M03 (PyCaret). Igualmente consolidado en tfm_abandono. PyCaret instalado con la opción [full] para incluir todos los algoritmos.
env_h2o	Entorno especializado original para el módulo M04 (H2O AutoML). Requiere instalación previa de Java 8 o superior en el sistema (https://adoptium.net/).
env_autogluon	Entorno especializado original para el módulo M05 (AutoGluon). En sistemas Windows se requiere ubicar los modelos temporales fuera del directorio de OneDrive para evitar conflictos de sincronización.

Tabla F.1. Entornos conda utilizados durante el desarrollo del proyecto. La unificación posterior de dependencias permitió ejecutar la totalidad del flujo desde el entorno principal tfm_abandono. Los entornos especializados se conservan como referencia reproducible. Fuente: fichero entornos_automl.md del repositorio.

F.4. Ficheros requirements disponibles

El repositorio del proyecto contiene seis ficheros requirements diferenciados que permiten instalar el subconjunto mínimo de dependencias para cada fase, optimizando el tiempo y el espacio en disco cuando solo se desea reproducir una parte específica del trabajo.

Fichero	Alcance y uso
requirements_proyecto.txt	Especificación general del proyecto con cotas mínimas de versión ($\geq$). Recomendado para instalaciones limpias en entornos nuevos donde se desean las versiones más recientes compatibles.
requirementsautoml.txt	Especificación pinned con versiones exactas ($=$) del entorno utilizado en la generación del modelo final. Garantiza la reproducibilidad bit a bit. Es la versión técnica de referencia para auditoría.

Fichero	Alcance y uso
requirements_fase1.txt	Subconjunto mínimo para ejecutar exclusivamente la Fase 1 (transformación, limpieza, integración relacional).
requirements_fase2.txt	Subconjunto para Fase 2 (EDA inicial). Incluye Altair y dependencias de visualización interactiva.
requirements_fase3.txt	Subconjunto para Fase 3 (feature engineering). Incluye herramientas de análisis de distribuciones y outliers.
requirements-notebook.txt	Alias funcional de requirements_fase3.txt para entornos Jupyter aislados.

Tabla F.2. *Ficheros requirements del proyecto y su alcance. Para reproducir el modelo final del TFM con versiones idénticas a las del entrenamiento original, debe utilizarse requirementsautoml.txt. Para nuevas instalaciones flexibles, requirements_proyecto.txt resuelve compatibilidades con versiones más recientes. Fuente: ficheros del repositorio público.*

F.5. Estructura del repositorio público

El código completo del proyecto se aloja en el repositorio público https://github.com/mortemj/AU_UJI_v2 bajo la rama master. La organización del repositorio sigue la convención Cookiecutter Data Science, ampliamente adoptada en proyectos académicos de ciencia de datos por su modularidad y trazabilidad.

```
AU_UJI_v2/
├── app/                # Aplicación Streamlit institucional
│   ├── main.py         # Punto de entrada de la app
│   ├── config_app.py   # Configuración de UI, mapas y constantes
│   └── pages/          # Páginas p00-p06
├── data/               # Datasets organizados por nivel de procesamiento
│   ├── 00_raw/         # Datos originales (no incluidos en el repo)
│   ├── 01_interim/     # Datos intermedios
│   ├── 02_processed/   # Datos procesados
│   ├── 03_features/    # Dataset modelable dataset_final_tfm.parquet
│   ├── 05_modelado/    # Modelos entrenados y X_test_prep.parquet
│   ├── 06_evaluacion/  # meta_test_app.parquet, métricas
│   └── automl/         # Datasets y resultados de la fase AutoML
├── docs/               # Documentación HTML (GitHub Pages)
│   └── html/           # Informes navegables por fase
├── notebooks/         # Jupyter Notebooks organizados por fase
│   ├── fase1/         # Transformación e integración
│   └── fase2/         # EDA inicial
```

```

├── fase3/      # Feature engineering
├── fase4/      # EDA final dirigido al abandono
├── fase_automl/ # Validación AutoML (módulos M00-M07)
├── fase5/      # Modelado clásico (69 configuraciones)
├── fase6/      # Evaluación e interpretabilidad
├── fase7/      # Aplicación y despliegue
├── src/        # Módulos Python reutilizables
├── config/     # Configuración centralizada (RUTAS, mapas)
├── html/       # Generación de informes HTML
├── utils/      # Funciones auxiliares
├── results/    # Salidas finales del proyecto
├── tests/      # Tests automatizados
├── tribunal/   # Material para defensa
├── project/    # Documentación de proyecto
├── README.md
├── .gitignore
├── requirements_proyecto.txt
├── requirements_fase1.txt
├── requirements_fase2.txt
├── requirements_fase3.txt
├── comprimir_modelo_app.py
└── comprimir_modelo_app.bat

```

La carpeta `data/` se incluye con su estructura de subdirectorios pero sin los datos originales (`00_raw/`), que están sujetos a confidencialidad institucional bajo el acuerdo con la Universitat Jaume I. Los ficheros derivados (`01_interim`, `02_processed` y `03_features`) tampoco se versionan en el repositorio público, conforme a las exclusiones definidas en el fichero `.gitignore`. Las personas evaluadoras del proyecto tienen acceso al modelo serializado `LightGBM__none.pkl` y a los ficheros de evaluación necesarios para auditar el resultado.

Adicionalmente, el repositorio publica los informes navegables generados durante el proyecto en la URL https://mortemj.github.io/AU_UJI/, mediante GitHub Pages. La aplicación institucional se encuentra desplegada en <https://tfm-abandono-dinamico.streamlit.app/>, accesible públicamente sin requisitos de autenticación.

F.6. Instrucciones de reproducción

Para reproducir el entorno de ejecución del proyecto desde cero, deben seguirse los siguientes pasos en un sistema con Anaconda y Git instalados.

En primer lugar, se clona el repositorio público y se accede al directorio raíz del proyecto:

```
git clone https://github.com/mortemj/AU_UJI_v2.git
cd AU_UJI_v2
```

A continuación, se crea el entorno principal del proyecto con Python 3.11 y se instalan las dependencias pinned:

```
conda create -n tfm_abandono python=3.11 -y
conda activate tfm_abandono
pip install -r requirements_proyecto.txt
```

Si se desea reproducir la fase AutoML con los entornos especializados originales, debe seguirse adicionalmente el procedimiento documentado en el fichero entornos_automl.md, que incluye los comandos específicos de cada framework y, en el caso de H2O, la instalación previa de Java 8 o superior.

Para verificar la correcta instalación, se puede ejecutar el siguiente comando, que carga el modelo final y comprueba su funcionalidad básica:

```
python -c "import joblib; m = joblib.load('data/05_modelado/models/LightGBM__none.pkl'); print(m)"
```

Por último, la aplicación web puede lanzarse localmente mediante:

```
streamlit run app/main.py
```

La aplicación se abrirá en un navegador apuntando a la dirección <http://localhost:8501> y replicará exactamente el comportamiento de la versión desplegada en producción.

Anexo G. Capturas adicionales de la aplicación institucional

El presente anexo recoge las capturas exhaustivas de las siete páginas de la aplicación institucional desplegada en <https://tfm-abandono-dinamico.streamlit.app/>, complementando la descripción funcional resumida en la sección 4.9 del Capítulo 4. Para cada página se incluyen tantas capturas como vistas relevantes presenta, ordenadas según el flujo natural de navegación.

La aplicación se ha desarrollado con Streamlit 1.55.0 sobre el modelo final del proyecto (LightGBM con estrategia 'none') y la pipeline de preprocesamiento descrita en el Anexo B. La distribución por páginas obedece al perfil de la persona usuaria objetivo: las páginas p00 y p06 son de uso general, p01 y p02 están orientadas a personal directivo, p03 al servicio de orientación preuniversitaria, p04 al servicio de orientación universitaria y p05 a auditoría y supervisión metodológica del sistema.

Las capturas se realizaron en formato A3 a alta resolución para preservar la legibilidad del contenido. En el presente anexo se incluyen escaladas al ancho de página A4 manteniendo la proporción original.

G.1. p00 — Página de inicio

La página inicial recibe a la persona usuaria con el título institucional, una presentación breve del propósito de la herramienta, las métricas globales del modelo y la navegación hacia el resto de páginas. Sirve como punto de entrada y carta de presentación pública del sistema.




Figura G.1.1. Página de inicio (p00). Vista completa con cabecera institucional, descripción del proyecto, KPIs del modelo (AUC-ROC, F1-Score, alumnos únicos, tasa de abandono, mejor modelo) y panel de secciones disponibles.

G.2. p01 — Vista institucional

Esta página presenta la situación global del abandono universitario en la UJI desde una perspectiva agregada. Incluye indicadores clave (KPI), evolución temporal de la tasa de abandono y comparativas por rama de conocimiento. Está orientada al equipo directivo y a los servicios de calidad institucional.




Figura G.2.1. p01 — Visión institucional. Vista superior con cabecera, filtros y KPIs principales (alumnos, tasa abandono real, riesgo alto, titulaciones activas), evolución temporal del abandono y abandono por rama de conocimiento.




Figura G.2.2. p01 — Visión institucional. Vista inferior con riesgo por rama (apilado), distribución del riesgo (donut), tabla de abandono por titulación, nota metodológica y resumen de la selección actual.

G.3. p02 — Vista por titulación

Permite la exploración detallada del comportamiento del abandono en una titulación concreta. La persona usuaria selecciona una titulación y la página despliega su tasa histórica, perfiles diferenciales del alumnado que abandona, comparativa con el promedio de la rama y métricas de evaluación específicas para esa titulación.




Figura G.3.1. p02 — Por titulación. Vista superior con selector de titulaciones, comparativa de KPIs (alumnos, abandono real, riesgo predicho, F1 del modelo), tabla detallada de las titulaciones seleccionadas, distribución por riesgo y probabilidad de abandono (violines).




Figura G.3.2. p02 — Por titulación. Vista inferior con evolución temporal por titulación, factores más influyentes (Cohen's d) y comparativa con el resto de titulaciones de la UJI.

G.4. p03 — Pronóstico de prospectos

Página orientada al servicio de orientación preuniversitaria. Permite estimar el riesgo de abandono de una persona aspirante a partir de los datos disponibles antes de la matrícula (nota de acceso, vía de acceso, situación socioeconómica esperada). Genera un pronóstico orientativo acompañado de recomendaciones heurísticas. Conviene recordar que el modelo se entrenó sobre alumnado matriculado, por lo que el pronóstico para personas no matriculadas debe interpretarse como estimación comparativa, no como predicción absoluta.

Figura G.4.1. p03 — Futuro estudiante. Vista superior con formulario para comparar varias titulaciones, perfil del prospecto (académico, situación laboral, edad, vía de acceso, sexo) y datos avanzados (orden de preferencia, universidad, nota de selectividad).

Detalle por titulación

Despliega para ver el perfil de abandono histórico y los factores de riesgo.


Cómo calcular los factores

Rápido ☐ **Preciso**

Si cambias el método o cualquier dato del perfil, deberás pulsar de nuevo Calcular mis predicciones.


Turismo — Histórico: 39,8% — Tu riesgo: 90,0%

Tu perfil vs perfiles de referencia



Comparativa sobre alumnos de Grado en Turismo. Cuanto más cerca del borde exterior, mejor en esa variable.


¿Qué factores influyen en tu riesgo?



Verde = ese factor reduce tu riesgo. Rojo = lo aumenta. Los valores son impactos marginales por factor, no componentes que sumen al riesgo final.

Periodismo — Histórico: 15,2% — Tu riesgo: 70,6%

Tu perfil vs perfiles de referencia



Comparativa sobre alumnos de Grado en Periodismo. Cuanto más cerca del borde exterior, mejor en esa variable.

¿Qué factores influyen en tu riesgo?



Verde = ese factor reduce tu riesgo. Rojo = lo aumenta. Los valores son impactos marginales por factor, no componentes que sumen al riesgo final.

Traducción e Interpretación — Histórico: 10,3% — Tu riesgo: 61,6%

Tu perfil vs perfiles de referencia



Comparativa sobre alumnos de Grado en Traducción e Interpretación. Cuanto más cerca del borde exterior, mejor en esa variable.


¿Qué factores influyen en tu riesgo?



Verde = ese factor reduce tu riesgo. Rojo = lo aumenta. Los valores son impactos marginales por factor, no componentes que sumen al riesgo final.

Medicina — Histórico: 7,9% — Tu riesgo: 8,2%

Tu perfil vs perfiles de referencia



Comparativa sobre alumnos de Grado en Medicina. Cuanto más cerca del borde exterior, mejor en esa variable.

¿Qué factores influyen en tu riesgo?




Verde = ese factor reduce tu riesgo. Rojo = lo aumenta. Los valores son impactos marginales por factor, no componentes que sumen al riesgo final.

¿Dónde estás respecto a otros alumnos?

Agregado sobre las 4 titulaciones seleccionadas.

PERCENTIL EN GRUPO
87
de 100 titulaciones elegidas...

Nota punto = 1 alumno - color por nivel de riesgo



728 alumnos · Titulaciones elegidas (4)

Tu riesgo es 57,4%. Estás mejor que el 33% de alumnos de titulaciones elegidas (4).

MEDIA DEL GRUPO
17,4%
media: 2,3%

Distribución por niveles de riesgo



TU VS MEDIA
+40,2 pp
por que la media

Nota metodológica: las recomendaciones se generan a partir de reglas heurísticas basadas en los factores del perfil (nota de acceso, situación laboral, beca, etc.), no del modelo de machine learning. Sirven como orientación, no como diagnóstico.

Recomendaciones personalizadas

Indicador sobre becas

Los años con beca son uno de los factores protectores más importantes. Consulta las convocatorias del Ministerio y las becas propias de la U3 antes de matricularte.

Este predictor es una estimación estadística basada en datos históricos. No determina ni garantiza ninguna decisión académica.

Figura G.4.2. p03 — Futuro estudiante. Vista inferior con comparativa de titulaciones, abandono histórico, velocímetros de riesgo personal por titulación, perfil radar comparado con perfiles de referencia, factores que influyen en el riesgo y recomendaciones personalizadas.

G.5. p04 — Pronóstico de alumnado matriculado

Página principal del sistema desde la perspectiva operativa. Permite a personal de orientación introducir los datos completos de una persona estudiante ya matriculada y obtener un pronóstico individualizado del riesgo de abandono, acompañado de una explicación SHAP local que identifica los factores específicos que han contribuido a la predicción.




Figura G.5.1. p04 — Alumno en curso. Vista superior con selector de titulación, formulario completo organizado en tres cards temáticas (Académico, Personal, Socioeconómico) y datos avanzados desplegables.




Figura G.5.2. p04 — Alumno en curso. Vista inferior con resultado del pronóstico individual: KPIs (riesgo personal, media contexto, ranking, factor clave), velocímetro de riesgo, distribución de notas de la titulación y recomendaciones personalizadas.

G.6. p05 — Equidad y diversidad


Esta página presenta un análisis exhaustivo de equidad algorítmica del modelo, evaluando si el sistema produce decisiones equilibradas entre subgrupos definidos por atributos sensibles. Incluye métricas formales de fairness (Disparate Impact, Demographic Parity, Equal Opportunity), análisis desagregado por ocho atributos protegidos (sexo, rama, vía de acceso, situación de beca, orden de preferencia, provincia, país de origen y residencia), análisis de errores del modelo y un simulador de política institucional. Está orientada a auditoría y supervisión metodológica del sistema.

Equidad y diversidad

¿Predice el modelo de forma justa entre distintos grupos de estudiantes?

¿Qué desplace más el riesgo de abandono?


Tasa real de abandono por categoría. La línea punteada es la media UJI (29,5%). Cada flecha muestra cuánto desvía ese grupo el riesgo respecto a la media.



Variables con diferencia > 3 pp entre grupos se excluyen del gráfico (se agrupan narrativa visual). N total analizado: 6,396 alumnos.

Retrato del abandono

Tasas de abandono reales en el dataset, no predicciones del modelo. La barra muestra dónde está cada grupo en la escala 0-100%.



¿Qué es la equidad en un modelo de machine learning?

El problema

Un modelo puede tener buena precisión global pero equivocarse sistemáticamente más con ciertos grupos. Por ejemplo, detectar peor el abandono en mujeres que en hombres, o en alumnos sin beca que con beca.

Qué medimos

Comparamos si el modelo tiene el mismo rendimiento (F1, recall, precisión) en todos los grupos. También medimos el Disparate Impact: el ratio entre las tasas de predicción positiva de cada grupo.


La regla del 80%

Estadístico internacional de fairness: si el grupo menos favorecido recibe predicciones positivas a menos del 80% de la tasa del grupo más favorecido, el modelo muestra señales de discriminación estadística.

Variables analizadas en este TFM: Sexo (variable protegida, ODS 5), Rama de conocimiento (5 áreas), Vía de acceso (origen educativo), Situación de beca (proxy socioeconómico, variable más importante del modelo). El análisis de equidad se usó en conjunto con el TFM (CE301/CE31) y uno de los aspectos más valorados por los tribunales de Justicia.

Equidad por sexo

Variable variable protegida (ODS 5 – Igualdad de género).




El modelo muestra un rendimiento homogéneo entre grupos de sexo (diferencia F1: 2.1 pp).

Ver tabla detallada

Equidad por rama de conocimiento

No es una variable protegida en sentido estricto, pero permite detectar si el modelo rinde mejor en unas disciplinas que en otras.



Hay una diferencia moderada de rendimiento entre grupos de rama de conocimiento (diferencia F1: 6.6 pp). El modelo funciona mejor en Ciencias Experimentales que en Ingeniería y Arquitectura.

Ver tabla detallada

Equidad por vía de acceso

Refleja el origen educativo del alumno (selectividad, PE, mayores de 25...). Diferencias aquí señalan posibles inequidades de oportunidad educativa.

Gráfico con grupos de N > 30. Excluidos por tamaño insuficiente: Cambio de base, Pruebas acceso mayores 40 años, Pruebas acceso mayores 45 años.




Hay una diferencia notable de rendimiento entre grupos de vía de acceso (diferencia F1: 40.0 pp). El grupo Extranjeros en CEE está significativamente menos protegido. Requiere atención.

Ver tabla detallada

Equidad por situación de beca

Tramos por intensidad del apoyo becar: Sin beca / 1-2 años (partida) / 3+ años (sustentada). Más informativo que binario convén, porque permite detectar si el modelo trata distintos a becaros cuantitativos frente a becaros cualitativos. a, antes, beca es la variable más importante del modelo.




Hay una diferencia notable de rendimiento entre grupos de situación de beca (diferencia F1: 49.2 pp). El grupo Beca sostenida (3+ años) está significativamente menos protegido. Requiere atención.

Nota: los becaros tienen una tasa de abandono más baja que los no becaros, por eso el modelo les da menos como positivos. No indica sesgo discriminatorio.

Ver tabla detallada

Equidad por orden de preferencia

Posición en que el alumno eligió esta titulación en la preinscripción (1ª opción, 2ª, etc.). Agrupado en tramos para finalidad estadística. Variable no protegida, pero revela sesgo del sistema de asignación de plazas: los alumnos que se entren en su 1ª opción tienden a abandonar más.



Equidad por provincia

Origen geográfico del alumno dentro de España. Agrupado en Castilla vs resto de provincias. Permite detectar si el arraigo territorial actúa como factor protector frente al abandono.





Figura G.6.1. p05 — Equidad y diversidad. Vista superior: análisis de desplazamiento del riesgo por categoría, retrato del abandono y métricas de equidad por sexo, rama de conocimiento, vía de acceso, situación de beca, orden de preferencia, provincia, país de origen y residencia.



Valoración matizada

El modelo se comporta de forma mayoritariamente equitativa, pero muestra señales de posible discriminación estadística en sexo, rama de conocimiento, vía de acceso, situación de beca, provincia, país de origen (Disparate Impact < 0.8). Este hallazgo no invalida el modelo pero exige supervisión explícita en la toma de decisiones institucionales que lo empleen.

Datos clave del test (N = 4,396 alumnos):

El mínimo: 0.00 (en vía de acceso) diferencia F1 mínima: 49.1 pp (en situación de beca) F1 global: 83.3%, AUC: 95.4%

Cualquier uso institucional debe ir acompañado de supervisión humana y revisión periódica.

Limitaciones del análisis

- Datos históricos: el modelo refleja los patrones de 2010-2020. Los cambios estructurales recientes (pandemia, nuevos grados) pueden no estar representados.
- Censura temporal cohorte 2020: los 184 alumnos que iniciaron en 2020 tienen una ventana de observación inferior a 4 años (cierra del dataset en 2023), por lo que su tasa de abandono observada (94%) infravalora el valor real. La solución metodológica correcta (análisis de supervivencia Kaplan-Meier) se presenta de forma exploratoria al final de esta página y queda como línea de ampliación del TFM.
- Equidad o causalidad: que el modelo sea equitativo no significa que el sistema académico lo sea. El modelo aprende de desigualdades preexistentes en los datos.
- Grupos pequeños: las estimaciones para grupos con N < 30 tienen mayor varianza estadística y se excluyen de los gráficos comparativos, pero se listan en las tablas con un aviso.
- Sin constraints de fairness en entrenamiento: el modelo no incorpora restricciones de equidad durante la optimización. Métodos como reweighting, exponential gradient o threshold optimization podrían mejorar la paridad entre grupos a costa de rendimiento global.
- Uso ético obligatorio: esta herramienta es de apoyo a la decisión, nunca sustituto del juicio humano.

Figura G.6.2. p05 — Equidad y diversidad. Vista inferior: brecha de predicción entre grupos (Disparate Impact), análisis de errores del modelo por sexo, simulador de política institucional y conclusión sobre la justicia del modelo con valoración matizada y limitaciones del análisis.

G.7. p06 — Guía semántica y transparencia

Página dedicada a la transparencia metodológica y la guía semántica del sistema. Recoge la paleta de colores y su significado, los niveles de riesgo, los códigos visuales por rama de conocimiento, las métricas reales del modelo cargadas dinámicamente, la comparativa con el baseline AutoML, las limitaciones documentadas, el catálogo completo de titulaciones, el marco ético y legal aplicable (RGPD, AI Act, UNESCO), un glosario de términos técnicos y la iconografía utilizada en toda la aplicación.





Predicción de Abandono — UJI

TFM · Universitat Oberta de Catalunya · Maria José Morfe

Inicio

Visión institucional

Por titulación

Futuro estudiante

Alumno en curso

Equidad y diversidad

Guía semántica

Guía semántica y transparencia

Qué significa cada color, símbolo y métrica de esta aplicación · Marco ético y legal · Glosario de términos

Índice de esta página

- Paleta de colores — riesgo, ramas (togas), sexo, institucional
- Transparencia del modelo — métricas, comparativa baseline, limitaciones
- Catálogo de titulaciones — todas las titulaciones por rama de conocimiento
- Marco ético y legal — RGPD, AI Act, ODS 5, UNESCO
- Glosario — términos técnicos e iconos
- Decisiones metodológicas — pendiente de completar con las fases

Paleta de colores y significado semántico

Cada color en esta app tiene un significado concreto y documentado.

Niveles de riesgo de abandono

Los umbrales son: bajo < 30% · medio 30-60% · alto ≥ 60%. Se eligieron para equilibrar sensibilidad y especificidad con una tasa de abandono del 29,2%.

Riesgo bajo

Probabilidad < 30%

#18b981

Riesgo medio

30%-60%

#f79646

Riesgo alto

Probabilidad > 60%

#d62728

Ramas de conocimiento — paleta inspirada en togas doctorales

Los colores de cada rama están inspirados en los colores tradicionales de las togas doctorales españolas, adaptados para legibilidad en pantalla. Ningún color de rama coincide con los de riesgo para evitar confusión semántica.

SO · Ciencias Sociales y Jurídicas

Inspiración: toga amarillito-rojo → ámbar dorado

#d97786

TE · Ingeniería y Arquitectura

Inspiración: toga marrón → naranja tostado

#c2433c

SA · Ciencias de la Salud

Inspiración: toga amarillo limón → azul cian

#89b3c2

HU · Artes y Humanidades

Inspiración: toga morado → violeta medio

#7c3aed

EX · Ciencias Experimentales

Inspiración: toga azul marino → azul profundo

#194e88

Sexo — convención ODS 5

Colores independientes de las ramas para evitar acoplamiento involuntario. Alineados con la convención visual internacional y el ODS 5 (igualdad de género).

Mujer

Variable protegida ODS 5

#d62728

Hombre

Convención visual estándar

#194e88

Total

Línea agregada neutra

#444444

Colores institucionales

Azul institucional UJI

Cabeceiras, botones principales, énfasis

#1a488c

Azul claro accent

Hover, accents secundarios

#4481f8

Transparencia del modelo

Métricas reales cargadas dinámicamente desde métricas_modelo.json.

AUC-ROC

0,956

F1-Score test

0,833

Alumnos test

6.725

Tasa abandono

29,2%

Comparativa con el baseline AUTOML

MODELO FINAL

LightGBM

AUC 0,956 · F1 0,833

BASELINE AUTOML

TabPFN v2

AUC 0,964 · F1 0,850

¿Qué significan AUC y F1?

AUC-ROC (Área bajo la curva ROC) Mide la capacidad del modelo para distinguir entre alumnos que van a abandonar y los que no. Un AUC de 0,956 significa que, dado un alumno que abandona y otro que no, el modelo asigna mayor probabilidad de abandono al primero en el 95,6% de los casos. Rango: 0,5 (azar) → 1,0 (perfecto).

F1-Score Media armónica entre precisión (¿de los que predigo que abandonan, cuántos realmente abandonan?) y recall (¿de los que realmente abandonan, cuántos detecto?). Con una tasa de abandono del 29,2%, el F1 es más informativo que la exactitud (accuracy). Un F1 de 0,833 indica un equilibrio sólido entre los dos errores posibles.

Limitaciones del modelo

1. Datos hasta 2020. El modelo refleja patrones de 2010-2020. Cambios estructurales posteriores (pandemia, nuevos grados) pueden no estar representados.

2. Censura temporal cohorte 2020. Los alumnos que iniciaron en 2020 tienen menos de 4 años de observación — su tasa de abandono observada subestima el valor real. La solución metodológica correcta es el análisis de supervivencia (Kaplan-Meier), propuesto como línea de ampliación del TFM.

3. Resultados orientativos. Las predicciones son probabilidades estadísticas, no deterministas. No deben usarse como único criterio de decisión sobre ningún estudiante.

Jueves, 7 de mayo de 2026

71

Figura G.7.1. p06 — Guía semántica y transparencia. Vista superior: paleta de colores y significado semántico, niveles de riesgo, ramas de conocimiento, sexo y colores institucionales. Transparencia del modelo con métricas reales ($AUC=0,956$, $F1=0,833$, $n=6.725$) y comparativa con el baseline AutoML.

4. Grupos pequeños (N < 30). Las estimaciones para grupos con pocos alumnos tienen mayor varianza estadística y deben interpretarse con cautela.

Catálogo de titulaciones por rama de conocimiento

Titulaciones disponibles en la app · Datos UJI 2010-2020 · Nombres según SIA 2025

Ciencias Sociales y Jurídicas

Administración y Dirección de Empresas

Doble ADE + Derecho

Ciencias Actividad Física y Deporte

Criminología y Seguridad

Comunicación Audiovisual

Derecho

Economía

Finanzas y Contabilidad

Gestión y Administración Pública

International Business Economics

Artes y Humanidades

Estudios Ingleses

Historia y Patrimonio

Humanidades

Traducción e Interpretación

Ingeniería y Arquitectura

Arquitectura Técnica

Diseño y Desarrollo de Videojuegos

Ing. Diseño Industrial y Desarrollo de Productos

Ing. Eléctrica

Ing. Informática

Ing. Mecánica

Ing. Química

Ing. Tecnologías Industriales

Inteligencia Robótica

Matemática Computacional

Ciencias Experimentales

Química

Bioquímica y Biología Molecular

Ciencias de la Salud

Enfermería

Medicina

Psicología

50 · 18 titulaciones

40 · 4 titulaciones

18 · 11 titulaciones

2 · 2 titulaciones

3 · 3 titulaciones

Fuente: [scisearch](#), [scisearch](#) · Clasificación oficial UJI/ANECA · Nombres actualizados según SIA 2025

Marco ético y legal

Esta aplicación opera bajo un marco normativo explícito.

RGPD – Reglamento UE 2016/679

Todos los datos son anonimizados. Ningún alumno es identificable. Los registros se identifican únicamente por un código interno ficticio.

AI Act – Reglamento UE 2024/1689

Los sistemas de IA aplicados a educación se clasifican como alto riesgo. Esta app requiere supervisión humana explícita y no puede sustituir el juicio académico.

ODS 5 – Igualdad de género

El sexo es una variable protegida analizada explícitamente en la página de equidad. El modelo muestra rendimiento homogéneo entre grupos de sexo (diferencia F1: 1,8 pp).

UNESCO – Ética de la IA (2021)

Recomendación sobre la ética de la inteligencia artificial. Principios de transparencia, responsabilidad y no discriminación aplicados al diseño de esta herramienta.

Uso responsable: esta herramienta es de apoyo a la decisión, nunca sustituto del juicio humano. Cualquier uso institucional debe ir acompañado de supervisión humana y revisión periódica.

Glosario de términos y símbolos

Definiciones precisas de los conceptos usados en la app.

Abandono (definición estricta) Baja definitiva del grado sin traslado ni cambio de titulación. No incluye traslados a otro grado ni interrupciones temporales.	AUC-ROC Área bajo la curva ROC. Mide la capacidad discriminativa del modelo independientemente del umbral de clasificación. Rango: 0,5 (azar) a 1,0 (perfecto).
Riesgo predicho (%) Probabilidad que el modelo asigna a un alumno de abandonar el grado, basada en su perfil. Es una estimación estadística, no una certeza.	F1-Score Media armónica entre precisión y recall. Más informativo que la exactitud cuando las clases están desbalanceadas (29,2% abandono vs 70,8% no abandono).
Abandono real (%) Porcentaje de alumnos que realmente abandonaron en el conjunto de test (datos históricos 2010-2020). No es una predicción.	Gradient Boosting Familia de algoritmos que construye un ensamble de árboles de decisión secuencialmente, donde cada árbol corrige los errores del anterior. En este TPM se entrenaron LightGBM, XGBoost y GradientBoosting (scikit-learn).
Disparate Impact (DI) Ratio entre la tasa de predicción positiva del grupo menos favorecido y la del más favorecido. Valor ideal: cercano a 1,0. Por debajo de 0,8 → señal de discriminación estadística (regla del 80%, EEOC).	SHAP Shapley Additive exPlanations. Método para explicar cuánto contribuye cada variable a la predicción de un alumno concreto. Basado en la teoría de juegos cooperativos (Shapley, 1953).
Falso positivo (FP) El modelo predice abandono pero el alumno completa el grado. Consecuencia: intervención innecesaria.	Kaplan-Meier Estimador de supervivencia que tiene en cuenta la censura temporal. Permite estimar el tiempo hasta el abandono incluso para cohortes que no han completado el período de observación. Propuesto como línea de ampliación del TPM.
Falso negativo (FN) El alumno abandona pero el modelo no lo detecta. Consecuencia: alumno en riesgo sin apoyo.	D_atrict Dataset de producción del TPM. 33.621 registros × 24 features. Construido con auditoría de leakage estricta → excluye variables que podrían filtrar información del futuro al modelo.

Iconos y su significado

Visión institucional – KPIs globales y tendencias	Por titulación – análisis detallado por grado	Futuro estudiante – pronóstico antes de matricularse
Alumno en curso – pronóstico con datos actuales	Equidad y diversidad – análisis de fairness	Riesgo bajo – probabilidad de abandono < 30%
Riesgo medio – probabilidad 30-60%	Riesgo alto – probabilidad ≥ 60%	Nota metodológica – información técnica del bloque
Adviso – interpretar con cautela	Recomendación personalizada	Titulación o dato académico

Sobre el modelo – decisiones metodológicas

Este bloque se completará al cerrar las fases 1-6 del proyecto.

Pendiente de completar

Aquí se documentarán: pipeline completo · selección del modelo final · por qué 24 features · decisión D_atrict · por qué no incluir titulación · Kaplan-Meier como extensión

Maria José Moritz Ruiz · Trabajo Final de Máster · UOC · Universitat Jaume I · 2026 · [mjmoritz@uoc.edu](#)

Figura G.7.2. p06 — Guía semántica y transparencia. Vista inferior: catálogo de titulaciones por rama de conocimiento, marco ético y legal (RGPD, AI Act, UNESCO), glosario de términos técnicos e iconografía con su significado.

Anexo H

Encuesta sobre motivos de abandono

Anexo H. Encuesta sobre los motivos de abandono

La tasa de abandono es uno de los indicadores utilizados para valorar la eficiencia de un título en relación con los resultados del aprendizaje previstos y el funcionamiento global de este. En este sentido se realizó el siguiente estudio, dirigido a la mejora de los títulos de la Universitat Jaume I (UJI), prestando atención al abandono, con el objetivo de identificar y analizar las causas por las que el estudiantado abandona sus estudios. Esta encuesta complementaria fue diseñada y administrada como parte del trabajo metodológico, aunque finalmente no se incorporó al modelo predictivo por la baja tasa de respuesta debido a problemas técnicos en el envío institucional.

IDENTIFICACIÓN Y TRAYECTORIA

1. Actualmente no estas matriculado/a en la UJI, en el *(dato embebido: titulación)* que iniciaste en el curso académico *(datos embebido: curso académico)* ¿Has abandonado dichos estudios antes de obtener el título?
 - ☐ (1) Sí
 - ☐ (2) No, pretendo continuar los estudios del grado, aunque ahora no esté matriculado/a
 - ☐ (3) No, sigo matriculado/a en el grado *(pasa a “Fin de cuestionario”)*
2. ¿Te fuiste a otra Universidad?
 - ☐ (1) Sí, al mismo grado *(pasa a la pregunta 11)*
 - ☐ (2) Sí, a otro grado
 - ☐ (3) No, solo he cambiado de grado y estoy aun la UJI
 - ☐ (4) No, he abandonado los estudios universitarios *(pasa a la pregunta 4)*
3. ¿El nuevo grado elegido se imparte en la UJI

- ☐ (1) Sí (pasa a la pregunta 11) ☐ (2) No

DIFICULTADES

4. Indica qué circunstancias pudieron influir en tu decisión de dejar los estudios (abandonar): (puedes marcar más de una opción si lo consideras oportuno)

- ☐ Motivos personales
- ☐ Motivos instruccionales y académicos
- ☐ Motivos económicos
- ☐ Motivos relacionados con la propia carrera

Si tienes alguna otra motivación que no esté incluida en las citadas anteriormente, ¿nos la puedes indicar? _____

5. De las circunstancias que nos has indicado, valora el grado de importancia que pudieron tener cada una de ellas en tu decisión de dejar los estudios (abandonar).

	Nada importante	Un poco importante	Importante	Muy importante	Totalmente importante
Motivos Personales (pasa pregunta 6)	☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Motivos instruccionales y académicos (pasa pregunta 7)	☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Motivos económicos (pasa pregunta 8)	☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Motivos relacionados con la propia carrera (pasa pregunta 9)	☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)

6. Indica qué motivo personal te ha llevado a tomar la decisión de dejar los estudios

- ☐ (1) COVID
- ☐ (2) Vivir Lejos
- ☐ (3) Enfermedad
- ☐ (4) Matrimonio
- ☐ (5) Embarazo
- ☐ (6) Hijos
- ☐ (7) Falta de tiempo disponible para el estudio
- ☐ (8) Discapacidad o necesidades especiales. Indicar quina _____

7. Indica qué motivo instruccional y académico te ha llevado a tomar la decisión de dejar los estudios

- ☐ (1) Horarios
- ☐ (2) Programa o Temarios
- ☐ (3) Complejo
- ☐ (4) Problemas con los profesores
- ☐ (5) Exceso de carga académica
- ☐ (6) Bajo nivel de la carrera
- ☐ (7) Dificultades con el nivel del grado elegido

8. Indica qué motivo económico te ha llevado a tomar la decisión de dejar los estudios

- ☐ (1) Por mantener a la familia
- ☐ (2) Recursos insuficientes para estudiar
- ☐ (3) Para ayudar al gasto familiar
- ☐ (4) Me quede sin beca
- ☐ (5) NO poder pagar la matrícula

9. Indica qué motivo relacionado con la propia carrera te ha llevado a tomar la decisión de dejar los estudios

- ☐ (1) Baja empleabilidad
- ☐ (2) NO me gusta la carrera
- ☐ (3) NO me gusta el plan de estudios

ABANDONO

10. ¿Cuál fue tu actividad principal después de dejar los estudios en la UJI? (puedes marcar más de una opción si lo consideras oportuno)

- ☐ Otros estudios
☐ Trabajar
☐ Preparar oposiciones ☐ No quiero comentarlo ☐ Otras.

Por favor, indica cuál: _____

11. Durante el último año en que estuviste matriculado en el grado elegido en la UJI, ¿en qué momento tomaste la decisión de abandonarla?

- ☐ (1) A las pocas semanas de empezar
☐ (2) Antes de finalizar el primer cuatrimestre
☐ (3) Al inicio del segundo cuatrimestre
☐ (4) Antes de finalizar el segundo cuatrimestre
☐ (5) Una vez finalizado el curso

12. Si tuvieras que señalar una única razón por la que dejaste el grado, ¿cuál sería?

- ☐ (1) No me gustaba, no era la que quería, no era mi primera elección
☐ (2) Era incompatible con el trabajo u otros estudios
☐ (3) Aunque me gustaba no me compensaba el tiempo o esfuerzo necesario,
☐ (4) Problemas económicos
☐ (5) Cambio de domicilio
☐ (6) Problemas de salud
☐ (7) Otros problemas personales o familiares
☐ (8) Dificultad en los estudios
☐ (9) Covid-19
☐ (10) Discapacidad o necesidades especiales ☐ (11) Otros.

Por favor, indica cuál: _____

TRABAJO

13. ¿Desempeñaste algún tipo de actividad laboral mientras cursabas el grado en la UJI?

- ☐ (1) Ninguna (pasa a la pregunta 16)
- ☐ (2) A tiempo completo de forma continua
- ☐ (3) A tiempo parcial de forma continua
- ☐ (4) Esporádicamente a tiempo completo o tiempo parcial (pasa a la pregunta 16)
- ☐ (5) En vacaciones y/o fines de semana (pasa a la pregunta 16)

14. Durante ese periodo ¿qué considerabas prioritario?

- ☐ (1) Estudios
- ☐ (2) Trabajo

15. ¿En qué medida el trabajo que realizabas era compatible con tus estudios?

☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Totalmente incompatible	Un poco incompatible	Bastante compatible	Muy compatible	Totalmente compatible

MOTIVACIÓN

16. ¿Tienes algún título universitario?

- ☐ (1) No
- ☐ (2) Diplomatura relacionada con el grado que abandonaste
- ☐ (3) Licenciatura relacionada con el grado que abandonaste
- ☐ (4) Otro grado relacionado con el grado que abandonaste
- ☐ (5) Un título (diplomatura, licenciatura o grado) no relacionado con el grado que abandonaste

17. Valora el grado de importancia que tenía para ti conseguir el título del grado que abandonaste.

☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Nada importante	Un poco importante	Importante	Muy importante	Totalmente importante

18. ¿Qué posición ocupaba la titulación que estabas cursando en tu solicitud de ingreso a la universidad?

- ☐ (1) Primera
- ☐ (2) Segunda
- ☐ (3) Tercera
- ☐ (4) Cuarta
- ☐ (5) Quinta o superior
- ☐ (6) No estaba entre mis opciones de ingreso

19. Si no hubiese existido nota de corte o restricción de plazas y hubieses podido elegir cualquier grado ¿habrías escogido el grado en el que te matriculaste?

- ☐ (1) Sí
- ☐ (2) No

20. ¿Te gustaba el contenido de las asignaturas del grado que empezaste?

☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Absolutamente nada	Un poco	Bastante	Mucho	Absolutamente todo

21. ¿Cómo te parece la relación entre la duración de los estudios que elegiste y el contenido y la dificultad de los mismos?

☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Muy cortos para el grado de dificultad	Cortos para el grado de dificultad	Razonable y ajustado al grado de dificultad	Largos para el grado de dificultad	Muy largos para el grado de dificultad

VALORACIÓN UJI

22. Antes de abandonar el grado en el que te matriculaste ¿llegaste a conocer la universidad (ir a clase, tutorías, profesores...)?

- ☐ (1) Sí
- ☐ (2) No (pasa a la pregunta 24)

23. De tu experiencia en el grado, ¿podrías indicarnos qué opinión tienes de la UJI?

☐ (1)	☐ (2)	☐ (3)	☐ (4)	☐ (5)
Muy mala	Mala	Regular	Buena	Muy buena

24. ¿Hay alguna actuación por parte de la UJI que podría haber cambiado tu decisión de abandonar el grado que cursabas? (puedes marcar más de una opción si lo consideras oportuno)

- ☐ No
- ☐ Mayor apoyo académico: profesores y universidad
- ☐ Mayor flexibilidad de horarios y asistencia
- ☐ Mayor oferta académica ☐ Becas y ayudas ☐ Otras.

Por favor, indica cuál o cuáles: _____

DATOS SOCIO-DEMOGRÁFICOS

25. Estado Civil en el momento en el que realizabas los estudios

- ☐ (1) Soltero/a ☐ (2) Casado/a
- ☐ (3) Unión de Hecho
- ☐ (4) Divorciado/a
- ☐ (5) Viudo/a

26. Tipo de residencia, en el momento del abandono de los estudios

- ☐ (1) Vivía con mis padres
- ☐ (2) Residencia universitaria o piso compartido
- ☐ (3) Vivía solo/a, con mi pareja, o con mi propia familia
- ☐ (4) Otra modalidad

27. Lugar de residencia durante el curso:

- ☐ (1) Castellón capital
- ☐ (2) Provincia de Castellón
- ☐ (3) Valencia capital

- ☐ (4) Provincia de Valencia
- ☐ (5) Otra provincia española

28. Indica cuál fue la principal fuente de financiación de tus estudios universitarios.

- ☐ (1) Recursos propios
- ☐ (2) Tu familia
- ☐ (3) Becas (solo esta opción pasa a la pregunta 29 y 30) ☐ (4) Otros

29. ¿Has solicitado alguna beca de estudios durante tus estudios en la Universidad?:

- ☐ (1) Sí
- ☐ (2) No

30. Disfrutabas de beca en el momento en que abandonaste los estudios

- ☐ (1) Sí
- ☐ (2) No

31. En la actualidad, ¿desempeñas algún tipo de actividad laboral?:

- ☐ (1) Ninguna
- ☐ (2) A tiempo completo de forma continua
- ☐ (3) A tiempo parcial de forma continua
- ☐ (4) Esporádicamente a tiempo completo o tiempo parcial
- ☐ (5) En vacaciones y/o fines de semana

Notas metodológicas

La encuesta fue revisada y validada por la Comisión Deontológica de la UJI y supervisada por la Oficina de Promoción y Evaluación de la Calidad, dependiente del Vicerrectorado de Planificación Económica y Estratégica. Los datos se trataron conforme al RGPD (Reglamento UE 2016/679) y al Reglamento de protección de datos personales de la UJI (artículo 33). La duración estimada para su realización era de entre 5 y 10 minutos. Los datos resultantes se almacenaron de forma anonimizada. La tasa de respuesta efectiva fue muy baja debido a incidencias en el envío institucional, por lo que estos datos no se incorporaron al modelo predictivo de este TFM.

