

4.6.X · El caso de Júlia: leer una predicción individual

 Júlia
Edad de entrada 19 años
Vía de acceso PAU (Bachillerato)
Nota de acceso 11,80 / 14
Rama Ciencias de la Salud
Orden de preferencia 1.ª opción
Beca Sí
Trabajo No trabaja
1er año 54 ECTS · 7,8
Riesgo del modelo 12 % · Bajo

En septiembre de 2018, **Júlia** llegó al campus de Riu Sec con la maleta llena de ilusión y una nota de acceso de 11,80. Había elegido el grado en primera opción, después de casi un año dudando entre dos titulaciones de Ciencias de la Salud. Vivía con sus padres en Castelló, le habían concedido beca y no necesitaba compaginar los estudios con un empleo.

Su primer curso transcurrió con normalidad: aprobó 54 de los 60 ECTS matriculados con una nota media de 7,8. Cuando el modelo de predicción procesa su expediente al final del primer año, devuelve una probabilidad de abandono del 12 %, situándola dentro del grupo de riesgo bajo.

La pregunta interesante no es *cuánto* es ese 12 %, sino *por qué*. Cuando aplicamos el análisis SHAP local sobre el caso de Júlia, identificamos las cuatro variables que más empujan la predicción hacia la clase «no abandona»: los 54 créditos superados en primer curso, la nota media de 7,8, la concesión de la beca y el hecho de que esté estudiando su primera opción de preinscripción.

En el caso de Júlia, el modelo no «aprende» a no señalarla como abandono porque sea mujer ni porque viva en Castelló: aprende a no señalarla porque ha aprobado, ha rendido y ha elegido la titulación que quería estudiar.

Esta lectura encaja con la evidencia agregada presentada en sección 4.6.1 (SHAP global): los predictores de mayor peso del modelo son `cred_superados_anio_1er`, `nota_1er_anio` y `n_anios_beca`. El expediente de Júlia activa los tres factores en sentido protector, lo que explica que su probabilidad de abandono se sitúe muy por debajo de la media de su rama (29,1 %) y de la media global del dataset (29,25 %).

El interés institucional de este tipo de lectura individual es directo: permite al servicio de orientación no sólo saber qué estudiantes están en riesgo, sino entender por qué el modelo los considera así, y diseñar intervenciones específicas en lugar de protocolos genéricos.

4.7.X · El caso de Arnau: del diagnóstico a la simulación

 Arnau
Edad de entrada
22 años
Vía de acceso
CFGS (FP Superior)
Nota de acceso
7,80 / 14
Rama
Ingeniería y Arquitectura
Orden de preferencia
3.ª opción
Beca
No
Trabajo
Tiempo completo
1er año
24 ECTS · 5,4
Riesgo del modelo
78 % · Alto

Arnau empezó el grado tres años más tarde de lo habitual. Después de un ciclo formativo de grado superior, llegó a la universidad sin beca, con un trabajo a tiempo completo en una empresa del polígono de Cabanes y matriculándose en su tercera opción de preinscripción. Su nota media al final del primer curso fue de 5,4 y aprobó solamente 24 de los 60 ECTS matriculados.

El modelo le asigna una probabilidad de abandono del 78 %, claramente dentro del grupo de riesgo alto. El análisis SHAP local atribuye ese valor a la combinación de bajo rendimiento académico, carga laboral sostenida y ausencia de apoyo institucional vía beca. Hasta aquí, una lectura técnica convencional.

La pregunta crítica para una herramienta de uso institucional no es sólo «¿qué predice el modelo sobre Arnau?», sino también «¿qué tendría que cambiar en su situación para que el modelo dejara de considerarlo en riesgo?». Este es exactamente el espacio del análisis contrafactual con DiCE (sección4.6.3).

Aplicando DiCE sobre el caso de Arnau, el sistema identifica el contrafactual mínimo más próximo: si Arnau hubiera obtenido beca durante su primer curso y reducido su jornada laboral a tiempo parcial, manteniendo el resto de variables idénticas, su probabilidad de abandono caería del 78 % al 41 %. Este resultado no es una recomendación clínica ni una garantía: es una lectura del modelo, útil para guiar la conversación de orientación con datos concretos.

Donde el SHAP responde «por qué Arnau está en riesgo», el análisis DiCE responde «qué tendría que cambiar para que ya no lo estuviera». Las dos preguntas son complementarias y, juntas, transforman el modelo en una herramienta operativa para el servicio de orientación.

El caso de Arnau también ilustra la sección de equidad algorítmica (sección4.7). El modelo no «castiga» a Arnau por ser hombre, ni por haber accedido vía CFGS, ni por estudiar una rama de Ingeniería. Las métricas de fairness reportadas en este capítulo (Demographic Parity Difference, Equal Opportunity Difference y Disparate Impact Ratio sobre las seis variables sensibles) confirman que el modelo se comporta de manera razonablemente homogénea entre subgrupos. Lo que diferencia a Arnau no es su perfil demográfico, sino la combinación de variables académicas y socioeconómicas que la literatura previa identifica como factores de exposición al abandono temprano.

Los dos casos —Júlia y Arnau— se han construido como prototipos pedagógicos, no como personas concretas. Sus perfiles se inspiran en patrones reales del dataset modelable de 33.621 expedientes, pero ningún registro individual identificable se ha utilizado en su elaboración, conforme al RGPD y al protocolo de protección de datos del proyecto.