

Pronóstico del éxito y del abandono en los títulos de grado de la Universitat Jaume I

Uoc

María José Morte Ruiz

Área 5 - Data Science in Social

Universitat Oberta
de Catalunya

Tutor/a de TF
Raúl Parada Medina
Profesor/a responsable de

Susana Acedo Nadal

Fecha Entrega
Julio 2026

Copyright

© (el autor/a)

Reservados todos los derechos. Está prohibida la reproducción total o parcial de esta obra por cualquier medio o procedimiento, comprendidos la impresión, la reprografía, el microfilme, el tratamiento informático o cualquier otro sistema, así como la distribución de ejemplares mediante alquiler y préstamo, sin la autorización escrita del autor o de los límites que autorice la Ley de Propiedad Intelectual.

Ficha del Trabajo Final

Título del trabajo:	<i>PRONÓSTICO DEL ÉXITO Y DEL ABANDONO EN LOS TÍTULOS DE GRADO DE LA UNIVERSITAT JAUME I</i>
Nombre del autor/a:	<i>María José Morte Ruiz</i>
Nombre del Tutor/a de TF:	Raúl Parada Medina
Nombre del/de la PRA:	Susana Acedo Nadal
Fecha de entrega:	07/2026
Titulación o programa:	Máster Universitario en Ciencia de Datos
Área del Trabajo Final:	Área 5 - Data Science in Social Systems, Smart Cities and Urban Data
Idioma del trabajo:	Castellano
Palabras clave	Abandono universitario, aprendizaje automático, LightGBM, AutoML, interpretabilidad, equidad algorítmica, SHAP, Universitat Jaume I
Resumen del Trabajo	
El propósito de esta investigación es analizar las causas del abandono universitario, un fenómeno persistente en el ámbito nacional. Este abandono varía de unas titulaciones a otras entre el 5 % y el 50 % aproximadamente. Este amplio rango puede ser debido a multitud de factores. Se busca estudiar si el éxito o el fracaso académico viene marcado por el rol del estudiantado, factores sociodemográficos (como edad, género, nacionalidad, domicilio, situación laboral) o socioeconómicos (como la emancipación o trabajo estable). Para ello se ha realizado un estudio multifactorial de causalidad multivariable para ver el grado de significancia entre los distintos factores utilizando algunos indicadores de rendimiento académico (tasas de abandono y éxito, de evaluación o de rendimiento) de una serie temporal de 11 años proporcionada por la Universidad Jaume I (Castellón de la Plana) que se ha llevado a cabo en todas las titulaciones existentes impartidas desde que comenzaron los grados hasta 2021. El objetivo es predecir el resultado del abandono universitario (o la deserción académica). Para ello, este proyecto aplicará técnicas de clasificación binaria supervisada mediante un enfoque AutoML (PyCaret), comparando múltiples algoritmos como XGBoost, Árboles de Decisión y Naïve Bayes, entre otros.	

De este modo se pretende obtener las evidencias más significativas que influyen en el abandono para saber los motivos y poder recomendar factores correctivos que reduzcan o eviten dicho abandono.

Abstract

The purpose of this research is to analyse the causes of university dropout, a persistent phenomenon at the national level. Dropout rates vary from one degree to another between approximately 5 % and 50 %. This wide range may be due to a multitude of factors. The aim is to study whether academic success or failure is determined by the student profile, sociodemographic factors (such as age, gender, nationality, place of residence, employment status) or socioeconomic factors (such as emancipation or stable employment). To this end, a multifactorial, multivariate causality study has been carried out to assess the degree of significance among the different factors, using academic performance indicators (dropout, success, evaluation and performance rates) from an 11-year time series provided by the Universitat Jaume I (Castellón de la Plana), covering all degree programmes offered since their introduction until 2021.

The objective is to predict university dropout (academic attrition). To this end, the project will apply supervised binary classification techniques using an AutoML approach (PyCaret), comparing multiple algorithms such as XGBoost, Decision Trees, and Naïve Bayes, among others.

In this way, it is intended to obtain the most significant evidence influencing dropout in order to identify the underlying reasons and recommend corrective measures to reduce or prevent it.

Índice

1. Introducción	7
1.1. Contexto y justificación del Trabajo	8
1.2. Objetivos del Trabajo	9
1.3. Impacto en sostenibilidad, ético-social y de diversidad	10
1.4. Enfoque y método seguido	12
1.5. Planificación del trabajo	14
1.6. Hitos del cronograma del proyecto	17
1.7. Especificación de requisitos	20
2. Estado del arte	24
2.1. El papel de la minería de datos	27
2.2. Cómo abordar el problema	28
2.3. Análisis de técnicas utilizadas en estudios anteriores de abandono	31
3. Materiales y Métodos	36
3.1. Conjunto de datos	36
3.2. Arquitectura del proyecto y flujo de trabajo	38
3.3. Preprocesado y limpieza (Fase 1)	40
3.4. Análisis exploratorio inicial (Fase 2)	41
3.5. Ingeniería de variables (Fase 3)	42
3.6. Análisis exploratorio del target (Fase 4)	44
3.7. Validación competitiva con AutoML (Fase 3.5)	45
3.8. Modelado clásico supervisado (Fase 5)	46
3.9. Sistema dinámico de selección del modelo ganador (Fase 6/m00)	48
3.10. Interpretabilidad del modelo (Fase 6/m01-m02)	49
3.11. Análisis de equidad algorítmica (Fase 6/m03)	50
3.12. Robustez, calibración y sostenibilidad (Fase 6/m04)	51
3.13. Aplicación Streamlit (Fase 7)	52

3.14. Herramientas y entorno técnico	53
4. Resultados.....	54
4.1. Resultados del análisis exploratorio inicial (Fase 2)	54
4.2. Resultados del análisis dirigido al abandono (Fase 4).....	55
4.3. Resultados de la validación con AutoML	57
4.4. Resultados del modelado clásico (Fase 5)	58
4.5. Métricas desagregadas por clase	60
4.6. Importancia de variables mediante valores SHAP	64
4.7. Análisis de equidad y diversidad	66
4.8. Robustez, calibración y sostenibilidad	69
4.9. Aplicación Streamlit como herramienta de uso institucional	74
4.10. Limitaciones identificadas	76
5. Conclusiones y trabajos futuros	78
5.1. Conclusiones por objetivo	78
5.2. Aportaciones técnicas y científicas	80
5.3. Aportaciones institucionales y producto desplegado	81
5.4. Limitaciones del estudio	82
5.5. Líneas de trabajo futuro	83
5.6. Reflexión ética y compromiso con los Objetivos de Desarrollo Sostenible	84
Glosario	86
Indicadores académicos.....	86
Tipologías de abandono.....	86
Aprendizaje automático y modelos predictivos	87
Marco institucional y normativo	89
Tecnologías y formatos	90
Bibliografía.....	91

Lista de Figuras

Ilustración 1. Tasa de abandono de grado por tipo de universidad y año.	8
Ilustración 2. Etapas del proceso de KDD.	13
Ilustración 3. Tareas en relación con las entregas y las metodologías aplicadas	15
Ilustración 4. Fases del cronograma del proyecto.	18
Ilustración 5. Clasificación de deserción con respecto a la intención. Fuente: adaptado de Díaz Rangel (2014).	25
Ilustración 6. Factores asociados al abandono según el modelo de Tinto (1992).	26
Ilustración 7. Modelo conceptual del proceso de deserción universitaria	30
Ilustración 8. Arquitectura modular del proyecto	39
Ilustración 9. Matriz de confusión del modelo LightGBM__none	61
Ilustración 10. Curva ROC del modelo LightGBM__none. AUC = 0,956.	62
Ilustración 11. Curva Precision-Recall del modelo LightGBM__none. AUC-PR = 0,919. La línea gris discontinua indica el baseline correspondiente a la proporción de positivos en el conjunto de test (0,295).	63
Ilustración 12. Métricas del modelo LightGBM__none para distintos umbrales de decisión. El descenso del umbral incrementa la sensibilidad a costa de la precisión, permitiendo adaptar el modelo a contextos de intervención más o menos saturados.	63
Ilustración 13. Top-15 features ordenadas por importancia SHAP global (media del valor absoluto sobre el conjunto de test). Modelo LightGBM__none.	64
Ilustración 14. Gráfico SHAP beeswarm del modelo LightGBM__none sobre las 6.596 observaciones del conjunto de test. Cada punto representa una persona estudiante; el eje horizontal muestra el impacto sobre la probabilidad de abandono predicha	66
Ilustración 15. Evolución del AUC-ROC	71
Ilustración 16. Curva de fiabilidad del modelo LightGBM.	72
Ilustración 17. Página de inicio (p00) de la aplicación Streamlit institucional, con cabecera, lema del proyecto e indicadores clave del modelo. Disponible en https://tfm-abandono-dinamico.streamlit.app/ .	75

Lista de tablas

Tabla 1. Relación entre el TFM y los Objetivos de Desarrollo Sostenible (ODS).	11
Tabla 2. Variables consideradas en el estudio	17
Tabla 3. Resumen de hitos del proyecto.	18
Tabla 4. Resumen de estudios anteriores sobre el abandono universitario	34

Tabla 5. Tasa de abandono real por rama de conocimiento sobre el conjunto de test (n = 6.596). Fuente: elaboración propia.	55
Tabla 6. Perfiles medios diferenciales entre alumnado con y sin abandono (n = 33.621). Fuente: elaboración propia a partir del dataset modelable	56
Tabla 7. Top-10 de los 69 modelos evaluados, ordenados por F1 con desempate por recall. El símbolo ★ identifica al modelo seleccionado	59
Tabla 8. Métricas de clasificación desagregadas por clase del modelo LightGBM__none sobre el conjunto de test. AUC-ROC = 0,956; AUC-PR = 0,919; Accuracy = 0,906.	60
Tabla 9. Métricas desagregadas por sexo. DPD = 0,147; EOD = 0,046; DIR = 0,587.	67
Tabla 10. Métricas desagregadas por rama de conocimiento. DPD = 0,231; EOD = 0,059; DIR = 0,370.	68
Tabla 11. Métricas desagregadas por vía de acceso. DPD = 0,390; EOD = 0,432; DIR = 0,249.	68
Tabla 12. AUC-ROC del modelo LightGBM desagregado por cohorte de entrada (cursos 2010- 2020).	70
Tabla 13. Métricas de calibración probabilística del modelo LightGBM sobre el conjunto de test (n = 6.596).	72
Tabla 14. Indicadores de sostenibilidad operativa del modelo LightGBM.	73

1. Introducción

Este Trabajo de Fin de Máster (TFM) tiene como objetivo analizar y pronosticar la tasa de abandono en los estudios de grado de la Universitat Jaume I (UJI). El estudio se basa en datos institucionales recogidos desde la implantación del Plan Bolonia en la UJI. El conjunto de datos se obtuvo a partir del registro de preinscripciones del Sistema Universitario Valenciano, filtrando los registros del alumnado finalmente matriculado en la UJI.

El periodo de análisis comprende once cursos académicos consecutivos, desde el 2010-2011 hasta el 2020-2021, e incluye los datos de matrícula de todo el alumnado de grado activo en la UJI durante esos años, con independencia del curso de inicio o de la titulación. Aunque el presente TFM se desarrolla en 2026, el corte temporal del estudio se cierra en el curso 2020-2021, último ejercicio académico para el que se dispone de datos institucionales consolidados. Esta serie histórica cerrada de once años resulta suficiente para garantizar la robustez del análisis y la validez de los modelos predictivos.

Nota terminológica: En este trabajo se emplea el término **«abandono»** como concepto principal para referirse a la interrupción definitiva de los estudios de grado, en consonancia con la terminología adoptada por el Ministerio de Universidades (Fernández-Mellizo, 2022) y la CRUE. El término **«deserción»** se utiliza como sinónimo en contextos donde se hace referencia a la literatura iberoamericana (Himmel, 2002; García de Fanelli, 2014), mientras que **«dropout»** se emplea al citar fuentes anglosajonas (Tinto, 1975; Braxton et al., 2004). Los tres términos designan el mismo fenómeno a lo largo del documento.

a) Tasa de **abandono** del grado




Ilustración 1. Tasa de abandono de grado por tipo de universidad y año.

La Ilustración 1, extraída del informe U-Ranking 2019 (Fundación BBVA & Ivie, 2020), muestra las distintas trayectorias de abandono en los estudios de grado según el Sistema Universitario Español (SUE): desde el cambio de titulación hasta la salida definitiva del sistema. Este gráfico permite contextualizar el fenómeno del abandono universitario a nivel nacional y orientar el análisis predictivo con mayor precisión. Para un análisis desagregado por tipo de trayectoria (cambio de titulación, salida del sistema y abandono total), véase Ilustración A.1 en Anexo A.

1.1. Contexto y justificación del Trabajo

En los últimos años, se ha puesto de manifiesto el importante crecimiento del abandono de los estudios universitarios (Fundación BBVA, 2019). En este trabajo se entiende por abandono el hecho de que una persona estudiante, tras haberse matriculado por primera vez en una titulación, no se vuelva a matricular durante dos cursos consecutivos en la misma carrera y universidad.

Aunque este fenómeno ha estado presente históricamente, su incremento reciente resulta preocupante y constituye uno de los principales motivos que impulsan este trabajo. Este aumento se produce en un contexto de transformación socioeconómica y educativa, marcado por la reducción de fondos públicos para la educación superior y la creciente competencia entre universidades públicas y privadas (Ministerio de Educación, Formación Profesional y Deportes, s. f.).

En el caso concreto de la UJI, no existe hasta la fecha un análisis global y en profundidad de las tasas de abandono en sus titulaciones de grado. Por ello, este TFM representa una oportunidad para estudiar el fenómeno desde una perspectiva multifactorial, utilizando series históricas de matrícula desde 2010 y aplicando técnicas de análisis predictivo. El objetivo es identificar los factores que influyen en el abandono y proporcionar a la dirección de la universidad conclusiones que contribuyan a diseñar estrategias orientadas a reducirlo y fomentar nuevos ingresos.

A nivel nacional, el abandono universitario se estima en torno al 13 % (Fernández-Mellizo, 2022), cifra que desciende al 11 % entre el estudiantado menor de 30 años, datos similares a los de otros países de la OCDE. Según el Informe del Ministerio de Universidades (2022), durante el curso 2015-2016 la tasa de créditos aprobados sobre créditos matriculados en las universidades españolas fue del 64 %, mientras que la tasa de graduación se situó en el 32,4 %, seis puntos por debajo de la media de la OCDE.

La evolución reciente del sistema universitario español muestra señales contrastadas. Datos de La Moncloa (2022) señalan que el crecimiento del número de graduados entre 2001 y 2007 fue del 0,5 % en España, frente al 4,1 % del conjunto de países de la OCDE. No obstante, el informe de la Fundación BBVA (2019) sitúa la tasa de titulados sobre ingresados en el 80 %, lo que refleja una mejora notable respecto a los registros de 2016.

Este contexto motiva los objetivos específicos que se detallan a continuación.

1.2. Objetivos del Trabajo

El objetivo principal de este estudio es analizar el abandono en los estudios de grado de la UJI desde la implantación del Plan Bolonia, dado que afecta aproximadamente a uno de cada diez miembros del alumnado. Más allá de cuantificar la tasa de abandono, se pretende comprender la naturaleza, las causas y las características del fenómeno, con el fin de identificar los factores que lo explican y orientar estrategias de prevención y apoyo al alumnado.

Este análisis permitirá estudiar si el éxito o el fracaso académico están determinados por el perfil del estudiantado, considerando variables como la edad, el género, la nacionalidad, el domicilio

durante los estudios y la situación laboral. También se tendrán en cuenta aspectos económicos, como la emancipación o la estabilidad en el empleo, para comprender mejor la relación entre las condiciones personales y el rendimiento académico.

Asimismo, se analizarán las causas del abandono universitario, un fenómeno persistente tanto en la UJI como en el ámbito nacional, con tasas que varían entre titulaciones desde el 5 % hasta el 50 %. Para ello, se utilizarán los indicadores de rendimiento académico —tasas de abandono, evaluación, éxito y rendimiento— correspondientes a los últimos once años, según los datos proporcionados por la UJI.

Objetivos del estudio:

- **O1.** Establecer un modelo predictivo para el abandono universitario.
- **O2.** Estudiar las variables de mayor influencia en el fenómeno.
- **O3.** Analizar la interacción entre las variables asociadas al abandono.
- **O4.** Diagnosticar si existe desigualdad de oportunidades en el abandono según factores sociales, económicos y demográficos.
- **O5.** Proponer políticas para reducir el abandono y mejorar la igualdad de oportunidades.

El propósito final es aportar información útil que permita a la universidad focalizar el problema, diseñar propuestas estratégicas y aplicar medidas de mejora orientadas a reducir el abandono y potenciar el éxito académico. El logro de estos objetivos requiere considerar las dimensiones éticas, sociales y de sostenibilidad que se abordan en la siguiente sección.

1.3. Impacto en sostenibilidad, ético-social y de diversidad

El objetivo principal de esta dimensión es determinar cómo los factores sociales y de diversidad influyen en el abandono universitario, con el fin de reducir su tasa y avanzar hacia una universidad **ética** —justa y equitativa para toda persona—, **diversa** —donde nadie sea discriminado por razones sociales o de género—, **sostenible** —que haga un uso responsable de los recursos económicos y del capital humano que la sociedad pone a su disposición— y **eficiente** —capaz de optimizar sus procesos educativos y administrativos para minimizar el abandono—. La deserción

universitaria no solo afecta a las familias, sino también al gobierno, ya que los recursos invertidos se desperdician, lo que lleva a un aumento de la desigualdad, la pobreza y un progreso limitado en el desarrollo científico y académico (Humphrey, 2008).

Integrar los conceptos de sostenibilidad, ética social y diversidad en este TFM permite desarrollar un proyecto innovador, transformador y con impacto institucional. Estos tres ejes refuerzan el compromiso de la universidad con los valores contemporáneos de equidad, inclusión y responsabilidad, y se concretan en tres dimensiones complementarias:

- **Sostenibilidad.** Se promueve el uso responsable de los recursos computacionales mediante flujos de trabajo eficientes, reproducibles y escalables.
- **Ética social.** El análisis del abandono universitario se aborda desde una perspectiva crítica, reconociendo su impacto en la equidad educativa y en la toma de decisiones institucionales.
- **Diversidad.** Se consideran variables que permiten detectar sesgos estructurales y se fomenta la inclusión de colectivos vulnerabilizados en el diseño del modelo predictivo.

ODS	Relación con el TFM	Ejemplo de acción en el trabajo
ODS 4	Educación de calidad (inclusiva y equitativa)	Análisis de factores de permanencia
ODS 5	Igualdad de género	Detección de brechas en abandono
ODS 10	Reducción de desigualdades	Políticas de apoyo a colectivos vulnerables

Tabla 1. Relación entre el TFM y los Objetivos de Desarrollo Sostenible (ODS).

Este TFM se vincula de forma directa con el Plan UJI-ODS 2030, hoja de ruta institucional para la implantación de la Agenda 2030 en la Universitat Jaume I, contribuyendo especialmente a los ODS 4, 5 y 10. La aplicación operativa de estos principios mediante el Sistema de Gestión Documental institucional, la documentación técnica en Confluence y los mecanismos de transferencia e impacto se desarrollan en el Anexo A (apartados A.2, A.3, A.4 y A.5). Estos principios guían el enfoque metodológico que se describe a continuación.

1.4. Enfoque y método seguido

Este Trabajo de Fin de Máster adopta un enfoque modular, reproducible y ético para el análisis del abandono universitario, integrando herramientas técnicas, criterios institucionales y principios de sostenibilidad, diversidad y responsabilidad social.

El método seguido se articula en tres niveles complementarios:

Nivel técnico: proceso KDD y modelado predictivo.

La metodología se basa en el proceso de **Knowledge Discovery in Databases (KDD)** (Fayyad, Piatetsky-Shapiro y Smyth, 1996), que permite transformar datos originales en conocimiento útil para la toma de decisiones institucionales. Este proceso se compone de cinco fases:

- **Selección de datos.** Se determinan las fuentes y se extrae la información relevante para el análisis.
- **Preprocesamiento.** Se limpian y preparan los datos, manejando valores faltantes, inconsistencias y rangos anómalos.
- **Transformación.** Se generan nuevas variables y se normalizan los datos para facilitar el modelado.
- **Data Mining.** Se aplican técnicas de clasificación binaria para detectar patrones ocultos y predecir el riesgo de abandono.
- **Interpretación y evaluación.** Se analizan los patrones obtenidos y se evalúa su utilidad institucional.




Ilustración 2. Etapas del proceso de KDD.

La Ilustración 2 representa visualmente el flujo de transformación de datos en conocimiento, desde la selección hasta la evaluación de patrones. El conocimiento generado se propone como **Soporte a la toma de decisiones (DSS)**, orientado a mejorar la permanencia del alumnado y optimizar las políticas institucionales.

Nivel práctico: herramientas y entornos utilizados.

La estrategia de modelado se estructura en dos etapas complementarias. En una primera fase de pre-modelado, se realiza un **screening sistemático mediante cinco frameworks de aprendizaje automático automatizado (AutoML)** —LazyPredict, PyCaret, H2O, AutoGluon y **TabPFN v2** (Hollmann et al., 2024)¹—, este último un *modelo fundacional para datos tabulares* que constituye una aportación metodológica reciente al estudio del abandono universitario. En una segunda fase, se desarrolla un proceso de **modelado clásico** con afinado de hiperparámetros y comparación de algoritmos de gradient boosting, ensemble y modelos lineales, del que se obtiene el modelo final del estudio. Este enfoque dual reduce sesgos subjetivos en la selección de modelos y facilita la replicabilidad institucional.

Las herramientas utilizadas incluyen:

- **Python** como lenguaje base.
- **Scikit-learn, XGBoost, LightGBM y CatBoost** como librerías de clasificación.

- **SHAP**, **LIME** y **DiCE** para la interpretabilidad y la generación de explicaciones contrafactuales.
- **Jupyter Notebooks** para la ejecución modular y reproducible del flujo de trabajo.

Nivel institucional y ético.

El modelo se documenta íntegramente en el Sistema de Gestión Documental de la UJI, garantizando trazabilidad, revisión por expertos y transferencia. En coherencia con los Objetivos de Desarrollo Sostenible (ODS 4, ODS 5 y ODS 10), todas las actuaciones institucionales y éticas propuestas en este estudio contribuyen a fortalecer el compromiso universitario con la sostenibilidad educativa, la igualdad de género y la reducción de desigualdades. Además, el análisis se realiza desde una perspectiva crítica, reconociendo el abandono como fenómeno multifactorial con implicaciones sociales, económicas y culturales. Cada decisión metodológica se justifica técnicamente y se documenta con fines didácticos, facilitando su comprensión por parte del alumnado, personal docente y personal técnico.

Este enfoque permite no solo obtener resultados técnicamente válidos, sino también generar conocimiento útil, transferible y alineado con los valores institucionales de la UJI. La aplicación de este enfoque se concreta en la planificación temporal del proyecto.

¹ La inclusión de TabPFN v2 en el estudio fue una aportación incorporada durante el desarrollo del trabajo, posterior a la fase inicial de planificación.

1.5. Planificación del trabajo

La planificación del Trabajo de Fin de Máster se ha estructurado por fases, alineadas con los hitos de las PECs y las metodologías propuestas para alcanzar los entregables definidos. Se han utilizado herramientas gráficas para representar tanto la secuencia de tareas como los hitos temporales clave.

Pronóstico del éxito en los títulos de la Universitat Jaume I

Fecha de inicio: 19/02/2026 María José Martínez Ruiz
Fecha de finalización: 24/06/2026 Tutor: Raúl Parada Medina

Posición	Fecha de inicio	Fecha de finalización	Actividad	Duración	Aplicación	
1	19/02/2026	01/03/2026	Definición y planificación del trabajo final	10		M1
2	19/02/2026	20/02/2026	Objetivos	1		
3	21/02/2026	01/03/2026	Presentar PEC	8		
4	02/03/2026	22/03/2026	Estado del arte o análisis de mercado del proyecto	20		M2
5	23/03/2026	30/03/2026	Fuentes	7		
6	23/03/2026	02/04/2026	Parámetros	10		
7	23/03/2026	27/03/2026	Datos	4		
8	23/03/2026	28/04/2026	Diseño e implementación del trabajo	36		M3
8.1	23/03/2026	28/03/2026	Limpieza y Preparación de Datos et (Preprocesamiento)	6	Tarea crítica. Dado que el dataset tiene "muchos errores" (según su descripción), se añade 1 día para garantizar un preprocesamiento robusto.	
			Normalización de datos y tratamiento de valores atípicos. Imputación o eliminación de datos faltantes (gestión de errores). Definición de la variable objetivo (clasificación binaria: abandono / no abandono)			
8.2	29/03/2026	03/04/2026	Ingeniería de Características (Transformación)	6	Esta fase es clave para la calidad del modelo y requiere tiempo, pero 7 días es razonable tras una limpieza completa.	
			Creación de variables de rendimiento (ratios de éxito, evaluación, etc.) Codificación de variables categóricas (género, acceso, etc.). Balanceo del dataset (si es necesario por la tasa de abandono).			
8.3	04/04/2026	09/04/2026	Modelado Inicial (Data Mining y Entrenamiento)	6	6 o 7 días. El uso de librerías como PyCaret (mencionado en el documento) automatiza el benchmark inicial, permitiendo acelerar esta fase.	
			Configuración inicial de algoritmos (Árboles de Decisión, Naive Bayes, XGBoost) Entrenamiento y comparación de algoritmos base (Árboles de Decisión, Naive Bayes, XGBoost) Selección de modelos con mejor métrica de desempeño (p. ej., F1-Score, AUC)			
8.4	10/04/2026	17/04/2026	Optimización y Evaluación Final	8	La optimización y la validación cruzada intensiva, junto con el análisis de sesgos éticos, requieren tiempo completo.	
			Optimización de hiperparámetros (Grid/Random Search). Validación cruzada y ajuste del umbral de clasificación. Análisis de la interpretabilidad (SHAP/Feature Importance) y bias.			
8.5	18/04/2026	21/04/2026	Serialización e Integración del Modelo	4	Es un paso técnico crucial para preparar el modelo para su despliegue web.	
			Finalización y serialización del modelo predictivo optimizado (pickle/json).			
8.6	22/04/2026	28/04/2026	Desarrollo de la Plataforma Web Interactiva	7	Construir la estructura web (Streamlit), embeber visualizaciones (Tableau/Power BI) e implementar la consulta interactiva es una tarea de una semana.	
			Diseño del dashboard dinámico /Desarrollo de la aplicación web (Streamlit). Procesado de implementación de la visualización de resultados clave (streamlit/power bi embebe).			
9	27/03/2026	19/04/2026	Actividades complementarias en paralelo de formación de ayuda al TFM	23		
10	20/04/2026	08/05/2026	Feedback profesor	15		
11	11/05/2026	17/05/2026	Redacción de la memoria (La Entrega)	6		M4-1
12	18/05/2026	24/05/2026	Redacción de la memoria (Entrega Final)	6		M4-2
13	25/05/2026	02/06/2026	Presentación audiovisual del trabajo	7		M4-3
14	09/06/2026	10/06/2026	Preparación de la defensa del proyecto.	2		M5-1
15	09/06/2026	16/06/2026	Defensa pública	18		M5-2
				0		

Ilustración 3. Tareas en relación con las entregas y las metodologías aplicadas

La Ilustración 3 muestra la planificación del TFM mediante un diagrama de Gantt que vincula las fechas de las PECs con las tareas metodológicas del proyecto. La planificación temporal se articula en cinco módulos principales (M1-M5):

- **Módulo 1.** Definición y planificación del trabajo final, incluyendo entrega al comité de ética y solicitud de confidencialidad.
- **Módulo 2.** Estado del arte y análisis de mercado del proyecto.
- **Módulo 3.** Diseño e implementación del trabajo.
- **Módulo 4.** Redacción y presentación de la memoria.
- **Módulo 5.** Defensa pública del proyecto.

Para una representación visual complementaria de las fases principales y su secuencia temporal, véase Ilustración A.3 en Anexo A.

1.5.1. Análisis del abandono universitario mediante aprendizaje automático supervisado

El análisis del abandono se aborda como un problema de **clasificación binaria**, aplicando técnicas de aprendizaje automático supervisado. Se considera abandono cuando una persona estudiante no registra matrícula durante dos cursos académicos consecutivos en la misma titulación y universidad.

Aunque la literatura distingue diferentes tipos de deserción —voluntaria, involuntaria, cambio de titulación o salida del sistema (Himmel, 2002)—, en este estudio se opta por una clasificación binaria (abandono / no abandono) por dos razones: en primer lugar, los datos institucionales disponibles no permiten distinguir con fiabilidad el motivo del cese de matrícula; en segundo lugar, desde la perspectiva institucional, el objetivo prioritario es detectar el riesgo de abandono independientemente de su causa, para activar mecanismos de intervención temprana.

La estrategia metodológica combina, como se detalla en la sección 1.4, una primera fase de screening con frameworks AutoML y una segunda fase de modelado clásico con afinado de hiperparámetros, garantizando un proceso reproducible y alineado con los principios de transparencia y sostenibilidad computacional. Una representación complementaria del flujo general de minería de datos puede consultarse en la Ilustración A.4 del Anexo A.

Para la realización de este estudio se dispone de un conjunto de ficheros de datos en formato hoja de cálculo proporcionados por la Universitat Jaume I. Estos archivos contienen una serie histórica que abarca desde el curso 2010-2011 hasta el 2020-2021, integrando la información necesaria para el análisis de las trayectorias académicas. Las variables consideradas se organizan en cuatro categorías principales:

Categoría	Variables
-----------	-----------

Individuales	Fecha de nacimiento, género, nacionalidad, domicilio durante los estudios, estado civil, tipo de residencia
Académicas	Curso de acceso, vía de acceso, nota de acceso, titulación, créditos matriculados, créditos superados, tasa de rendimiento, tasa de éxito, curso de abandono
Institucionales	Facultad/centro, tipo de preinscripción, posición en la solicitud de ingreso, modalidad de dedicación
Socioeconómicas	Situación laboral, tipo de beca, financiación de los estudios, emancipación

Tabla 2. Variables consideradas en el estudio

El alcance temporal del estudio comprende los cursos académicos desde 2010-2011 hasta 2020-2021, periodo que coincide con la implantación del Plan Bolonia y abarca exclusivamente titulaciones de grado de entre 180 y 240 créditos. El análisis se circunscribe al abandono dentro de la UJI: no se contempla la continuación de estudios en otras universidades ni el cambio entre titulaciones de la propia institución, debido a la falta de acceso a esos datos. El detalle temporal de los hitos se desarrolla a continuación.

1.6. Hitos del cronograma del proyecto

La planificación del Trabajo de Fin de Máster se ha estructurado en cinco hitos principales (M1-M5) que marcan la evolución progresiva del proyecto desde la definición inicial hasta la defensa pública. Cada hito está vinculado a una PEC entregable y se representa gráficamente en el cronograma visual.



En la Ilustración 4 se presenta el cronograma de fases del TFM, con fechas clave y tareas específicas que permiten seguir el progreso del proyecto, garantizar su éxito académico y facilitar la gestión del tiempo en el contexto institucional de la UJI.

Hito	Periodo	Descripción
M1	Feb 2026	Definición y planificación
M2	Mar 2026	Estado del arte
M3	Mar-Abr 2026	Diseño e implementación
M4	May-Jun 2026	Redacción y presentación
M5	Jun-Jul 2026	Defensa pública

Tabla 3. Resumen de hitos del proyecto.

A continuación, se sintetizan los cinco hitos principales:

M1 — Definición y planificación. Esta primera fase se centra en la elección del tema, el enfoque metodológico, la coordinación con el tutor, la presentación de la PEC1 y una primera búsqueda

bibliográfica en bases de datos especializadas. Se aborda el problema del abandono universitario en la UJI² desde una metodología cuantitativa no experimental.

M2 — Estado del arte. Esta fase se centra en la recopilación de antecedentes relevantes sobre el abandono universitario a nivel nacional e internacional, mediante la consulta de bases de datos científicas (Scopus, Web of Science, Dialnet, CSIC, Teseo) y organismos públicos (Ministerio de Universidades, SIIU, CRUE, SIUVP), construyendo la base teórica y empírica que sustenta el diseño del modelo.

M3 — Diseño e implementación. Esta fase se centra en la construcción progresiva del proyecto mediante técnicas de minería de datos sobre los datos reales de la UJI, integrando fuentes institucionales (Vicerrectorado de Investigación, Gabinete de Planificación, OIATI, UADTI)³. La metodología de modelado se desarrolla en el Capítulo 3.

M4 — Redacción y presentación. Esta fase se centra en la elaboración de la memoria final del TFM (entrega preliminar y entrega definitiva) y en la preparación de la presentación audiovisual para la defensa, con comunicación continua con el tutor para incorporar *feedback* y consolidar el documento.

M5 — Defensa pública. La fase final consiste en la entrega definitiva del documento, la presentación ante el tribunal evaluador y la respuesta a preguntas, en modalidad online (junio-julio 2026). Este hito representa la culminación del trabajo técnico y la consolidación de competencias comunicativas, éticas y académicas.

Para una visualización detallada del cronograma día a día, véase Ilustración A.5 en Anexo A. El desarrollo expandido de cada uno de los módulos M1-M5, con sus objetivos específicos, fuentes consultadas y entregables intermedios, se recoge en el apartado A.8 del Anexo A. El cumplimiento de esta planificación requiere especificar los requisitos del sistema.

1.7. Especificación de requisitos

1.7.1. Requisitos funcionales

El sistema desarrollado para el análisis y predicción del abandono universitario debe cumplir las siguientes funciones principales:

- Permitir la recolección, tratamiento y análisis de datos académicos, sociodemográficos y económicos de todo el estudiantado, respetando la diversidad y garantizando la inclusión de colectivos tradicionalmente infrarrepresentados.
- Implementar algoritmos de aprendizaje automático supervisado para realizar la clasificación binaria del fenómeno de abandono en estudios universitarios de grado.
- Facilitar la generación de informes predictivos, desagregados por perfiles de diversidad (género, edad, nacionalidad, situación socioeconómica, entre otros), que permitan identificar patrones de abandono y orientar estrategias correctivas de manera equitativa e inclusiva.
- Disponer de interfaces para la visualización integrada de los resultados, favoreciendo la comprensión y el uso tanto por personal docente y de gestión, como por el propio alumnado.
- Permitir la exportación y documentación transparente de los procesos y resultados, facilitando la transferencia institucional y la mejora continua.

1.7.2. Requisitos no funcionales

El proyecto debe garantizar los siguientes requisitos transversales:

- **Accesibilidad universal.** El sistema será accesible por todas las personas usuarias, incluidas aquellas con diversidad funcional. Se optimizarán las interfaces para diferentes necesidades de uso y dispositivos.
- **Protección de datos y privacidad.** Se cumplirá la normativa vigente en materia de protección de datos personales, garantizando la seguridad, anonimato y confidencialidad de la información de todo el estudiantado.

- **Escalabilidad y eficiencia.** El sistema se diseñará para gestionar grandes volúmenes de datos históricos y actuales, asegurando un funcionamiento eficiente y sostenible.
- **Transparencia y reproducibilidad.** Todos los procedimientos y modelos aplicados estarán documentados de modo accesible y comprensible, asegurando la trazabilidad y la posibilidad de replicar el proceso por otros equipos o personas investigadoras, promoviendo la transferencia de conocimiento.

1.7.3. Requisitos éticos, de diversidad y sostenibilidad

Este proyecto incorpora los siguientes principios transversales de calidad institucional:

- **Equidad e inclusión.** Se garantiza la consideración de la diversidad de perfiles del estudiantado, evitando tecnicismos excluyentes y asegurando una representación justa en todas las fases del análisis.
- **Compromiso ético.** El trabajo se realiza respetando los principios de justicia, no discriminación y responsabilidad social, primando el uso ético de los datos y la aplicación de modelos que favorezcan la toma de decisiones equitativas.
- **Perspectiva de sostenibilidad.** Se promueve el uso responsable de los recursos, la optimización energética y la reducción de la brecha de abandono, alineando el proyecto con los ODS de la Agenda 2030 y las políticas institucionales de la UJI.
- **Mejora continua.** El sistema se ha de preparar para la actualización y adaptación a nuevas necesidades, promoviendo la reflexión crítica y la innovación institucional.

Protocolo ético y protección de datos.

Este proyecto ha sido sometido a una doble evaluación ética. Por una parte, se presentó la documentación completa ante el **Comité de Ética de Investigación en Seres Humanos (CEISH)** de la Universitat Jaume I, incluyendo el formulario de Investigador Principal del proyecto (SLTET-00), la autorización institucional (SLTET-01) y la autorización del representante (SLTET-02), obteniendo dictamen favorable. Por otra parte, se cumplimentó el formulario de autoevaluación ética de la UOC, igualmente con resultado favorable. Los datos académicos utilizados proceden del repositorio institucional de la UJI y fueron proporcionados de forma anonimizada en origen, sin contener nombres, DNI ni datos identificativos directos, según consta en el certificado emitido por

el Vicerrector de Investigación de la UJI, **Jesús Lancis Sáez**, con fecha **15 de octubre de 2024 y firma digital**. Adicionalmente, se diseñó y administró una **encuesta complementaria de 30 preguntas** al estudiantado de la UJI, cuyo protocolo de recogida de datos fue incluido en la documentación presentada al CEISH. El tratamiento de todos los datos se realiza conforme al **Reglamento General de Protección de Datos (RGPD, Reglamento UE 2016/679)**, la **Ley Orgánica 3/2018** de Protección de Datos Personales y Garantía de los Derechos Digitales, y el **Reglamento de protección de datos personales de la UJI (Artículo 33)**.

Principios éticos aplicados.

El marco ético de este TFM se fundamenta en los principios reconocidos internacionalmente — **Declaración de Helsinki**, **Informe Belmont** y **Declaración Universal sobre Bioética y Derechos Humanos de la UNESCO**—, adaptados al ámbito de la investigación educativa con datos institucionales. En concreto, el proyecto aplica los principios de (a) **beneficencia**, mediante el diseño del modelo predictivo orientado a identificar al estudiantado en riesgo de abandono para activar mecanismos de apoyo preventivo; (b) **no maleficencia**, garantizando que los resultados no se utilicen para penalizar, excluir ni estigmatizar a ninguna persona estudiante, sino exclusivamente para orientar políticas de acompañamiento; (c) **justicia y equidad**, asegurando que el análisis considere la diversidad de perfiles sin discriminar por género, nacionalidad, origen socioeconómico u otras variables sensibles; y (d) **privacidad y confidencialidad**, mediante la gestión anonimizada de los datos, sin posibilidad de reidentificación individual, y su almacenamiento en entornos seguros con acceso restringido.

Equidad algorítmica y prevención de sesgos.

Dado que el proyecto emplea técnicas de aprendizaje automático para clasificación binaria, resulta imprescindible evaluar si el modelo resultante reproduce o amplifica sesgos presentes en los datos históricos. Para ello se realiza un análisis de equidad (*fairness*) que incluye la evaluación del rendimiento del modelo desagregado por variables sensibles —género, nacionalidad y vía de acceso—, el cálculo de métricas de equidad como *disparate impact* y *equal opportunity difference*, y el análisis de interpretabilidad mediante **SHAP** para verificar que las variables con mayor peso predictivo no codifiquen discriminación indirecta. Este enfoque se alinea con las recomendaciones

de la **Comisión Europea (2019)** sobre inteligencia artificial fiable y con el **ODS 10** sobre reducción de las desigualdades.

Sostenibilidad computacional.

En coherencia con los principios de sostenibilidad del proyecto, se documenta el coste computacional de las fases de entrenamiento y evaluación de los modelos predictivos, incluyendo el tiempo de ejecución, el consumo de memoria y una estimación de la huella de carbono asociada al procesamiento. Este registro permite comparar la eficiencia de los distintos frameworks y algoritmos evaluados, y seleccionar no solo el más preciso, sino también el más eficiente desde el punto de vista energético. Se priorizan flujos de trabajo reproducibles y modulares que minimicen la repetición innecesaria de experimentos computacionales, contribuyendo así a una práctica de ciencia de datos responsable y alineada con la sostenibilidad digital.

El estado del arte sobre el abandono universitario y las técnicas de minería de datos aplicadas a su estudio se desarrolla en el siguiente capítulo.

2. Estado del arte

Tras la presentación del problema, los objetivos y el enfoque metodológico realizados en el capítulo anterior, este capítulo revisa el estado del arte sobre el abandono universitario, articulando los marcos conceptuales clásicos, las aproximaciones cuantitativas más consolidadas y los estudios precedentes que sustentan las decisiones de diseño del presente trabajo.

El presente proyecto tiene como finalidad predecir la probabilidad de que una persona estudiante no complete sus estudios, es decir, que incurra en deserción académica. El abandono universitario genera consecuencias económicas, sociales y académicas, por lo que su prevención requiere estrategias eficaces basadas en evidencia.

Es necesario distinguir, en primer lugar, entre la deserción voluntaria y la involuntaria, tal como propone el modelo de análisis de la deserción estudiantil en la educación superior desarrollado por Himmel (2002). Esta distinción constituye el punto de partida teórico del presente estudio y sirve de base para la clasificación binaria adoptada en el modelo predictivo.

La deserción voluntaria puede adoptar la forma de renuncia a la carrera por parte del estudiantado o del abandono no informado a la institución de educación superior.

La deserción involuntaria se produce como consecuencia de una decisión institucional, fundada en sus reglamentos vigentes, que obliga al alumnado a retirarse de los estudios. En este último caso, la deserción puede estar fundamentada en un desempeño académico insuficiente o responder a razones disciplinarias de diversa índole.




Ilustración 5. Clasificación de deserción con respecto a la intención. Fuente: adaptado de Díaz Rangel (2014).

La Ilustración 5 muestra una clasificación más detallada que la dicotomía simple retención/deserción. Cada categoría puede analizarse a distintos niveles de granularidad según las necesidades del estudio.

Aunque se trata de un modelo clásico, Tinto (1975) ya destacaba la importancia de la integración del alumnado en la vida académica como resultado de la interacción entre las características propias del estudiantado y las de la universidad. Su vigencia ha sido confirmada por investigaciones posteriores que lo han ampliado y adaptado a nuevos contextos educativos (Cabrera et al., 1993; Braxton et al., 2004). Estos estudios coinciden en que la integración académica y social sigue siendo un predictor clave de la permanencia estudiantil, especialmente cuando se analiza junto a variables institucionales y personales. Estos antecedentes teóricos sustentan directamente la selección de variables y el diseño del modelo predictivo del presente TFM.

Siguiendo esta línea, los factores que explican el abandono universitario pueden clasificarse en:

(1) Factores individuales, que a su vez pueden dividirse en factores demográficos, socioeconómicos y académicos (según la clasificación de García de Fanelli, 2014). Los demográficos son los que tienen que ver con el género, la edad, etc.; los socioeconómicos con la situación social, económica y cultural de la familia del estudiantado, o la propia en caso de emancipación; los académicos con la experiencia educativa previa y con las expectativas académicas.

(2) Factores de interacción del estudiantado con el ambiente de la universidad, que resultan en dos tipos de integración: la integración académica, que se manifiesta sobre todo en el rendimiento académico en la universidad; y la integración social, que se refiere al grado de participación en actividades de la universidad y al grado de compromiso institucional.

(3) Factores institucionales, que van desde el tipo de universidad (pública o privada), a sus recursos, pasando por su calidad.




Ilustración 6. Factores asociados al abandono según el modelo de Tinto (1992).

Las definiciones de Tinto y Himmel coinciden en entender la deserción como la situación en la que el estudiantado aspira a un proyecto educativo y no logra concluirlo. Operativamente, se considera persona desertora a quien, estando matriculada en educación superior, no presenta actividad académica durante dos semestres consecutivos.

El objetivo es analizar el fenómeno e intervenir en él, con el fin de elaborar un diagnóstico y proponer respuestas que minimicen el abandono a nivel social, educativo, profesional y económico.

Se adopta el estudiantado como unidad de análisis para identificar frecuencias de abandono, sus causas asociadas y los perfiles de riesgo en cada titulación de la UJI, con el fin de orientar políticas institucionales que promuevan la permanencia.

Comprender cómo influye el comportamiento del estudiantado en la obtención del título (Mishra et al., 2014) resulta clave para intervenir en consecuencias como las pérdidas económicas (Márquez-Vera et al., 2016), las bajas tasas de graduación o el deterioro reputacional de la institución, dado que la calidad de la educación se mide en buena parte por el porcentaje de personas graduadas y por las estrategias de retención.

Estos marcos teóricos clásicos han encontrado en la minería de datos educativa un instrumento metodológico que permite operacionalizar y validar empíricamente sus hipótesis a gran escala.

2.1. El papel de la minería de datos

La aplicación de la minería de datos en el ámbito educativo no es reciente, pero sí ha ganado solidez en los últimos años como herramienta para analizar el abandono estudiantil desde múltiples perspectivas. Estudios desarrollados en la Universidad de Granada (Araque et al., 2009), la Universidad de Castilla-La Mancha (Lacave et al., 2016), junto con análisis a gran escala promovidos por el Ministerio de Universidades (Fernández-Mellizo, 2022), evidencian su utilidad y alcance.

Estos trabajos —que se revisan con mayor detalle en el apartado 2.3— emplean técnicas diversas, que van desde la regresión logística y las redes bayesianas hasta algoritmos de aprendizaje automático, con el objetivo de identificar factores de riesgo asociados al abandono. Lo que distingue a la minería de datos educativa es su capacidad para procesar grandes volúmenes de información mediante estos métodos avanzados, permitiendo análisis automatizados y profundos que, en muchos casos, superan las posibilidades de los enfoques estadísticos clásicos.

Este proyecto se enmarca precisamente en esa tradición, adoptando un enfoque de clasificación binaria supervisada que permite no solo predecir el abandono, sino también interpretar los factores que lo determinan, con el fin de orientar políticas institucionales basadas en evidencia.

Una vez establecida la disciplina metodológica, conviene precisar cómo se aborda el problema concreto del abandono en el caso de estudio de la Universitat Jaume I.

2.2. Cómo abordar el problema

Este estudio aborda el abandono universitario en la UJI analizando los cursos académicos desde 2010-2011 hasta 2020-2021, mediante la aplicación de técnicas de minería de datos.

El objetivo principal es desarrollar y comparar diferentes modelos predictivos para identificar el algoritmo más eficaz en la detección temprana de la probabilidad de abandono. Para garantizar la robustez metodológica, el proyecto integra un enfoque híbrido: una fase inicial de validación competitiva mediante cinco frameworks de AutoML (LazyPredict, PyCaret, H2O, AutoGluon y TabPFN v2), seguida de una fase de modelado clásico optimizado en la que se evalúan múltiples algoritmos y estrategias de manejo del desbalance de clases.

Para ello, el análisis se basa en un amplio conjunto de variables que provienen de dos fuentes principales:

Datos institucionales: facilitados por servicios de la UJI (Gabinete de Planificación y Prospectiva, UADTI). Incluyen resultados académicos, interacción con la universidad, datos económicos, personales y modo de acceso (preinscripción). El detalle se desarrolla en el Capítulo 3.

Datos de encuesta: para completar la información descrita, se diseñó y administró una encuesta de treinta preguntas, que pasó previamente por la Comisión Deontológica y fue supervisada por la Oficina de la Promoción y Evaluación de la Calidad, dependiente del Vicerrectorado de Planificación Económica y Estratégica. Sin embargo, debido a problemas relacionados con la protección de datos en el envío al estudiantado, la tasa de respuesta fue muy baja, lo que comprometió la representatividad de los resultados. Por este motivo, los datos de la encuesta no se incorporaron al modelo predictivo, aunque su diseño y administración se documentan como parte del proceso metodológico del trabajo.

La propuesta de investigación se concreta en torno a tres objetivos:

- (1) Aplicar técnicas de aprendizaje automático para extraer reglas que permitan predecir la deserción en las distintas titulaciones.
- (2) Definir perfiles de riesgo combinando variables personales, académicas y no académicas, con el fin de identificar patrones significativos.
- (3) Analizar las rutas de deserción asociadas a cada perfil, revelando asociaciones entre variables que podrían permanecer ocultas o resultar difíciles de detectar mediante técnicas estadísticas tradicionales.

Como producto final y herramienta de transferencia de este trabajo, los resultados obtenidos — incluyendo los perfiles de riesgo y los factores asociados a la deserción— se presentan en una plataforma web interactiva diseñada para facilitar su exploración y aplicación práctica. Esta herramienta tiene una doble funcionalidad, adaptada a los distintos actores implicados:

Para la institución: funciona como un cuadro de mando dinámico, desde el cual se pueden visualizar los perfiles identificados y las asociaciones entre variables (objetivos 2 y 3), con el fin de orientar intervenciones más eficaces y contextualizadas.

Para el estudiantado (actual o futuro): ofrece una herramienta de pronóstico personalizada, que permite introducir datos propios y obtener una estimación de la probabilidad de abandono, basada en el modelo predictivo más preciso desarrollado en este estudio (objetivo 1).




Ilustración 7. Modelo conceptual del proceso de deserción universitaria

La Ilustración 7 presenta el modelo conceptual que sustenta la investigación, visualizando los múltiples factores que inciden en el fenómeno de la deserción universitaria.

El modelo articula la interacción entre dos grandes bloques. En primer lugar, los factores del estudiante: factores individuales, académicos y socioeconómicos, que representan las características y el contexto que la persona estudiante aporta al sistema universitario. En segundo lugar, los factores institucionales: el entorno de la universidad, influenciado por factores de infraestructura y servicios, valores (cultura institucional) y acciones (políticas de apoyo).

La convergencia entre los factores del estudiantado y el entorno universitario —mediada por los valores y acciones que definen la cultura y las respuestas institucionales— configura el recorrido

académico de cada persona. Cuando esta interacción es favorable, puede reforzar el compromiso y facilitar la permanencia. Pero si se generan fricciones —por desajustes entre las expectativas y necesidades del estudiantado frente a las respuestas institucionales— la trayectoria puede desviarse, y el abandono se convierte en una posibilidad real.

Este modelo no busca simplificar el fenómeno, sino todo lo contrario: enfatiza que la deserción no es una decisión aislada, sino el resultado de una dinámica compleja, donde confluyen historias personales, contextos sociales y respuestas institucionales. Por eso, más allá del análisis técnico, el objetivo es que los resultados puedan traducirse en herramientas útiles y accesibles para quienes toman decisiones y para quienes las viven.

En ese sentido, la plataforma web que acompaña este estudio no es solo un producto final, sino una propuesta de transferencia activa. El cuadro de mando permite a equipos académicos, responsables institucionales y personas implicadas en el acompañamiento estudiantil explorar los perfiles de riesgo y las asociaciones detectadas, con una mirada más contextualizada y operativa. Y para el estudiantado —actual o futuro— se ofrece una herramienta de pronóstico personalizada, donde se puede simular el perfil académico y personal para obtener una estimación de la probabilidad de abandono, basada en el modelo más eficaz.

La idea es que esta herramienta no solo visualice el problema, sino que contribuya a anticiparlo, entenderlo y, en la medida de lo posible, prevenirlo.

Para situar este planteamiento en el contexto de las investigaciones previas, la siguiente sección sintetiza los estudios más relevantes en este ámbito.

2.3. Análisis de técnicas utilizadas en estudios anteriores de abandono

A partir de los años ochenta, con el avance de los medios informáticos, surgió en las universidades la necesidad de evaluar la calidad de la educación superior que ofrecen, con el fin de minimizar los costes individuales, sociales y económicos que conlleva el abandono.

Un buen ejemplo de aplicación metodológica se encuentra en la publicación del Ministerio de Universidades (2022), titulada «Análisis del abandono de los estudiantes de grado en las

universidades presenciales en España», elaborada por María Fernández-Mellizo, que se centra en investigar la tasa de deserción entre el estudiantado de nacionalidad española que ingresó en programas de grado en el sistema universitario presencial durante el curso académico 2015-2016.

Otro ejemplo publicado es el de Araque, Roldán y Salguero (2009), quienes recopilaron las bases de datos de la Universidad de Granada de gran parte del estudiantado de 25 titulaciones para identificar las variables que influyen en el abandono. Para ello se analizó cada una de las facultades, identificando las variables de abandono tanto globales como propias de cada facultad.

Además de estos estudios descriptivos, numerosos trabajos han aplicado técnicas de análisis predictivo para abordar el abandono universitario desde una perspectiva cuantitativa. Entre las más utilizadas se encuentran los modelos de regresión logística, los árboles de decisión, las redes neuronales artificiales y los algoritmos de clasificación supervisada, que permiten identificar patrones y variables significativas en grandes volúmenes de datos académicos.

La Tabla 4 resume estos y otros estudios relevantes, identificando la metodología utilizada, la población analizada y sus principales hallazgos. La última fila recoge la contribución específica del presente TFM, destacando los aspectos que lo diferencian en términos de alcance, metodología e impacto esperado.

Institución	Estudio y año	Población	Metodología	Resultado
Moncloa - Ministerio de Universidades	Análisis del abandono de los estudiantes de grado en las universidades presenciales en España. 2022	Estudiantes de grado, universidades presenciales españolas, < 30 años.	Regresión logística.	Menos abandono en las universidades privadas (Fernández-Mellizo, 2022).
Universidad de Granada (Araque, Roldán, Salguero)	Factors influencing university dropout rates. 2009	Estudiantes de Ingeniería de Software (3 carreras).	Data Warehouse y análisis estadístico. Pruebas de chi-cuadrado y tablas de contingencia.	El perfil de abandono depende de la materia estudiada.

Institución	Estudio y año	Población	Metodología	Resultado
Universidad de Castilla-La Mancha (Lacave, Molina, et al.)	Aplicación al estudio del abandono. 2016	Titulaciones de Informática.	Aprendizaje de redes bayesianas.	Perfiles que abandonan según los datos académicos.
Universidad Complutense de Madrid	Analizar los factores de entrada. 2021	Alumnado de primer año de grado (Curso 2017/18).	Análisis logístico.	Los esfuerzos deben centrarse en el primer curso.
Universidad de Barcelona	Proyecto Sistema Intel·ligent (Universidad de Barcelona, 2017)	Estudiantes del grado de Informática.	Cinco algoritmos diferentes de aprendizaje automático.	Crear un sistema para tutores. Precisión del 82 %.
Universidad de Córdoba (Gámez, Esteban, et al.)	Algoritmo para la predicción del desempeño. 2023	Estudiantes de educación a distancia (OULAD).	Creación del algoritmo FlexNSLVOOrd.	Ayuda al profesorado a dar respuestas personalizadas (Gámez-Granados et al., 2023).
Universidad de Windsor (Wang & Zhou)	Un estudio sobre la deserción de estudiantes chinos. 2021	Estudiantes internacionales chinos.	Metodología cualitativa (experiencias y percepciones).	Abandono por fracaso académico y falta de integración (Wang & Zhou, 2021).
Universidad de Oviedo (Grupo ADIR)	Estudio de los factores de riesgo. 2023	Alumnado, PAS, personal docente y equipos de gestión.	Identificación cualitativa de causas del abandono.	Guía de buenas prácticas para prevenir el abandono, ModAU-GBP (Núñez Pérez & Bernardo, 2023).
Estudio Global (McKee, educations.com)	Tasas de abandono universitario: tendencias y causas (McKee, s. f.).	Informe del Instituto de Asuntos Públicos: factores	Identificación cualitativa de causas (distancia, costes, cultura).	Combinación de presiones financieras, aprendizaje en

Institución	Estudio y año	Población	Metodología	Resultado
		determinantes del abandono.		línea y expectativas.
Universitat Jaume I (M. J. Morte Ruiz)	Presente TFM, 2026	Grado UJI 2010-2020, 33.621 registros activos; 40 titulaciones.	Clasificación binaria supervisada: validación competitiva con cinco frameworks AutoML (LazyPredict, PyCaret, H2O, AutoGluon, TabPFN v2) y modelado clásico optimizado (LightGBM, XGBoost, CatBoost).	Modelo final LightGBM (AUC=0,956; F1=0,833; Recall=0,808). Interpretabilidad multimétodo (SHAP, LIME, DiCE), análisis de equidad algorítmica y aplicación Streamlit institucional desplegada.

Tabla 4. Resumen de estudios anteriores sobre el abandono universitario

La propuesta del presente TFM se diferencia de los estudios sintetizados en la Tabla 4 en cuatro aspectos clave. En primer lugar, amplía el horizonte temporal: cubre once cohortes consecutivas (cursos 2010-2011 a 2020-2021), lo que aporta estabilidad estadística y permite el análisis de patrones a largo plazo. En segundo lugar, incorpora un conjunto de variables más completo —24 variables (features) finales sobre 33.621 registros y 40 titulaciones—, integrando dimensiones académicas, demográficas, socioeconómicas y administrativas. En tercer lugar, combina cinco frameworks de AutoML con un módulo de modelado clásico optimizado, contrastando soluciones automatizadas frente a optimización manual y seleccionando el modelo final con criterios operativos de interpretabilidad y eficiencia. En cuarto lugar, profundiza en la dimensión ética: aplica interpretabilidad multimétodo (SHAP, LIME y DiCE) y métricas de equidad algorítmica sobre atributos protegidos, garantizando que el modelo no reproduzca ni amplifique sesgos estructurales presentes en los datos históricos. Adicionalmente, el proyecto culmina con una aplicación Streamlit institucional desplegada que permite la transferencia operativa del conocimiento generado a los equipos de gestión académica de la Universitat Jaume I.



El detalle metodológico de cómo se han implementado estas decisiones —desde el origen y la preparación de los datos hasta la selección del modelo final— se desarrolla en el siguiente capítulo.

3. Materiales y Métodos

En el presente capítulo se describe la metodología seguida en el desarrollo del trabajo, desde la obtención de los datos originales hasta el despliegue final del modelo predictivo en una aplicación web. La estructura del capítulo refleja la organización modular del proyecto en siete fases secuenciales (F0 a F7), complementadas con un módulo transversal de validación competitiva mediante AutoML (Fase 3.5). Cada sección documenta tanto las decisiones técnicas adoptadas como su justificación metodológica, en coherencia con los principios de reproducibilidad y trazabilidad institucional descritos en el capítulo 1.

3.1. Conjunto de datos

3.1.1. Origen institucional

El presente trabajo se fundamenta en datos académicos administrativos cedidos por la Universitat Jaume I (UJI), facilitados por el Gabinete de Planificación y Prospectiva y la Unidad de Análisis y Desarrollo en Tecnologías de la Información (UADTI). Esta procedencia institucional garantiza tanto la fiabilidad de los datos como su pleno alineamiento con los criterios académicos de la universidad.

El conjunto de datos abarca el periodo comprendido entre los cursos 2010-2011 y 2020-2021, ambos incluidos. Esta delimitación temporal de once cursos coincide con la implantación del Plan Bolonia en la UJI y se justifica por la necesidad de disponer de volumen suficiente para entrenar modelos predictivos robustos, garantizando que los datos reflejen la estructura curricular vigente.

3.1.2. Estructura del dataset original

Los datos originales se distribuyen en nueve tablas relacionales que recogen información heterogénea sobre los expedientes académicos del estudiantado: becas, demograficos, domicilios, expedientes, notas, preinscripcion, recibos, titulaciones y trabajo. La integración y consolidación de estas tablas se aborda en la sección 3.3, mediante un pipeline de limpieza y unión relacional documentado y reproducible.

3.1.3. Datasets canónicos del proyecto

A lo largo del flujo del proyecto se generan dos datasets canónicos diferenciados. Por un lado, el dataset longitudinal limpio (`df_alumno_limpio.parquet`, 109.568×43), salida de la Fase 1 y descrito en la sección 3.3, que conserva la granularidad anual del registro académico original. Por otro, el dataset modelable a nivel de unidad (estudiante, titulación) (`dataset_final_tfm.parquet`, 33.621×25), salida de la Fase 3 y descrito en la sección 3.5, que constituye el insumo directo del modelado supervisado.

El dataset modelable contiene 33.621 registros académicos correspondientes a 30.872 personas estudiantes únicas. La diferencia entre ambas cifras (2.749 registros, 8,17 % del total) se explica por las matrículas múltiples: estudiantado que ha iniciado estudios en más de una titulación durante el periodo analizado, ya sea por cambio de plan, compatibilización simultánea o reingreso tras un abandono previo.

Esta circunstancia se ha considerado de forma explícita en el diseño metodológico, dado que cada combinación (estudiante, titulación) constituye una unidad de análisis independiente desde el punto de vista del riesgo de abandono. Asumir esta unidad es coherente con la propuesta teórica de Tinto (1975, 1993), retomada por Himmel (2002), según la cual la integración académica del alumnado se produce de forma específica en cada titulación.

El dataset cubre 40 titulaciones de grado de la UJI, agrupadas en cinco ramas de conocimiento: Artes y Humanidades (HU), Ciencias (EX), Ciencias de la Salud (SA), Ciencias Sociales y Jurídicas (SO) e Ingeniería y Arquitectura (TE).

3.1.4. Variable objetivo y desbalance de clases

La variable objetivo abandono se ha codificado de forma binaria: 0 si el estudiantado continúa matriculado activamente o ha finalizado los estudios con éxito; 1 si interrumpe la matriculación sin completar la titulación durante el horizonte de observación, sin reingreso documentado.

La definición adoptada es coherente con el modelo de Himmel (2002) presentado en el capítulo 2, considerando tanto la deserción voluntaria como la involuntaria. Asimismo, se asume el criterio operativo extendido en la literatura: se considera abandono cuando el estudiantado no se vuelve a matricular durante dos cursos consecutivos en la misma titulación y universidad.

La distribución de clases evidencia el carácter desbalanceado del problema, característico de los estudios de abandono universitario (Araque et al., 2009; Lacave et al., 2016): un 70,75 % del estudiantado se clasifica como no abandono frente al 29,25 % que sí abandonó. Esta proporción se mantiene de forma equivalente en los conjuntos de entrenamiento y test tras la división estratificada (sección 3.8).

La tasa global del 29,25 % se sitúa por encima de la media nacional reportada por el Ministerio de Universidades (2022), aproximadamente del 13 %. Esta diferencia se explica por la ampliación de la ventana temporal del presente estudio y por la consideración del abandono a nivel de titulación, que captura los cambios dentro de la propia UJI. Este desbalance ha condicionado tanto la selección de métricas (sección 3.8.4) como la exploración de tres estrategias de manejo del desbalance (sección 3.8.2).

3.2. Arquitectura del proyecto y flujo de trabajo

3.2.1. Diseño metodológico modular

El proyecto se ha organizado en siete fases secuenciales, cada una autocontenida pero integrada con las demás mediante datasets canónicos en formato Apache Parquet. Esta arquitectura modular persigue tres objetivos: garantizar la reproducibilidad completa del pipeline, facilitar la auditoría independiente de cada etapa y permitir la reejecución selectiva de fases sin recalcular el resto.

Las siete fases con sus salidas principales son:

Fase 0 — Configuración: definición de constantes, rutas, parámetros globales y entorno computacional.

Fase 1 — Transformación: limpieza de las nueve tablas Excel originales e integración relacional. Salida: `df_alumno_limpio.parquet` (109.568 × 43).

Fase 2 — Análisis exploratorio inicial: auditoría de calidad y diagnóstico previo a la construcción de variables.

Fase 3 — Ingeniería de variables: reducción a unidad (estudiante, titulación) y construcción de variables derivadas. Salida: `dataset_final_tfm.parquet` (33.621 × 25).

Fase 3.5 — Validación AutoML: baseline objetivo mediante cinco frameworks de aprendizaje automático automatizado, complementados con un módulo de baselines clásicos.

Fase 4 — Análisis exploratorio del target: bivalente con la variable objetivo y construcción de perfiles de riesgo.

Fase 5 — Modelado clásico supervisado: 69 combinaciones de algoritmo y estrategia de manejo del desbalance.

Fase 6 — Evaluación e interpretabilidad: selección dinámica del modelo ganador, SHAP, LIME, DiCE, equidad, robustez, calibración y sostenibilidad.

Fase 7 — Aplicación y despliegue: integración del modelo en una aplicación web Streamlit pública.

Esta estructura modular se articula con la metodología KDD (Knowledge Discovery in Databases) descrita en el capítulo 1: cada fase es una concreción operativa de las cinco etapas KDD —selección de datos (F1), preprocesamiento (F1-F2), transformación (F3), data mining (F5-F6) e interpretación y evaluación (F6).

La Ilustración 13 sintetiza visualmente esta arquitectura, mostrando la secuencia de fases, los datasets canónicos producidos como interfaces entre ellas, las dependencias del modelo dinámico de la fase 6, el producto desplegado como salida del proceso, y la correspondencia con las cinco etapas de la metodología KDD.




Ilustración 8.Arquitectura modular del proyecto

La arquitectura del proyecto se articula en siete fases secuenciales con datasets canónicos en formato Apache Parquet (`df_alumno_limpio` y `dataset_final_tfm`). La validación competitiva se realiza mediante AutoML en la Fase 3.5; la evaluación e interpretabilidad se consolidan en la Fase 6; y el producto institucional se despliega como aplicación Streamlit pública en la Fase 7. La banda inferior establece la correspondencia con las cinco etapas de la metodología KDD (Fayyad et al., 1996). La URL mostrada en el diagrama corresponde a la versión inicial estática; la versión dinámica de referencia para este TFM se describe en la sección 3.13.

3.2.2. Reproducibilidad y trazabilidad

La reproducibilidad se ha garantizado mediante cinco mecanismos públicos y verificables: control de versiones con Git en repositorio público (https://github.com/mortemj/AU_UJI); cinco entornos conda aislados con sus `requirements.txt` versionados; documentación HTML auto-generada de cada notebook (95 documentos publicados en https://mortemj.github.io/AU_UJI/); datasets canónicos en formato Parquet entre fases; y dos aplicaciones desplegadas en producción: una versión inicial estática (<https://tfm-abandono.streamlit.app/>) basada en el modelo Stacking del primer estudio, y una versión dinámica final (<https://tfm-abandono-dinamico.streamlit.app/>), que permite la sustitución del dataset y, en consecuencia, actualiza el modelo ganador y todas las

métricas de forma automática. Esta arquitectura dinámica se validó en el propio desarrollo: cuando la variable `orden_preferencia` se corrigió de un rango erróneo (1-3) al rango correcto (1-20), el sistema reseleccionó automáticamente el modelo ganador (de Stacking a LightGBM) sin intervención manual.

La trazabilidad institucional del proyecto se completa con su documentación en el Sistema de Gestión Documental de la UJI mediante Confluence, garantizando la revisión por expertos y la transferencia del conocimiento generado, en coherencia con los principios de sostenibilidad y compromiso institucional descritos en el capítulo 1.

3.3. Preprocesado y limpieza (Fase 1)

3.3.1. Volumetría inicial

La Fase 1 transforma los datos originales facilitados por la UJI en formato Excel hasta un dataset relacional consolidado y validado. La tabla principal expedientes contiene 109.568 registros tras la unión inicial. El volumen relativamente alto respecto al número de personas estudiantes únicas (30.872) refleja la naturaleza longitudinal del registro: cada fila representa una matrícula anual, no un estudiante. Esta granularidad longitudinal se conserva durante la Fase 1 y se reduce posteriormente en la Fase 3, siguiendo el principio metodológico de no perder información antes de tiempo.

3.3.2. Pipeline de limpieza

El proceso de limpieza se estructura en seis módulos secuenciales con responsabilidades bien delimitadas: `f1_m01` genera informes de calidad sobre datos sin procesar (tipos, rangos, valores ausentes, duplicados); `f1_m02` aplica transformaciones documentadas (eliminación de duplicados, normalización de tipos, corrección de codificaciones); `f1_m03` produce informes post-limpieza con comparación contra los reportes originales para verificar ausencia de regresiones; `f1_m04a` realiza la unión relacional de las nueve tablas con auditoría explícita de registros perdidos; `f1_m04b` integra la información de preinscripción (clave para `orden_preferencia`); y `f1_m04c` y `f1_m04d` corrigen inconsistencias detectadas en calificaciones y vía de acceso, respectivamente. Cada módulo produce su propio informe HTML auto-generado.

3.3.3. Tratamiento de valores ausentes

El tratamiento de valores ausentes se realiza de forma diferenciada según la naturaleza de cada variable. Para las variables que codifican información estructuralmente ausente (calificaciones de selectividad en estudiantado que accedió por otra vía, etc.), se generan tres indicadores binarios `_missing` que se incorporan al dataset modelable como variables adicionales. Esta estrategia preserva la información sobre la propia ausencia, frecuentemente correlacionada con el fenómeno bajo estudio.

Para las variables con valores ausentes no estructurales se aplican imputaciones basadas en mediana (numéricas) o moda (categóricas), siempre ajustadas exclusivamente sobre el conjunto de entrenamiento para evitar fuga de información (data leakage) hacia el conjunto de test. Esta separación se implementa mediante el pipeline de preprocesamiento descrito en la sección 3.8.

3.3.4. Salida de la fase

El producto final de la Fase 1 es `df_alumno_limpio.parquet`, con dimensiones 109.568×43 , insumo principal de las fases posteriores de análisis exploratorio (Fase 2) e ingeniería de variables (Fase 3). Asimismo, la fase genera dos productos auxiliares para la trazabilidad institucional: un dashboard interactivo (`f1_m05_dashboard.html`) y un grafo de dependencias (`f1_m06_grafo.html`) que documenta gráficamente las relaciones entre las nueve tablas originales.

3.4. Análisis exploratorio inicial (Fase 2)

3.4.1. Objetivos

La Fase 2 realiza un análisis exploratorio sistemático del dataset consolidado en la Fase 1 con tres objetivos: diagnosticar la calidad de los datos, caracterizar la distribución de las variables y detectar patrones temporales asociados a las once cohortes analizadas. Esta fase tiene carácter descriptivo-exploratorio, no inferencial; las hipótesis sobre factores de riesgo se contrastan posteriormente en las secciones 3.6 y 3.8.

3.4.2. Estructura modular del análisis

El análisis se organiza en siete módulos: f2_m01 inspección estructural; f2_m02 auditoría de calidad (duplicados, valores fuera de rango, inconsistencias); f2_m03 análisis específico de patrones de valores ausentes (estructurales vs no estructurales); f2_m04 análisis univariante numérico (distribuciones, asimetría, percentiles, outliers); f2_m05 análisis univariante categórico (cardinalidades, frecuencias); f2_m06 análisis de evolución temporal con visualizaciones interactivas mediante Altair; y f2_m07 síntesis de hallazgos con recomendaciones para la Fase 3.

3.4.3. Hallazgos principales

El análisis exploratorio identificó cuatro hallazgos que han condicionado decisiones metodológicas posteriores: variables con valores ausentes estructurales (que motivaron los flags `_missing` de la sección 3.3.3); heterogeneidad temporal en la distribución de algunas variables a lo largo de las once cohortes (que motivó la estratificación train/test de la sección 3.8.3); cardinalidades elevadas en variables categóricas como `titulacion` (40 categorías), que motivaron la creación de la variable agregada `rama` y la exclusión de `titulacion` del modelo por riesgo de leakage; y distribuciones asimétricas en variables académicas, que orientaron la selección de algoritmos robustos a esta característica.

3.4.4. Productos generados

La Fase 2 produce diez informes HTML auto-generados accesibles desde https://mortemj.github.io/AU_UJI/docs/html/fase2/. Esta fase no genera nuevos datasets modelables dado su carácter exploratorio; la consolidación del dataset modelable se aborda en la Fase 3 (sección 3.5).

3.5. Ingeniería de variables (Fase 3)

3.5.1. Reducción a la unidad de análisis

La Fase 3 transforma el dataset longitudinal de la Fase 1 (109.568 registros a nivel de matrícula anual) en un dataset modelable a nivel de unidad de análisis (estudiante, titulación), con 33.621 registros. Esta reducción no constituye pérdida de información sino una reorganización estructural

que sintetiza el historial completo del estudiantado en cada titulación a un único registro consolidado, adecuado para el problema de clasificación binaria supervisada.

La unidad (estudiante, titulación) se ha definido siguiendo a Tinto (1975, 1993) y Himmel (2002): el abandono se conceptualiza como un fenómeno específico de cada titulación, donde el riesgo emerge de la interacción entre el estudiantado y el contexto académico concreto. Por ello, una persona que cambia de titulación dentro de la propia UJI se considera, desde el punto de vista del modelo, como dos unidades de análisis independientes con riesgo de abandono potencialmente diferenciado.

3.5.2. Construcción de variables derivadas

Las variables derivadas se han diseñado a partir de la literatura previa (Araque et al., 2009; Lacave et al., 2016; Fernández-Mellizo, 2022) y de los hallazgos del análisis exploratorio inicial. Entre las más relevantes destacan: *cred_repetidos* (créditos en los que el estudiantado se ha matriculado en más de una ocasión); *tasa_repeticion* (ratio entre repetidos y matriculados totales); *n_anios_trabajando* (cursos con situación laboral activa, dimensión socioeconómica); *n_anios_sin_notas* (indicador de desconexión académica progresiva); *tasa_abandono_titulacion* (tasa histórica de la titulación, variable contextual que sustituye a la variable nominal *titulacion* excluida del modelo); *cupo* (modalidad de admisión); y *orden_preferencia* (*posición de la titulación cursada en las preferencias de preinscripción, dimensión motivacional clave; incorporada en la V2.0 del dataset tras una reextracción institucional que corrigió las inconsistencias detectadas en la versión inicial — véase sección 3.9.3*)

3.5.3. Variables descartadas y justificación

Se han descartado de forma deliberada algunas variables candidatas. La variable *titulacion* se ha excluido por dos razones: su elevada cardinalidad (40 categorías) generaría una matriz codificada extremadamente dispersa con un número reducido de registros por clase, y su correlación directa con *tasa_abandono_titulacion* introduce un riesgo de leakage. Se mantiene únicamente *rama* (cinco categorías agregadas) y la variable contextual *tasa_abandono_titulacion*. Adicionalmente, *tuvo_beca* se descartó por redundancia con *n_anios_beca*, y *pago_fraccionado* por su escaso poder discriminativo en los análisis bivariantes preliminares.

3.5.4. Dataset modelable final

El producto final es `dataset_final_tfm.parquet` (33.621×25), insumo único de las fases posteriores. Tras la codificación de variables categóricas y la incorporación de los tres indicadores `_missing`, el conjunto efectivo de inputs técnicos al modelo asciende a 27 variables (24 derivadas + 3 flags). Las 24 variables se agrupan en ocho académicas, cuatro demográficas, cuatro socioeconómicas, tres administrativas, tres de rendimiento, una contextual y una de origen académico. El detalle completo se incluye en el Anexo C.

3.6. Análisis exploratorio del target (Fase 4)

3.6.1. Objetivos

La Fase 4 realiza el análisis exploratorio bivalente del dataset modelable, centrándose en la relación entre cada feature y la variable objetivo abandono. A diferencia de la Fase 2 (univariante y descriptiva), esta fase incorpora una perspectiva bivalente e inferencial. Sus objetivos son: caracterizar el target identificando patrones de abandono por subgrupos (rama, sexo, vía de acceso); cuantificar la relación bivalente feature-target mediante estadísticos apropiados; y construir perfiles de riesgo que sintetizan los hallazgos.

3.6.2. Estructura modular y enfoque metodológico

El análisis se organiza en nueve módulos: `f4_m01` inspección del dataset post-Fase 3; `f4_m02` análisis específico del target abandono; `f4_m03` y `f4_m04` distribuciones numéricas y categóricas vs target; `f4_m05` tests estadísticos sistemáticos; `f4_m06` matriz de correlación; `f4_m07` propuesta de selección de variables; `f4_m08` perfiles de riesgo; y `f4_m09` conclusiones para la Fase 5.

El análisis bivalente sigue un enfoque coherente con la naturaleza de cada par de variables. Para las numéricas, dada la asimetría detectada en la Fase 2, se opta por estadísticos no paramétricos (prueba U de Mann-Whitney), garantizando robustez frente a desviaciones de la normalidad. Para las categóricas se aplica chi-cuadrado de Pearson, complementada con el estadístico V de Cramer. El análisis de correlaciones utiliza el coeficiente de Spearman por su robustez frente a relaciones no lineales y valores atípicos.

3.6.3. Productos generados

La Fase 4 produce informes HTML auto-generados con visualizaciones interactivas de elevada riqueza visual, publicados en https://mortemj.github.io/AU_UJI/docs/html/fase4. Los hallazgos cuantitativos específicos derivados de este análisis se presentan en la sección 4.2 del capítulo de Resultados.

3.7. Validación competitiva con AutoML (Fase 3.5)

3.7.1. Justificación

La Fase 3.5 introduce un módulo transversal de validación competitiva con AutoML, situado entre la ingeniería de variables (Fase 3) y el modelado clásico (Fase 5). Esta ubicación responde al objetivo metodológico de establecer un baseline objetivo que el modelado clásico deba superar para justificar su elección frente a soluciones automatizadas. La fase persigue tres finalidades: auditar el dataset modelable mediante herramientas externas, establecer un suelo de rendimiento sin intervención manual, y justificar la inversión metodológica de la Fase 5.

3.7.2. Frameworks evaluados

Se han evaluado cinco frameworks AutoML, complementados con un módulo de baselines clásicos, por su representatividad en el panorama actual del aprendizaje automático automatizado: LazyPredict, PyCaret, H2O AutoML, AutoGluon y TabPFN v2. Este último —modelo fundacional para datos tabulares (Hollmann et al., 2024)— constituye una incorporación metodológica reciente al estudio del abandono universitario, basada en una arquitectura transformer preentrenada que permite obtener predicciones competitivas sin necesidad de afinado de hiperparámetros, lo que justifica su inclusión como contraste frente a los enfoques AutoML tradicionales. Como referencia complementaria se ha ejecutado además un módulo de baselines clásicos (clasificador de mayoría y regresión logística básica). Cada framework se ha desplegado en un entorno conda independiente para evitar conflictos de dependencias. El detalle técnico se incluye en el Anexo D.

3.7.3. Métrica y proceso

Todos los frameworks se han evaluado sobre el mismo conjunto de test, con las mismas métricas que la Fase 5 (AUC-ROC, F1, Precision, Recall, Accuracy). Esta unificación garantiza la validez

metodológica de la comparación posterior. El framework con mejor rendimiento se identifica como baseline de referencia para la Fase 5. Los resultados detallados se presentan en la sección 4.1.

3.8. Modelado clásico supervisado (Fase 5)

3.8.1. Diseño experimental

La Fase 5 entrena y evalúa sistemáticamente un conjunto amplio de algoritmos de clasificación supervisada con el objetivo de identificar el modelo más adecuado para el problema. El diseño se estructura como factorial 2D: 23 algoritmos $\times$ 3 estrategias de manejo del desbalance, dando lugar a 69 combinaciones únicas. Los 23 algoritmos se organizan en seis familias: Lineales (regresión logística, LDA, SGD, perceptrón, SVM lineal); Árboles (decision tree, random forest, extratrees); Boosting (AdaBoost, gradient boosting, XGBoost, LightGBM, CatBoost); Ensamblados (bagging, stacking, voting); MLP+EBM (perceptrón multicapa y explainable boosting machine); y Otros (k-NN, SVM RBF, naive Bayes). Esta organización por familias responde al principio de diversidad algorítmica.

3.8.2. Estrategias de manejo del desbalance

Cada algoritmo se entrena con tres estrategias diferenciadas: sin tratamiento (none), pesos balanceados (balanced, mediante `class_weight='balanced'` o equivalente), y SMOTE (sobremuestreo sintético de la clase minoritaria mediante interpolación lineal entre vecinos próximos, Chawla et al., 2002). La exploración sistemática de las tres estrategias responde al principio de no asumir a priori cuál es óptima: la respuesta depende del algoritmo y de la métrica priorizada.

3.8.3. División train/test y validación cruzada

El dataset se divide mediante split estratificado 80/20, conservando la proporción de clases (70,75 %/29,25 %) en ambos subconjuntos. El conjunto de entrenamiento contiene 26.896 personas estudiantes y el de test 6.725. Sobre el entrenamiento se aplica validación cruzada estratificada de 5 folds. Todo el preprocesamiento se implementa mediante un Pipeline de scikit-learn ajustado exclusivamente sobre entrenamiento, evitando fuga de información.

Cabe matizar que el conjunto de test contiene 129 personas estudiantes (1,9 %) que iniciaron sus estudios en el curso 2009-2010, justo en el límite inferior del periodo de análisis declarado (cursos 2010-2011 a 2020-2021). Esta inclusión residual se explica por la implantación progresiva del Plan Bolonia en la Universitat Jaume I durante el curso 2009-2010 y no compromete la validez de los resultados, dado el escaso volumen relativo y su distribución equilibrada respecto a las cohortes posteriores. La sección 4.5 del Capítulo 4 reporta las métricas finales del modelo seleccionado tanto sobre el conjunto de test completo ($n = 6.725$) como sobre el subconjunto filtrado a cohortes ≥ 2010 ($n = 6.596$), siendo la divergencia entre ambos valores marginal ($\Delta AUC < 0,0005$, $\Delta F1 < 0,002$) y no alterando ni la jerarquía de modelos ni la decisión final de selección. Esta nota de transparencia metodológica se complementa con el detalle adicional aportado en el Anexo A.

3.8.4. Métricas de evaluación

La selección de métricas considera el carácter desbalanceado del problema y, sobre todo, el coste asimétrico de los errores: un falso negativo (estudiante en riesgo no detectado) implica pérdida de oportunidad de intervención preventiva, mientras que un falso positivo implica un coste menor de seguimiento. Las cinco métricas utilizadas son: AUC-ROC (capacidad discriminativa global, robusta al desbalance); F1-score (media armónica entre precisión y recall); Precisión (control de falsos positivos); Recall (control de falsos negativos); y Accuracy. El criterio de selección del modelo ganador se basa en F1 sobre test, con desempate por Recall, asumiendo el coste asimétrico mencionado. Este criterio se concreta en el sistema dinámico de la sección 3.9.

3.8.5. Resultados de la fase

Los resultados detallados de los 69 modelos se sintetizan en el ranking maestro resultados_maestro.parquet. En el cuerpo de esta memoria, en la sección 4.3, se presentan los tres modelos con mejor rendimiento acompañados de un resumen del top-10. El ranking completo —incluyendo hiperparámetros utilizados y métricas de los cinco indicadores— se incluye en el Anexo A, siguiendo el principio editorial de mantener el cuerpo centrado en lo esencial.

3.9. Sistema dinámico de selección del modelo ganador (Fase 6/m00)

3.9.1. Filosofía del diseño

Una de las contribuciones metodológicas del trabajo es el diseño de un sistema dinámico de selección del modelo ganador implementado en `f6_m00_preparacion`. Este sistema se aleja del enfoque tradicional —en el que la persona investigadora selecciona manualmente un modelo concreto— y adopta un enfoque basado en reglas explícitas que se aplican automáticamente sobre el ranking de la Fase 5.

La motivación es triple: eliminar el sesgo subjetivo en la selección (el ganador no es el preferido por el personal investigador, sino el que satisface objetivamente unos criterios definidos a priori); garantizar la reproducibilidad y auditabilidad (el criterio está documentado y puede aplicarse de forma idéntica por terceras personas); y garantizar la robustez del sistema ante cambios en el dataset (incorporación de nuevas cohortes o variables relevantes en el futuro).

3.9.2. Criterio operativo

El sistema implementa un criterio jerárquico: criterio principal por F1-score sobre test en orden descendente; desempate por Recall sobre test (en caso de diferencias menores a 0,001 en F1), justificado por el coste asimétrico de los falsos negativos; y validación adicional consistente en superar el AUC-ROC del baseline AutoML, descartando el modelo y seleccionando el siguiente en caso contrario.

El resultado se persiste en `metricas_modelo.json`, que actúa como fuente única de verdad para todos los módulos posteriores: la aplicación Streamlit, los notebooks de interpretabilidad y los informes integradores leen este JSON, evitando hardcodes del modelo concreto en el código.

3.9.3. Validación del diseño: el caso del cambio de modelo ganador

El diseño dinámico ha sido validado de forma natural durante el propio desarrollo. En una iteración inicial, sin la variable `orden_preferencia` incorporada al dataset, el sistema seleccionó como modelo ganador un Stacking ensamblado (CatBoost + Random Forest + Regresión Logística), con resultados notables (AUC = 0,954; F1 = 0,827).

El origen del reajuste merece una aclaración metodológica. En la versión inicial del dataset (V1.0), la variable `orden_preferencia` —orden en que la persona estudiante había solicitado la titulación durante el proceso de preinscripción— presentaba inconsistencias atribuibles a la extracción original desde el almacén de datos institucional. Detectada la incidencia, se solicitó una nueva extracción corregida y, una vez verificada la fiabilidad del dato, la variable se incorporó al dataset en la V2.0 de forma simultánea al rediseño del sistema dinámico de selección. Es esta incorporación la que provocó el cambio de modelo ganador descrito a continuación, lo que ilustra cómo una mejora en la calidad del dato puede modificar las conclusiones del modelado sin necesidad de intervención manual sobre el pipeline.

Tras incorporar `orden_preferencia` (sección 3.5.2) y reejecutar la pipeline, el sistema reseleccionó automáticamente LightGBM con estrategia `none`, alcanzando resultados ligeramente superiores ($AUC = 0,956$; $F1 = 0,833$). Este reajuste no constituye intervención manual sino la respuesta esperada del sistema dinámico ante la mejora del dataset.

Más allá de la mejora cuantitativa marginal, LightGBM aporta tres ventajas operativas frente al Stacking inicial: mayor interpretabilidad (modelo único frente a ensamble apilado), mayor eficiencia computacional (entrenamiento aproximadamente diez veces más rápido), y trazabilidad simplificada. Este caso ilustra que el diseño dinámico no es un mero formalismo metodológico sino una propiedad funcional del sistema que aporta valor real ante la evolución natural del dataset.

3.10. Interpretabilidad del modelo (Fase 6/m01-m02)

3.10.1. Necesidad de interpretabilidad en ML educativo

En la predicción del abandono universitario, la interpretabilidad no constituye un atributo opcional sino un requisito metodológico y ético ineludible. Como argumentan Doshi-Velez y Kim (2017), las decisiones automatizadas que afectan a personas en contextos sensibles —como la detección temprana de riesgo académico— deben ser explicables para garantizar la transparencia frente al estudiantado afectado y permitir que el personal académico contraste las conclusiones del modelo con su conocimiento experto.

3.10.2. SHAP, LIME y DiCE

SHAP (Lundberg y Lee, 2017) constituye el método principal de interpretabilidad, basado en la teoría de juegos cooperativos para asignar a cada variable una contribución específica a la predicción individual. Sobre el modelo ganador se aplican tres niveles: SHAP global (importancia agregada en test), SHAP local (explicaciones individuales mediante waterfall y force plots), y SHAP por cohortes (segmentado por rama, situación laboral y otros subgrupos institucionalmente relevantes).

LIME (Ribeiro et al., 2016) se aplica como técnica complementaria para validar la consistencia de las explicaciones individuales mediante un enfoque metodológicamente diferente, aportando una capa adicional de robustez.

DiCE (Mothilal et al., 2020) genera explicaciones contrafactuales que responden a la pregunta crítica desde el punto de vista institucional: ¿qué cambios en el perfil del estudiantado modificarían la predicción? Esta perspectiva accionable resulta particularmente relevante para los servicios de orientación académica.

3.11. Análisis de equidad algorítmica (Fase 6/m03)

3.11.1. Marco metodológico y atributos protegidos

El análisis de equidad algorítmica constituye uno de los puntos diferenciales del trabajo, en consonancia con la creciente necesidad de auditar modelos de machine learning aplicados al ámbito educativo (Kizilcec y Lee, 2022). Su objetivo es detectar sesgos sistemáticos en las predicciones del modelo respecto a atributos protegidos, alineándose con los Objetivos de Desarrollo Sostenible 5 (igualdad de género) y 10 (reducción de desigualdades).

Se han considerado cinco atributos protegidos: sexo (binario hombre/mujer); beca (dimensión socioeconómica, codificada como `n_anios_beca`); vía de acceso (convencionales vs no convencionales); rama de conocimiento (cinco ramas UJI); y situación laboral (trabajadores vs no trabajadores).

3.11.2. Métricas de equidad utilizadas

Se han evaluado cuatro métricas complementarias ampliamente reconocidas en la literatura especializada (Mehrabi et al., 2021): Demographic Parity Difference (DPD, diferencia en la tasa de predicción positiva entre subgrupos); Equal Opportunity (EqOpp, diferencia en el recall entre subgrupos); Equalized Odds (EOD, diferencia conjunta en TPR y FPR); y Disparate Impact Ratio (DIR, ratio entre la tasa de predicción positiva del subgrupo desfavorecido y el favorecido, con umbral del $4/5 = 0,80$). Para cada métrica se calcula también un análisis interseccional (combinaciones como mujeres becadas u hombres no becados) que permite detectar sesgos no visibles en el análisis unidimensional. Las definiciones formales se incluyen en el Anexo E.

Complementariamente se realiza un análisis de errores por subgrupo (f6_m03b_errores_fpf), examinando la distribución de falsos positivos y falsos negativos en cada combinación de atributos protegidos.

3.12. Robustez, calibración y sostenibilidad (Fase 6/m04)

El módulo f6_m04a_stress somete al modelo a perturbaciones controladas del conjunto de test — ruido gaussiano en variables numéricas, valores ausentes artificiales, outliers extremos— para cuantificar la degradación de su rendimiento en condiciones adversas. El módulo f6_m04b_calibracion evalúa si las probabilidades predichas son fiables como estimaciones reales del riesgo mediante reliability diagram y Brier score, e identifica el umbral óptimo de clasificación dado que la tasa del 29,25 % desplaza el umbral natural del 50 %. Siguiendo los principios de Green AI (Schwartz et al., 2020) y en coherencia con el ODS 13 (acción climática), el módulo f6_m04c_sostenibilidad cuantifica la huella de carbono del entrenamiento e inferencia del modelo ganador mediante codecarbon, permitiendo identificar la combinación óptima entre rendimiento predictivo y coste energético.

3.13. Aplicación Streamlit (Fase 7)

3.13.1. Arquitectura de la aplicación

La fase final materializa el modelo ganador en dos aplicaciones web públicas desarrolladas con Streamlit: una versión inicial estática (<https://tfm-abandono.streamlit.app/>), correspondiente al modelo Stacking del primer estudio sin posibilidad de cambio de dataset, y una versión dinámica final (<https://tfm-abandono-dinamico.streamlit.app/>), que permite la sustitución del dataset y actualiza automáticamente el modelo ganador y las métricas. La aplicación está diseñada con un enfoque centrado en los perfiles de usuario, organizándose en siete páginas: p00 Inicio (presentación general y métricas globales); p01 Vista institucional (dashboard con KPIs agregados orientado a dirección y vicerrectorado); p02 Análisis por titulación (40 titulaciones con indicadores específicos); p03 Pronóstico de prospecto (estimación previa a la matriculación); p04 Alumnado en curso (análisis individualizado con monitorización de riesgo); p05 Análisis de equidad (transparencia algorítmica con métricas de fairness); y p06 Guía semántica y transparencia (paleta de colores, métricas del modelo, marco ético-legal y glosario de términos).

3.13.2. Casos de uso por perfil

Cada página responde a un caso de uso institucional específico: el Vicerrectorado de Estudiantes consulta p01 para evaluar la evolución agregada del abandono; la coordinación de titulación consulta p02 para identificar particularidades de su titulación; el servicio de orientación al estudiantado utiliza p03 (prospecto) y p04 (en curso) para apoyar la atención preventiva; y las tutorías académicas consultan p04 con interpretaciones SHAP individuales para guiar la conversación con el alumnado.

3.13.3. Despliegue y mantenimiento

La aplicación se ha desplegado en Streamlit Cloud, con código versionado en el repositorio público y actualización automática por integración continua. Las dependencias se gestionan mediante requirements.txt. Esta arquitectura permite el mantenimiento sostenible de la aplicación a coste cero, aspecto relevante desde la viabilidad institucional del producto.

3.14. Herramientas y entorno técnico

El proyecto se ha desarrollado íntegramente en Python 3.11. Las librerías utilizadas se agrupan según funcionalidad: pandas, numpy y pyarrow (manipulación de datos); scikit-learn, LightGBM, XGBoost, CatBoost e interpret (modelado clásico); pycaret, h2o, autogluon, lazypredict y tabpfn (AutoML); shap, lime, dice-ml y shapash (interpretabilidad); codecarbon (sostenibilidad); matplotlib, seaborn, plotly y altair (visualización); y streamlit (aplicación web). Se prevé el uso de lifelines para la futura ampliación con análisis de supervivencia.

Se han definido cinco entornos conda independientes: tfm_abandono (entorno principal) y env_pycaret, env_h2o, env_autogluon y env_lazypredict (auxiliares para frameworks AutoML). Cada entorno mantiene su requirements.txt versionado. La lista completa de versiones se incluye en el Anexo F.

El tratamiento de datos personales se ha realizado en cumplimiento del Reglamento General de Protección de Datos (RGPD) y la Ley Orgánica 3/2018. Los datos cedidos por la UJI se han trabajado en formato anonimizado, sin posibilidad de identificación individual del estudiantado. El proyecto se documenta íntegramente en el Sistema de Gestión Documental de la UJI mediante Confluence.

Los resultados obtenidos al aplicar esta metodología sobre el conjunto de datos descrito —desde el comportamiento global de los modelos hasta el análisis interpretativo del modelo ganador y su evaluación en términos de equidad, robustez y sostenibilidad— se presentan en el siguiente capítulo.

4. Resultados

El presente capítulo recoge los resultados obtenidos en cada una de las fases metodológicas descritas en el capítulo anterior. Se organiza en diez secciones que reflejan, de forma progresiva, el camino recorrido desde la exploración inicial de los datos hasta la evaluación de la equidad del modelo final y la implementación de la herramienta de soporte. El propósito es ofrecer una visión integral del rendimiento del sistema predictivo, justificar las decisiones técnicas tomadas y exponer con transparencia las limitaciones encontradas, en línea con los principios éticos del marco UNESCO para la inteligencia artificial (UNESCO, 2021).

4.1. Resultados del análisis exploratorio inicial (Fase 2)

El análisis exploratorio realizado sobre el dataset original (109.568 registros × 37 variables) permitió caracterizar el universo objeto de estudio antes de cualquier transformación. Se identificaron 30.872 personas estudiantes únicas matriculadas entre los cursos académicos 2010-2011 y 2020-2021 en las 40 titulaciones de grado activas de la Universitat Jaume I, distribuidas en cinco ramas de conocimiento.

El examen de calidad reveló una estructura de datos limpia para las variables académicas y demográficas, con presencia de valores ausentes concentrados principalmente en las notas de acceso y selectividad para las vías de acceso no convencionales (Adaptación a Grado, Traslado, Titulados Universitarios), un fenómeno coherente con la heterogeneidad documental de cada perfil de entrada. Asimismo, se constató que la distribución temporal de matrículas presentaba un sesgo natural hacia las cohortes más recientes, derivado del crecimiento sostenido de la oferta académica de la institución durante el período analizado.

El análisis temporal puso de manifiesto la necesidad metodológica de considerar la censura derecha en el seguimiento de las cohortes más recientes (2018-2020): el alumnado matriculado en estos años no ha dispuesto del tiempo suficiente para que el evento de abandono se manifieste plenamente, lo que justificará posteriormente la propuesta de un análisis de supervivencia

mediante el estimador de Kaplan-Meier (Kaplan & Meier, 1958) como línea de ampliación del trabajo.

4.2. Resultados del análisis dirigido al abandono (Fase 4)

Sobre el dataset preparado para modelado (33.621 registros × 25 variables), se realizó un análisis exploratorio orientado a caracterizar la variable objetivo y sus relaciones con las variables candidatas. La tasa global de abandono se sitúa en el 29,25 %, lo que confirma un desbalance moderado entre las clases (70,75 % de no abandono frente a 29,25 % de abandono) que requerirá ser gestionado en la fase de modelado.

4.2.1. Tasas de abandono por subgrupos

La descomposición del abandono por rama de conocimiento revela diferencias estadísticamente significativas que orientan la interpretabilidad posterior del modelo. La Tabla 4.1 sintetiza estas tasas para el conjunto de test filtrado al periodo oficial del TFM.

Rama de conocimiento	N	Abandonos	Tasa (%)
Ingeniería y Arquitectura (TE)	1.513	577	38,14 %
Ciencias Experimentales (EX)	170	63	37,06 %
Ciencias Sociales y Jurídicas (SO)	3.685	1.062	28,82 %
Artes y Humanidades (HU)	542	142	26,20 %
Ciencias de la Salud (SA)	686	105	15,31 %

Tabla 5. Tasa de abandono real por rama de conocimiento sobre el conjunto de test ($n = 6.596$). Fuente: elaboración propia.

Se observa una concentración del abandono en las ramas técnico-experimentales (TE y EX, con tasas superiores al 37 %), mientras que la rama de Ciencias de la Salud presenta el comportamiento opuesto, con una tasa inferior a la mitad de la media institucional. Este patrón es coherente con la literatura previa sobre exigencia académica diferencial entre disciplinas STEM y perfiles vocacionales con altas notas de corte (Araque et al., 2009; Bernardo et al., 2015).

El análisis por sexo muestra una brecha de 13,8 puntos porcentuales en favor de las mujeres (Hombre: 37,19 % de abandono; Mujer: 23,31 %). Este hallazgo confirma una pauta documentada en el sistema universitario español, donde las mujeres presentan sistemáticamente mayores tasas de permanencia y graduación (Araque et al., 2009). Se trata, por tanto, de una variable protegida (ODS 5) cuyo tratamiento equitativo será objeto de análisis específico en la sección 4.7.

Las vías de acceso no convencionales muestran tasas de abandono particularmente elevadas: Adaptación a Grado (51,69 %), Pruebas de acceso para mayores de 25 años (46,46 %) y vías de Extranjeros CEE (39,08 %). Estos perfiles requerirán especial atención en el análisis de equidad, dado el reducido tamaño muestral de algunos de ellos.

4.2.2. Perfiles diferenciales abandono frente a éxito

La comparación de medias entre alumnado que abandona y alumnado que persiste revela diferencias marcadas en variables académicas y socioeconómicas (Tabla 4.2). Estas diferencias anticipan las variables que mostrarán mayor importancia en el análisis posterior con SHAP.

Variable	No abandono	Abandono	Diferencia
Créditos superados año 1.º	61,8	36,6	-40,8 %
Tasa de repetición	7,75	2,79	-64,0 %
Créditos repetidos	18,7	6,7	-64,2 %
Años trabajando	2,05	0,73	-64,4 %
Años con beca	2,10	0,85	-59,4 %
Nota de acceso	8,73	7,52	-13,8 %
Nota 1.º curso	7,00	6,35	-9,4 %
Edad de entrada	20,3	21,8	+7,0 %
Tasa abandono titulación	0,274	0,365	+33,2 %

Tabla 6. Perfiles medios diferenciales entre alumnado con y sin abandono ($n = 33.621$). Fuente: elaboración propia a partir del dataset modelable

La interpretación de estos contrastes apunta a tres bloques explicativos diferenciados. En primer lugar, el rendimiento académico de primer año actúa como predictor temprano y robusto: el alumnado que abandona supera un 40,8 % menos de créditos en su primer año, dato que justifica el papel central que jugará esta variable en el modelo final. En segundo lugar, los indicadores

socioeconómicos (años con beca, años trabajando) muestran diferencias del orden del 60 %, evidenciando que el apoyo institucional sostenido y la dedicación exclusiva a los estudios constituyen factores protectores de primer orden. Por último, el contexto de titulación (tasa de abandono histórica de la titulación) actúa como variable de ajuste contextual, modulando el riesgo individual.

4.3. Resultados de la validación con AutoML

Antes de abordar el modelado clásico, se ejecutó una fase de validación mediante cinco frameworks de AutoML, complementados con un módulo de baselines clásicos con validación cruzada estratificada de cinco pliegues, para establecer un baseline competitivo y orientar la selección de familias algorítmicas. Esta estrategia responde a la recomendación metodológica de Erickson et al. (2020), quienes proponen el uso de AutoML como techo de referencia rápido antes de invertir en optimización manual.

Los cinco frameworks AutoML evaluados (LazyPredict, PyCaret, H2O, AutoGluon y TabPFN v2), junto con el módulo de baselines clásicos (LogisticRegression, RandomForest, GradientBoosting y XGBoost), ofrecieron resultados consistentes en cuanto a la familia ganadora: Gradient Boosting con ensamblado por bagging. El modelo de referencia identificado fue WeightedEnsemble_L2 generado por AutoGluon, con un AUC de 0,958 y un F1 de 0,833 sobre el conjunto de test. Este resultado se adoptó como baseline a superar en la fase de modelado clásico. Adicionalmente, TabPFN v2 (Hollmann et al., 2024), incorporado a propuesta del tutor del proyecto como diferenciador metodológico orientado a la calificación cum laude, alcanzó el mejor rendimiento bruto del screening (F1 = 0,850; AUC = 0,964), si bien su tiempo de inferencia ($\approx 7,3$ horas sobre el conjunto de test) lo descarta como candidato a producción ligera. La discusión completa de esta decisión se documenta en la sección D.4 del Anexo D.

La convergencia de los cinco frameworks AutoML y de los baselines clásicos hacia familias de árboles ensamblados confirma la idoneidad de esta categoría algorítmica para el problema, dada la naturaleza tabular y mixta (numérica-categorica) de las features y la presencia de relaciones no lineales documentadas en el análisis exploratorio. Asimismo, la diferencia de rendimiento entre

frameworks (excluyendo TabPFN v2) resultó marginal, con rangos de F1 entre 0,828 y 0,833 sobre el conjunto de test, lo que reforzó la decisión de pasar al modelado clásico con espacio de hiperparámetros controlado en lugar de continuar la búsqueda en AutoML.

4.4. Resultados del modelado clásico (Fase 5)

La Fase 5 del proyecto consistió en el entrenamiento sistemático de 23 modelos en cada una de las tres estrategias de gestión del desbalance (none, balanced, smote), totalizando 69 configuraciones evaluadas con validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento (26.896 registros). El conjunto de test (6.596 registros tras filtrar la cohorte residual de 2009 al periodo oficial del TFM) se reservó íntegramente para evaluación final.

4.4.1. Selección del modelo ganador

El criterio establecido para la selección final fue el F1-score sobre el conjunto de test, con desempate por recall y tolerancia de empate fijada en 0,001. Esta jerarquía responde a la naturaleza asimétrica del coste de clasificación en el problema: un falso negativo (persona estudiante que abandona y el modelo no detecta) implica la pérdida irreparable de una oportunidad de intervención preventiva, mientras que un falso positivo solo conlleva una orientación adicional no requerida. Por ello se prioriza el equilibrio precision-recall (F1) y, ante rendimientos equivalentes, se favorece la mayor sensibilidad.

La Tabla 4.3 recoge los diez modelos mejor clasificados de los 69 evaluados. El ranking completo se incluye en el Anexo A.

	Modelo	Estrategia	AUC	F1	Precision	Recall
1	XGBoost	none	0,957	0,834	0,869	0,801
2	LightGBM ★	none	0,956	0,833	0,864	0,805
3	MLP	none	0,953	0,831	0,851	0,812
4	MLP	balanced	0,953	0,831	0,851	0,812
5	XGBoost	balanced	0,957	0,830	0,788	0,876
6	XGBoost	smote	0,956	0,829	0,844	0,814
7	LightGBM	smote	0,955	0,828	0,842	0,814
8	CatBoost	none	0,954	0,827	0,869	0,789
9	Stacking	balanced	0,954	0,827	0,848	0,807

10	Stacking	none	0,954	0,827	0,848	0,807
----	----------	------	-------	-------	-------	-------

Tabla 7. Top-10 de los 69 modelos evaluados, ordenados por F1 con desempate por recall. El símbolo ★ identifica al modelo seleccionado

El modelo XGBoost__none alcanza un F1 marginalmente superior (0,834 frente a 0,833 de LightGBM__none); sin embargo, ambos modelos quedan dentro de la tolerancia de empate establecida ($\Delta F1 = 0,0002 < 0,001$). Aplicando el criterio de desempate por recall, LightGBM__none resulta seleccionado al presentar un recall de 0,805 frente a 0,801 de XGBoost ($\Delta \text{recall} = 0,0041$, que se traduce en ocho personas estudiantes adicionales correctamente identificadas como en riesgo). Este matiz, aparentemente menor, refleja la filosofía del proyecto: ante rendimientos equivalentes, optar por la configuración que mejor sirve al objetivo institucional de detección temprana del riesgo.

4.4.2. Comparativa con el baseline AutoML

El modelo LightGBM__none seleccionado en la Fase 5 alcanza un F1 de 0,833 y un AUC de 0,956 sobre el conjunto de test del proceso de entrenamiento ($n = 6.596$), frente al baseline AutoGluon WeightedEnsemble_L2 con $F1 = 0,833$ y $AUC = 0,958$. Aunque la diferencia métrica respecto al baseline es marginal ($\Delta F1 = +0,0004$), LightGBM__none ofrece ventajas operativas sustanciales que justifican su selección como modelo final: un único modelo serializable de menos de 1 MB frente al ensemble pesado de AutoGluon, interpretabilidad SHAP nativa con TreeExplainer y tiempo de inferencia un orden de magnitud inferior (92,3 ms para el conjunto completo). Esta combinación de rendimiento equiparable y operatividad superior constituye la argumentación central del proyecto para validar la estrategia de modelado clásico optimizado frente a AutoML genérico. La discusión completa respecto al modelo TabPFN v2 (que alcanzó el mejor rendimiento bruto del screening) se documenta en la sección D.4 del Anexo D.

4.4.3. Análisis por familia algorítmica y estrategia de desbalance

El comportamiento agregado de las 69 configuraciones permite extraer varias observaciones de interés metodológico. La familia Gradient Boosting domina sistemáticamente el ranking, con una media de F1 de 0,825 y un máximo de 0,834, seguida de la familia MLP+EBM (F1 medio 0,818).

Las familias lineales y de árboles individuales rinden de forma sustancialmente inferior, con medias de F1 en torno a 0,72 y 0,78 respectivamente.

En cuanto a la gestión del desbalance, las tres estrategias evaluadas (sin tratamiento, ponderación de clases y SMOTE) produjeron resultados comparables en términos de F1 medio (entre 0,762 y 0,777). Es destacable que la mejor configuración sea la estrategia «none»: la cantidad de datos disponibles y el diseño de los hiperparámetros (regularización L1/L2, submuestreo) permiten al modelo aprender de la distribución natural sin necesidad de remuestreo artificial, lo que reduce el riesgo de sobreajuste a regiones sintéticas del espacio de features (Chawla et al., 2002).

4.5. Métricas desagregadas por clase

El análisis del rendimiento del modelo final se completa con la descomposición de las métricas por clase, atendiendo a la recomendación expresa del tutor sobre la conveniencia de informar rendimientos diferenciales en problemas con desbalance. La Tabla 4.4 presenta las métricas globales y por clase calculadas sobre el conjunto de test (n = 6.596).

Clase	Precision	Recall	F1	Soporte
No abandono (0)	0,922	0,947	0,934	4.647
Abandono (1)	0,865	0,808	0,833	1.949
Macro avg	0,893	0,877	0,885	6.596
Weighted avg	0,905	0,906	0,905	6.596

Tabla 8. Métricas de clasificación desagregadas por clase del modelo LightGBM__none sobre el conjunto de test. AUC-ROC = 0,956; AUC-PR = 0,919; Accuracy = 0,906.

La interpretación conjunta de estas métricas permite caracterizar con precisión el comportamiento del modelo. La clase mayoritaria (no abandono) presenta un F1 de 0,934, con una sensibilidad del 94,71 % y una precisión del 92,15 %. La clase minoritaria (abandono), pese al desbalance del 29,25 %, alcanza un F1 de 0,833 con una sensibilidad del 80,8 % y una precisión del 86,48 %. Este resultado confirma que el modelo conserva una capacidad predictiva equilibrada en ambas clases, sin colapsar hacia la mayoritaria.

La matriz de confusión asociada (Ilustración 14) permite visualizar la distribución concreta de los errores. De las 1.949 personas estudiantes que efectivamente abandonan, el modelo identifica correctamente 1.574 (verdaderos positivos) y deja sin detectar 375 (falsos negativos, que representan el 19,24 % de los casos de abandono). De las 4.647 personas estudiantes que persisten, el modelo clasifica correctamente 4.401 y genera 246 falsas alarmas (5,29 % del alumnado de no abandono).





Ilustración 9. Matriz de confusión del modelo LightGBM__none


La asimetría de errores resulta favorable al objetivo institucional: se detectan ocho de cada diez casos reales de abandono y se comete una falsa alarma cada veinte personas estudiantes correctamente clasificadas, una proporción que la literatura considera operativamente viable para los servicios de orientación (Aulck et al., 2016).

4.5.1. Curvas ROC y Precision-Recall

La capacidad discriminativa del modelo se ilustra mediante la curva ROC (Ilustración 15), que recorre el espacio sensibilidad-especificidad para todos los umbrales posibles, y la curva Precision-Recall (Ilustración 16), más informativa en escenarios de desbalance moderado (Davis & Goadrich, 2006). El AUC-ROC obtenido (0,956) y el AUC-PR (0,919, frente a un baseline aleatorio del 0,295) confirman que el modelo discrimina con elevada robustez en todo el rango de operación, sin depender de un umbral concreto.



Il·lustració 10. Curva ROC del model `LightGBM__none`. AUC = 0,956.



Il·lustració 11. Curva Precision-Recall del modelo LightGBM__none. AUC-PR = 0,919. La línea gris discontinua indica el baseline correspondiente a la proporción de positivos en el conjunto de test (0,295).

4.5.2. Análisis de sensibilidad al umbral de decisión

El umbral por defecto de 0,50 representa el punto natural de decisión para clasificadores probabilísticos balanceados, pero la aplicación desarrollada permite al personal técnico institucional ajustarlo dinámicamente según las necesidades operativas. La Tabla 4.5 muestra cómo varían precisión y recall ante distintas elecciones de umbral, lo que facilita la calibración política del sistema en función de los recursos de intervención disponibles.

Umbral	Precision	Recall	F1
0,30	0,774	0,885	0,826
0,40	0,822	0,842	0,832
0,50 (por defecto)	0,864	0,805	0,833
0,60	0,904	0,750	0,820

Il·lustració 12. Métricas del modelo LightGBM__none para distintos umbrales de decisión. El descenso del umbral incrementa la sensibilidad a costa de la precisión, permitiendo adaptar el modelo a contextos de intervención más o menos saturados.

4.6. Importancia de variables mediante valores SHAP

La interpretabilidad del modelo final se aborda mediante la metodología SHAP (Lundberg & Lee, 2017), que permite descomponer cada predicción individual en las contribuciones marginales de cada variable. La agregación de los valores absolutos a nivel global ofrece un ranking de importancia consistente con la teoría de juegos cooperativos en la que se fundamenta el método (Shapley, 1953).

4.6.1. Importancia global de las variables

El cálculo se ha realizado mediante TreeExplainer sobre las 6.596 observaciones del conjunto de test, garantizando una estimación robusta de la contribución promedio de cada variable a la predicción de la probabilidad de abandono. La Ilustración 17 presenta el ranking de las quince variables más influyentes.




Ilustración 13. Top-15 features ordenadas por importancia SHAP global (media del valor absoluto sobre el conjunto de test). Modelo LightGBM__none.


El análisis revela una jerarquía nítida en tres bloques. El primer bloque, integrado por las cuatro variables más influyentes, captura el 60 % de la capacidad explicativa del modelo: créditos superados en el primer año (0,728), años trabajando (0,697), años con beca (0,630) y créditos repetidos (0,449). Estas cuatro variables conforman lo que podría denominarse el «núcleo predictor» del abandono, combinando rendimiento académico inicial y condicionantes socioeconómicos.

El segundo bloque, formado por las variables ordinales 5.^a a 8.^a (años sin beca, situación laboral, nota de primer año y años sin notas), aporta refinamiento al diagnóstico al complementar el panorama académico y socioeconómico. Por último, el tercer bloque (variables 9.^a a 15.^a) incorpora el contexto de la titulación, características demográficas y vías de acceso, modulando el riesgo individual con información estructural.

Cabe señalar que la variable `orden_preferencia` (posición de la titulación cursada en las preferencias de preinscripción del estudiantado) no aparece en el ranking SHAP top-15 a pesar de su carga semántica motivacional relevante. Esta ausencia se interpreta como evidencia de que el modelo captura el efecto motivacional a través de variables proxy más informativas (particularmente `cred_superados_anio_1er` y `nota_1er_anio`), que reflejan el impacto conductual de una baja motivación inicial sobre el rendimiento académico observado. Esta interpretación es coherente con el modelo de Tinto (1975, 1993), donde la integración académica media entre las expectativas iniciales y la persistencia.

4.6.2. Distribución de los valores SHAP

El gráfico tipo beeswarm (Ilustración 18) permite visualizar no solo la importancia agregada, sino la dirección y dispersión del impacto de cada variable. Los puntos a la derecha del eje vertical (valores SHAP positivos) representan contribuciones que aumentan la probabilidad de abandono predicha; los puntos a la izquierda, contribuciones que la disminuyen. El color codifica el valor de la variable original (rojo: alto; azul: bajo).



Il·lustració 14. Gràfic SHAP beeswarm del model `LightGBM__none` sobre les 6.596 observacions del conjunt de test. Cada punt representa una persona estudiant; el eix horitzontal mostra el impacte sobre la probabilitat de abandono predicha

La interpretació de los patrones más relevantes confirma la coherencia del modelo con el conocimiento del dominio. En primer lugar, los créditos superados en primer año muestran una relación inversa nítida: valores bajos (color azul) impulsan fuertemente hacia el abandono (SHAP positivos altos), mientras que valores altos (color rojo) protegen contra él. En segundo lugar, los años con beca actúan como factor protector consistente: los puntos rojos (muchos años con beca) se concentran en valores SHAP negativos, evidenciando que el apoyo institucional sostenido reduce sistemáticamente el riesgo de abandono. En tercer lugar, los años trabajando presentan un patrón más complejo: valores bajos (azul) contribuyen positivamente al abandono predicho para una parte del alumnado, lo que sugiere que este indicador captura perfiles de no integración socioeconómica más allá de la mera compatibilización estudios-trabajo.

4.7. Análisis de equidad y diversidad

El análisis de equidad constituye un requisito ético explícito del marco normativo aplicable al proyecto (RGPD UE 2016/679, AI Act UE 2024/1689 y Recomendación UNESCO sobre la ética de la IA, 2021), y responde asimismo a la solicitud específica del tutor de explicitar las métricas de fairness empleadas. Se han evaluado tres atributos sensibles del alumnado: sexo (variable

protegida según ODS 5), rama de conocimiento (no protegida en sentido estricto, pero relevante para detectar sesgos disciplinares) y vía de acceso (proxy del origen educativo, potencialmente vinculado a la oportunidad educativa).

Las métricas de equidad calculadas siguen la formulación canónica de Mehrabi et al. (2021): Demographic Parity Difference (DPD), Equal Opportunity Difference (EOD) y Disparate Impact Ratio (DIR). Las definiciones formales se incluyen en el Anexo E.

4.7.1. Equidad por sexo

Grupo	N	Tasa real	Tasa pred.	Precision	Recall	F1
Hombre	2.963	37,19 %	35,71 %	0,862	0,828	0,844
Mujer	3.633	23,31 %	20,97 %	0,869	0,782	0,823

Tabla 9. Métricas desagregadas por sexo. DPD = 0,147; EOD = 0,046; DIR = 0,587.

El modelo presenta un comportamiento globalmente homogéneo entre sexos en términos de F1 (diferencia de 2,15 puntos porcentuales) y de recall (EOD = 0,046, muy próximo al ideal). El Disparate Impact Ratio de 0,587 se encuentra por debajo del umbral del 80 % establecido por la regla de los cuatro quintos (EEOC, 1978), si bien debe interpretarse considerando que las tasas reales de abandono difieren significativamente entre sexos (Hombre: 37,19 %; Mujer: 23,31 %). El DIR captura, en este caso, una asimetría en las predicciones que es proporcional a la asimetría real subyacente, no necesariamente un sesgo del modelo. Este matiz sustancia una reflexión metodológica relevante: las métricas de paridad estadística pueden señalar como discriminatorios comportamientos predictivos que simplemente reflejan distribuciones reales no equitativas en la población (Hardt et al., 2016).

4.7.2. Equidad por rama de conocimiento

Rama	N	Tasa real	Tasa pred.	Precision	Recall	F1
EX (Ciencias Experimentales)	170	37,06 %	31,18 %	0,962	0,809	0,879
HU (Artes y Humanidades)	542	26,20 %	22,51 %	0,885	0,761	0,818
SA (Ciencias de la Salud)	686	15,31 %	13,56 %	0,925	0,819	0,869

SO (Ciencias Sociales y Jurídicas)	3.685	28,82 %	27,06 %	0,872	0,818	0,844
TE (Ingeniería y Arquitectura)	1.513	38,14 %	36,68 %	0,829	0,797	0,813

Tabla 10. Métricas desagregadas por rama de conocimiento. $DPD = 0,231$; $EOD = 0,059$; $DIR = 0,370$.

El rendimiento del modelo es notablemente estable entre ramas en términos de F1 (rango: 0,813-0,879), y particularmente equilibrado en recall ($EOD = 0,059$). El DIR de 0,370 reproduce la situación descrita para sexo: refleja la heterogeneidad estructural entre ramas (la rama SA presenta una tasa real de abandono menos de la mitad que TE), no un sesgo introducido por el modelo. La rama de Ciencias Experimentales muestra el F1 más alto (0,879), aunque este dato debe interpretarse con cautela dado el reducido tamaño muestral ($n = 170$).

4.7.3. Equidad por vía de acceso

El análisis por vía de acceso revela el resultado más sensible del estudio. La Tabla 4.8 muestra las métricas de las ocho vías con tamaño muestral superior a 30 personas estudiantes.

Vía de acceso	N	Tasa real	F1
Adaptación a Grado	296	51,69 %	0,914
Ciclo Formativo de Grado superior	790	38,61 %	0,865
Pruebas mayores 25 años	127	46,46 %	0,848
Pruebas Bachiller (LOGSE)	4.837	26,52 %	0,829
Titulados Universitarios	256	23,83 %	0,810
Extranjeros CEE	87	39,08 %	0,781
Traslado	108	19,44 %	0,571
Extranjeros no CEE	56	30,36 %	0,514

Tabla 11. Métricas desagregadas por vía de acceso. $DPD = 0,390$; $EOD = 0,432$; $DIR = 0,249$.

Los resultados evidencian una desigualdad de rendimiento sustancial entre vías. Mientras las vías mayoritarias (Pruebas Bachiller LOGSE y Ciclo Formativo) alcanzan F1 superiores a 0,82, las vías minoritarias presentan comportamientos divergentes: Extranjeros no CEE ($F1 = 0,514$, $n = 56$) y Traslado ($F1 = 0,571$, $n = 108$) muestran rendimientos muy inferiores. Este hallazgo, lejos de ser una limitación del modelo, constituye una alerta operativa relevante: el sistema funciona peor para los perfiles minoritarios, perfiles que con frecuencia coinciden con situaciones de mayor

vulnerabilidad académica y socioeconómica. La pequeña cardinalidad muestral de estas vías limita además la robustez de las métricas, advertencia que debe acompañar cualquier uso institucional del modelo sobre alumnado de estos perfiles.

El EOD de 0,432 confirma la magnitud del problema: la sensibilidad varía casi 43 puntos porcentuales entre vías, lo que implica que el modelo detecta el abandono de forma muy desigual según el origen educativo. Esta limitación se documenta en la sección 4.10 y constituye uno de los principales motivos de la propuesta de regeneración de la Fase 6 durante el periodo de prórroga, con el fin de implementar técnicas de mitigación específicas (reweighing, postprocessing) para los grupos más afectados.

4.8. Robustez, calibración y sostenibilidad

Una vez confirmadas la capacidad discriminativa global del modelo (sección 4.4), su comportamiento por clase (sección 4.5) y su comportamiento equitativo (sección 4.7), procede examinar tres dimensiones complementarias que condicionan la viabilidad de un despliegue institucional real: la estabilidad temporal del modelo a lo largo de las distintas cohortes, la calidad probabilística de sus predicciones y su huella operativa. Los resultados que se presentan a continuación se obtienen sobre el conjunto de test ($n = 6.596$) tras aplicar el filtro de cohortes ≥ 2010 descrito en la sección 3.1.3.

4.8.1. Estabilidad temporal por cohorte

La estabilidad temporal se evalúa calculando el AUC-ROC del modelo de forma desagregada para cada cohorte de entrada del estudiantado (curso de matrícula inicial). Esta perspectiva permite valorar si el desempeño global de 0,956 (sección 4.4) se mantiene homogéneo en el tiempo o si, por el contrario, existen cohortes con un rendimiento sustancialmente diferente que pudieran sugerir desviaciones de distribución (concept drift) o degradación gradual del modelo.

Cohorte	N	Tasa abandono	AUC-ROC
2010	657	37,7 %	0,9919
2011	715	36,5 %	0,9918
2012	680	36,3 %	0,9813

2013	603	37,5 %	0,9799
2014	633	36,8 %	0,9815
2015	580	35,2 %	0,9618
2016	539	31,0 %	0,9427
2017	562	31,5 %	0,9726
2018	538	21,2 %	0,9245
2019	505	14,3 %	0,9168
2020	584	0,0 %	n.d.

Tabla 12. AUC-ROC del modelo LightGBM desagregado por cohorte de entrada (cursos 2010-2020).

Los resultados muestran un AUC medio de 0,9645 con desviación estándar de 0,0259 y un rango de 0,0751 puntos entre la cohorte mejor evaluada (2010, AUC = 0,992) y la peor (2019, AUC = 0,917). Se observa un patrón decreciente progresivo desde 2017 que requiere una explicación cuidadosa, ya que constituye una limitación metodológica conocida del estudio.

El descenso del AUC en las cohortes 2018-2019 y la imposibilidad de calcular esta métrica en la cohorte 2020 (donde la tasa de abandono observada es del 0,0 %) responden al fenómeno de censura por la derecha característico de los datos longitudinales de trayectoria académica. El estudiantado que inicia el grado en 2018 o 2019 no ha dispuesto todavía del tiempo suficiente, en el momento de extracción del dataset, para haber completado de manera observable el evento de abandono según la definición operativa adoptada (sección 3.1.4): una persona estudiante actualmente activa y matriculada en su titulación inicial, pero que abandonará en cursos posteriores, queda etiquetada erróneamente como «no abandono» en este conjunto de entrenamiento. La proporción de abandonos observados en cohortes recientes infraestima por tanto la tasa real, lo que a su vez compromete tanto el aprendizaje del modelo sobre estos casos como la propia evaluación del AUC sobre ellos.

Esta limitación constituye una de las principales motivaciones para incorporar, como ampliación de este trabajo, un análisis de supervivencia con estimadores Kaplan-Meier (cap. 5). El análisis de supervivencia maneja explícitamente la censura por la derecha y permitiría estimar de forma no sesgada las funciones de riesgo para cohortes recientes. Para los propósitos del modelo de clasificación binaria presentado, conviene interpretar las métricas globales reportadas como

representativas del comportamiento sobre cohortes maduras (≤ 2017), donde el AUC se mantiene entre 0,9427 y 0,9919, evidenciando una notable estabilidad temporal del aprendizaje.




Ilustración 15. Evolución del AUC-ROC

.Evolución del AUC-ROC del modelo LightGBM por cohorte de entrada. La línea discontinua representa el AUC medio (0,9645) y la banda sombreada el intervalo ± 1 desviación estándar (0,0259). El descenso a partir de 2018 refleja la censura por la derecha asociada al horizonte temporal del dataset.

Como muestra la Ilustración 19, las cohortes maduras (2010-2017) presentan valores de AUC consistentemente superiores a 0,94, mientras que las cohortes 2018 y 2019 evidencian un descenso progresivo hasta 0,9168. Este patrón responde al fenómeno de censura por la derecha discutido en la sección 5.4, no a una pérdida real de capacidad predictiva del modelo, y constituye una de las motivaciones principales para incorporar como línea futura el análisis de supervivencia mediante estimadores Kaplan-Meier (sección 5.5).

4.8.2. Calibración probabilística

Más allá de la capacidad discriminativa, el uso responsable del modelo en un contexto institucional real exige que las probabilidades predichas sean fieles a las frecuencias observadas. Una alumna a la que el modelo asigna una probabilidad de abandono del 70 % debería pertenecer a un grupo en el que aproximadamente el 70 % de las personas estudiantes acaben efectivamente abandonando. Esta propiedad, denominada calibración, resulta especialmente crítica si las

probabilidades predichas se utilizan para definir umbrales de intervención tutorial o para diseñar políticas focalizadas. Para evaluarla se calculan dos métricas complementarias: el Brier score (error cuadrático medio entre la probabilidad predicha y la etiqueta real) y el Expected Calibration Error o ECE (diferencia ponderada entre confianza media y precisión observada por bins de probabilidad).

Métrica	Valor
Brier score	0,0702
ECE (10 bins)	0,0137

Tabla 13. Métricas de calibración probabilística del modelo LightGBM sobre el conjunto de test ($n = 6.596$).

El Brier score de 0,0702 y un ECE de 0,0137 sitúan al modelo en un régimen de calibración elevada: ambos valores están cerca del óptimo teórico (0) y muy por debajo de los umbrales habitualmente considerados aceptables para el despliegue (Brier < 0,15, ECE < 0,05). La curva de fiabilidad (Ilustración 20) confirma visualmente este comportamiento: los puntos correspondientes a los diez bins de probabilidad se sitúan próximos a la diagonal de calibración perfecta, con una ligera tendencia a la sobreestimación en el bin central (probabilidades en torno a 0,55-0,75) que no reviste implicaciones operativas relevantes.




Ilustración 16. Curva de fiabilidad del modelo LightGBM.

Curva de fiabilidad del modelo LightGBM. La diagonal punteada representa la calibración perfecta y la línea sólida el comportamiento empírico observado. Los valores de Brier (0,0702) y ECE (0,0137) confirman una calibración adecuada para el uso institucional.

La Ilustración 20 ilustra cómo la curva del modelo se mantiene muy próxima a la diagonal de calibración perfecta a lo largo de todo el rango de probabilidades, lo que confirma que las puntuaciones predichas pueden interpretarse directamente como probabilidades fiables de abandono. Esta propiedad es especialmente relevante en el uso institucional del modelo, donde un valor de 0,7 debe entenderse efectivamente como un 70 % de probabilidad de abandono y no como una mera puntuación de ordenamiento de riesgo.

4.8.3. Sostenibilidad operativa

La tercera dimensión examinada se refiere al coste computacional del modelo en producción, entendido como una proxy razonable de su huella energética y de la viabilidad de despliegues institucionales sostenibles. Se reportan cuatro indicadores: tiempo total de inferencia para el conjunto de test, tiempo medio por persona estudiante, throughput (alumnado procesado por segundo) y tamaño en disco del modelo serializado.

Indicador	Valor
Tiempo total de inferencia (lote 6.596)	92,3 ms
Tiempo medio por persona estudiante	0,0140 ms
Throughput	71.468 alumnos/s
Tamaño .pkl serializado	932,7 KB

Tabla 14. Indicadores de sostenibilidad operativa del modelo LightGBM.

Las cifras obtenidas reflejan un perfil operativo ligero. La inferencia sobre el conjunto completo de test se completa en 92,3 milisegundos, lo que supone un tiempo por individuo de 14 microsegundos y un throughput equivalente a 71.468 alumnos por segundo. El modelo serializado ocupa 932,7 KB, un orden de magnitud inferior al stacking previo (≈ 23 MB), lo que reduce el coste de despliegue en infraestructura cloud y mejora los tiempos de carga de la aplicación. En conjunto, estos indicadores sustentan la viabilidad técnica de un despliegue institucional regular: una ejecución diaria del modelo sobre la totalidad del estudiantado matriculado en la UJI (≈ 14.000 personas) requeriría menos de 200 milisegundos de cómputo y una huella en disco prácticamente despreciable, lo que es coherente con los principios de sostenibilidad operativa adoptados en la sección 1.3.

4.8.4. Síntesis

El modelo LightGBM presenta una alta estabilidad temporal sobre cohortes maduras (AUC entre 0,9427 y 0,9919 para 2010-2017), una calibración probabilística adecuada (Brier = 0,0702; ECE = 0,0137) y un perfil operativo eficiente (71.468 alumnos/s con un tamaño de 932,7 KB). El descenso del AUC en cohortes recientes (2018-2019) se atribuye a la censura por la derecha y queda explícitamente reconocido como limitación metodológica del enfoque de clasificación binaria, motivando la incorporación del análisis de supervivencia como ampliación natural del trabajo. Tomadas en su conjunto, las tres dimensiones examinadas sustentan la viabilidad de un despliegue institucional responsable y sostenible del sistema, en línea con los requisitos no funcionales y de sostenibilidad establecidos en la sección 1.7.

4.9. Aplicación Streamlit como herramienta de uso institucional

Los resultados del modelado se han plasmado en una aplicación web desarrollada con Streamlit, accesible en la dirección <https://tfm-abandono-dinamico.streamlit.app/>. La aplicación se organiza en siete secciones que cubren tanto la exploración global del fenómeno como el uso individualizado del modelo. Las capturas correspondientes a cada sección se incluyen en el Anexo G.

4.9.1. Estructura funcional

La sección de inicio (Ilustración 21) presenta los indicadores clave del modelo y orienta sobre el uso de las distintas páginas. La sección de visión institucional permite explorar la evolución temporal del abandono, los patrones por rama y la distribución de riesgo agregada. La sección por titulación profundiza en el análisis a nivel de grado concreto, ofreciendo comparativas internas y un perfil de los factores más influyentes en cada caso.




Ilustración 17. Página de inicio (p00) de la aplicación Streamlit institucional, con cabecera, lema del proyecto e indicadores clave del modelo. Disponible en <https://tfm-abandono-dinamico.streamlit.app/>.

Las dos secciones de pronóstico individualizado (futuro alumnado y alumnado en curso) permiten al usuario obtener una estimación personalizada del riesgo, complementada con recomendaciones heurísticas basadas en factores protectores. La sección de equidad reproduce los análisis de fairness presentados en este capítulo, ofreciendo un simulador de política institucional que permite ajustar el umbral de intervención y observar su impacto sobre detección, falsas alarmas y coste estimado.

4.9.2. Casos de uso documentados

La aplicación contempla cuatro casos de uso institucionales claramente diferenciados. El primero, dirigido al equipo de gestión y dirección académica, permite el seguimiento agregado de tendencias y la identificación de titulaciones con tasas anómalas de abandono. El segundo, orientado al profesorado coordinador y responsable de titulación, facilita el análisis intra-grado y la detección temprana de patrones de riesgo. El tercer caso de uso atiende al futuro alumnado, ofreciéndole una estimación contextualizada de su riesgo antes de matricularse, en línea con la

transparencia que reclama el Reglamento UE 2024/1689 (AI Act). El cuarto caso, dirigido al alumnado en curso y a la Unidad de Soporte Educativo (USE), permite personalizar la orientación con datos académicos actualizados.

En todos los casos, la aplicación opera bajo un principio explícito de supervisión humana: ningún resultado del modelo determina automáticamente decisiones académicas, sino que se ofrece como herramienta de apoyo a la decisión humana, en consonancia con la clasificación de los sistemas de IA aplicados a educación como de alto riesgo según el AI Act.

4.10. Limitaciones identificadas

El conjunto de resultados presentados está sujeto a varias limitaciones que conviene explicitar para facilitar la interpretación correcta del trabajo y orientar futuras líneas de mejora. En primer lugar, la censura derecha de las cohortes más recientes (2018-2020) implica que una parte del alumnado clasificado como «no abandono» podría aún abandonar en cursos posteriores no observados; este sesgo se aborda parcialmente en la propuesta de análisis de supervivencia mediante Kaplan-Meier incluida en el Capítulo 5.

En segundo lugar, la utilización del modelo sobre prospectos (futuro alumnado) presenta una limitación inherente: el modelo se entrenó con alumnado matriculado, por lo que la imputación de variables académicas ausentes (notas de primer año, créditos superados) introduce una incertidumbre que se documenta explícitamente en la sección correspondiente de la aplicación. La estimación obtenida en estos casos debe interpretarse como comparativa, no absoluta.

En tercer lugar, los análisis de equidad presentados en la sección 4.7 se han realizado sobre el modelo LightGBM__none seleccionado, pero los notebooks originales de Fase 6 utilizaban un modelo Stacking previo basado en CatBoost. La regeneración completa de los análisis de fairness con el modelo final, así como la implementación de técnicas de mitigación específicas para la vía de acceso, constituye una de las tareas planificadas para el periodo de prórroga.

Por último, la cardinalidad muestral de algunas vías de acceso minoritarias (Extranjeros no CEE: $n = 56$; Traslado: $n = 108$) limita la robustez estadística de las métricas de equidad correspondientes. La interpretación de estas debe realizarse con cautela, y su uso operativo



institucional requiere acompañarse de la supervisión humana y la revisión periódica que el marco normativo establece como requisito ético.

5. Conclusiones y trabajos futuros

Este capítulo cierra el Trabajo de Fin de Máster articulando las conclusiones generales en torno a los cinco objetivos planteados en la sección 1.2, exponiendo las aportaciones técnicas, científicas e institucionales del estudio, reconociendo de forma transparente las limitaciones identificadas y proponiendo líneas de trabajo futuro que continúen la investigación. Se concluye con una reflexión ética sobre el uso responsable de modelos predictivos en el ámbito educativo y su alineación con los Objetivos de Desarrollo Sostenible asumidos por la institución.

5.1. Conclusiones por objetivo

Los cinco objetivos planteados en la sección 1.2 se han abordado de manera explícita a lo largo del trabajo. A continuación se sintetiza el grado de cumplimiento de cada uno de ellos.

Objetivo 1. Establecer un modelo predictivo para el abandono universitario

Objetivo plenamente cumplido. Se ha entrenado y validado un modelo LightGBM sobre 33.621 registros y 24 variables semánticas (sección 3.5), seleccionado mediante un sistema dinámico que evalúa 69 modelos candidatos según los criterios $F1_{test}$ con desempate por $recall_{test}$ (sección 3.9). El modelo final alcanza un AUC-ROC de 0,956, un F1 de 0,833, una precisión del 86,5 % y un recall del 80,8 % sobre el conjunto de test ($n = 6.596$ con cohortes ≥ 2010 , sección 4.4-4.5). La calibración probabilística es alta (Brier = 0,0702; ECE = 0,0137) y la estabilidad temporal sobre cohortes maduras se mantiene entre 0,9427 y 0,9919 de AUC (sección 4.8). Estos resultados se sitúan en el rango superior de los modelos publicados en la literatura comparable (Aulck et al., 2016; Bernardo et al., 2015).

Objetivo 2. Estudiar las variables de mayor influencia en el fenómeno

Objetivo plenamente cumplido. El análisis SHAP global (sección 4.6) identifica de forma consistente las variables académicas como las de mayor impacto: créditos superados durante el primer año, nota media del primer año y tasa de abandono histórica de la titulación. Se confirman, en consonancia con la literatura previa (Tinto, 1975; Bernardo et al., 2015; Fernández-Mellizo,

2022), tres bloques explicativos diferenciados: rendimiento académico inicial, contexto institucional (titulación y rama de conocimiento) y condiciones socioeconómicas (becas, situación laboral, edad de entrada). El uso combinado de SHAP, LIME y DiCE permite además explicaciones tanto globales como individuales y contrafactuales (sección 3.10), proporcionando una comprensión multinivel del fenómeno.

Objetivo 3. Analizar la interacción entre las variables asociadas al abandono

Objetivo cumplido con matices que se desarrollan como limitación en la sección 5.4. La elección de un modelo de árboles potenciados (LightGBM) implica que las interacciones entre variables se aprenden y aprovechan implícitamente durante el entrenamiento, como evidencian las métricas de rendimiento alcanzadas. No obstante, no se ha realizado un análisis explícito de interacciones por pares mediante valores SHAP de interacción (Lundberg et al., 2020) ni un estudio dedicado de efectos cruzados, decisión motivada por las restricciones de extensión y por la prioridad otorgada a las dimensiones de equidad y robustez. Las interacciones más visibles emergen igualmente del análisis estratificado realizado en la sección 4.2 (perfil diferencial por rama y por sexo) y de la inspección de casos individuales mediante DiCE.

Objetivo 4. Diagnosticar la posible desigualdad de oportunidades

Objetivo plenamente cumplido. La fase 6 incorpora un análisis de equidad algorítmica (sección 3.11 y 4.7) sobre cuatro atributos protegidos —sexo, rama de conocimiento, vía de acceso y condición de becario o becaria— evaluados mediante cuatro métricas de fairness reconocidas en la literatura: Demographic Parity Difference, Equal Opportunity Difference, Equalized Odds Difference y Disparate Impact Ratio (Hardt et al., 2016; Chouldechova, 2017; Verma y Rubin, 2018). Los resultados confirman la existencia de desigualdades estructurales —especialmente la brecha de género observada (37,19 % de abandono en hombres frente al 23,31 % en mujeres) y la elevada tasa asociada a determinadas vías de acceso no convencionales—, sin que estas se traduzcan en disparidades introducidas por el modelo: las métricas de equidad se mantienen dentro de los umbrales aceptables establecidos en la literatura.

Objetivo 5. Proponer políticas para reducir el abandono y mejorar la igualdad de oportunidades

Objetivo cumplido con matices que se desarrollan como limitación en la sección 5.4. El trabajo aporta dos elementos fundamentales para la formulación de políticas: por un lado, una identificación cuantitativa y replicable de los grupos de mayor riesgo y de las palancas con mayor capacidad explicativa (sección 4.6 y 4.7); por otro lado, una herramienta institucional desplegada (sección 4.9) que permite a equipos directivos, coordinaciones de titulación y servicios de tutorización consultar el modelo en escenarios concretos. La traducción de estos hallazgos en políticas operativas concretas (programas de apoyo focalizado, intervenciones tutoriales tempranas, ajustes en los cupos de admisión) excede el alcance estricto de un TFM y constituye una línea natural de continuidad institucional, recogida en la sección 5.5.

5.2. Aportaciones técnicas y científicas

Más allá del cumplimiento de los objetivos planteados, el trabajo introduce cinco aportaciones técnicas y metodológicas que merecen ser destacadas como contribución diferencial.

En primer lugar, el sistema dinámico de selección del modelo ganador (sección 3.9) constituye una arquitectura poco habitual en proyectos de TFM. La aplicación y la propia memoria leen los valores de rendimiento desde un fichero JSON (`metricas_modelo.json`) generado automáticamente a partir del registro maestro de los 69 modelos evaluados, lo que garantiza la trazabilidad entre experimento, modelo desplegado y documentación, y elimina la dependencia de valores codificados manualmente.

En segundo lugar, se ha realizado una validación competitiva mediante AutoML (sección 3.7) con cinco frameworks distintos —AutoGluon, PyCaret, H2O AutoML, LazyPredict y TabPFN v2 (Hollmann et al., 2024)— como fase de screening previa al modelado clásico, lo que permite triangular conclusiones y establecer baselines defendibles ante el tribunal y ante una eventual revisión externa.

En tercer lugar, la auditoría explícita de fuga de información comparando los datasets D y D_strict (sección 3.5.4) representa una decisión metodológica responsable: se acepta una pérdida de 1,7 puntos de F1 a cambio de eliminar variables potencialmente contaminadas por el resultado, priorizando la pureza metodológica sobre el rendimiento aparente.

En cuarto lugar, el análisis de equidad multicriterio sobre cuatro atributos protegidos y con cuatro métricas complementarias (sección 3.11) responde al estado del arte en fairness algorítmica aplicada a la educación (Kizilcec y Lee, 2022) y proporciona una base sólida para auditorías futuras del modelo en producción.

En quinto lugar, el producto resultante es una aplicación funcional desplegada en infraestructura cloud (Streamlit Cloud) y accesible públicamente, que materializa el principio de reproducibilidad y permite el uso real del modelo más allá de la entrega académica del TFM.

5.3. Aportaciones institucionales y producto desplegado

El trabajo aporta a la Universitat Jaume I un conjunto de productos directamente integrables en sus procesos institucionales. La aplicación desplegada (<https://tfm-abandono-dinamico.streamlit.app/>) ofrece siete páginas funcionales orientadas a cuatro perfiles de uso: vista institucional para equipos directivos y vicerrectorado, análisis por titulación para coordinaciones, pronóstico para futuro estudiantado para servicios de orientación y pronóstico para alumnado en curso para tutorización académica. La página de equidad y diversidad y la guía semántica completan el sistema con transparencia sobre las decisiones del modelo y su marco ético.

Toda la trazabilidad del proyecto, desde los datos originales hasta el modelo desplegado, se documenta en el repositorio público del TFM y en la guía técnica. La encuesta sobre motivos de abandono (Anexo H) queda disponible como instrumento reutilizable por la institución para complementar el análisis cuantitativo con información cualitativa de quienes han abandonado. El conjunto del trabajo se alinea con el Plan UJI-ODS 2030 y refuerza la presencia de la universidad en proyectos de inteligencia artificial responsable aplicada al ámbito educativo.

5.4. Limitaciones del estudio

El reconocimiento explícito de las limitaciones constituye un ejercicio metodológico imprescindible. Se identifican seis limitaciones principales que delimitan el alcance del trabajo y orientan las líneas de continuidad.

La primera limitación es la censura por la derecha sobre las cohortes más recientes. Como muestra la Tabla 4.9, el AUC desciende de 0,9726 en la cohorte 2017 hasta 0,9168 en la cohorte 2019 y resulta indeterminado en la cohorte 2020 (tasa de abandono observada del 0,0 %). Este patrón no responde a una pérdida real de capacidad predictiva del modelo, sino al hecho de que el estudiantado matriculado en 2018-2020 no ha dispuesto en el momento de extracción del dataset del tiempo necesario para completar de manera observable el evento de abandono según la definición operativa adoptada (sección 3.1.4). Las métricas globales reportadas son por tanto representativas del comportamiento sobre cohortes maduras (≤ 2017) y deben interpretarse con prudencia para cohortes recientes.

La segunda limitación es el alcance restringido del análisis de interacciones, ya señalada en el cumplimiento del objetivo 3. La elección de no profundizar en valores SHAP de interacción ni en efectos cruzados explícitos responde a las restricciones de extensión de la memoria y deja abierto un espacio natural de continuidad.

La tercera limitación es la dependencia de variables disponibles únicamente a posteriori del primer año académico, en particular `cred_superados_anio_1er`, `nota_1er_anio` y `cred_repetidos`. Esto convierte al modelo en una herramienta de predicción a mitad de trayecto, no de selección a la entrada, y limita su aplicabilidad para perfiles de prospecto, donde la imputación con medianas degrada sistemáticamente las probabilidades estimadas (limitación documentada en la página p03 de la aplicación).

La cuarta limitación es el carácter exclusivamente institucional de los datos utilizados. No se ha incorporado información cualitativa procedente directamente del estudiantado que abandona — motivos, vivencias, dificultades— que enriquecería la comprensión del fenómeno. La encuesta del Anexo H proporciona el instrumento, pero su aplicación práctica queda fuera del alcance de este TFM.

La quinta limitación es la circunscripción a una única universidad (UJI). Aunque la metodología es replicable y la documentación lo facilita, la generalización de los hallazgos cuantitativos concretos a otras universidades del Sistema Universitario Español requiere validación empírica sobre datos propios de cada centro.

La sexta limitación afecta a la propia definición operativa del abandono adoptada (interrupción de la matrícula durante al menos un curso académico completo). Definiciones alternativas (cambio de titulación dentro de la misma universidad, abandono diferido, abandono temporal voluntario) producirían tasas y patrones distintos. Esta convención metodológica está documentada en la sección 3.1.4 y debe tenerse presente al comparar con otros estudios.

5.5. Líneas de trabajo futuro

El trabajo abre seis líneas naturales de continuidad, ordenadas según su prioridad y madurez técnica.

La primera línea, y más inmediata, es la incorporación de un análisis de supervivencia mediante estimadores Kaplan-Meier y test log-rank (Kaplan y Meier, 1958). Este enfoque, expresamente sugerido durante el seguimiento académico, resuelve la limitación de censura por la derecha identificada en la sección 5.4 y añade la dimensión temporal que el modelo de clasificación binaria no captura: no solo si el estudiantado abandona, sino cuándo lo hace. La comparación de curvas de supervivencia entre subgrupos mediante el test log-rank permitiría además contrastar formalmente diferencias entre, por ejemplo, alumnado becado y no becado, o entre ramas de conocimiento.

La segunda línea es el desarrollo de un modelo específico para perfiles de prospecto, entrenado únicamente con variables disponibles antes del inicio del grado (nota de acceso, vía de acceso, orden de preferencia, perfil sociodemográfico). Este modelo complementaría al actual, especializado en alumnado en curso, y resolvería la limitación documentada en la página p03 de la aplicación.

La tercera línea es la incorporación de cohortes posteriores a 2020 (cursos 2021-2022 en adelante) cuando dispongan de horizonte temporal suficiente para una evaluación completa, lo que permitirá validar la estabilidad temporal del modelo más allá del periodo actualmente cubierto y detectar eventuales desviaciones de distribución asociadas a cambios estructurales (efecto pospandemia, evolución del perfil del estudiantado, modificaciones en la oferta académica).

La cuarta línea responde a recomendaciones institucionales explícitas y consiste en la integración del producto desarrollado con los sistemas internos de la universidad: Sistema de Gestión Documental, Confluence y los entornos de la Oficina de Promoción y Planificación. Esta integración requeriría incorporar autenticación, control de acceso por perfiles y trazabilidad de las consultas, transformando la aplicación en una herramienta institucional formal.

La quinta línea, sugerida durante el seguimiento académico institucional, es el desarrollo de un análisis de series temporales sobre la evolución de la matrícula, que permitiría a la universidad anticipar tendencias agregadas a tres-cinco años vista, complementando el enfoque de predicción individual del modelo actual con una perspectiva agregada y prospectiva.

La sexta línea es la aplicación efectiva de la encuesta sobre motivos de abandono (Anexo H) sobre una muestra representativa del estudiantado que ha abandonado, lo que permitiría triangular las explicaciones cuantitativas obtenidas mediante machine learning con las narrativas cualitativas de las personas afectadas.

5.6. Reflexión ética y compromiso con los Objetivos de Desarrollo Sostenible

El uso de modelos predictivos en contextos educativos exige una reflexión ética que vaya más allá del cumplimiento técnico. El presente trabajo se enmarca explícitamente en los Objetivos de Desarrollo Sostenible asumidos por la Universitat Jaume I, particularmente el ODS 4 (educación de calidad) y el ODS 10 (reducción de las desigualdades), y responde a las recomendaciones internacionales sobre el uso responsable de la inteligencia artificial (UNESCO, 2021; Comisión Europea, 2019; Unión Europea, 2024).

Una primera consideración ética es que el modelo desarrollado constituye una herramienta de apoyo a la decisión, nunca un mecanismo automático de selección. Su uso institucional debe limitarse a la identificación temprana de situaciones que requieren acompañamiento tutorial reforzado, y en ningún caso puede emplearse para filtrar el acceso a la universidad, condicionar la admisión o estigmatizar a colectivos. La intervención educativa sigue siendo competencia humana y profesional.

Una segunda consideración es el compromiso con la transparencia algorítmica, materializado en tres frentes: la incorporación de SHAP, LIME y DiCE como capas explicativas accesibles desde la propia aplicación; la apertura del código en repositorio público con documentación completa; y la auditoría de equidad mediante métricas internacionalmente reconocidas. Estas decisiones se alinean con los principios de responsabilidad y trazabilidad establecidos por el Reglamento de Inteligencia Artificial de la Unión Europea (Unión Europea, 2024).

Una tercera consideración es la protección de datos personales. El conjunto de datos utilizado proviene de fuentes institucionales internas, ha sido tratado bajo el marco del Reglamento General de Protección de Datos (Unión Europea, 2016), y todas las identidades han sido seudonimizadas mediante un identificador ficticio que impide cualquier reidentificación. El modelo desplegado no almacena consultas individuales y los ejemplos mostrados en la aplicación corresponden a perfiles ilustrativos.

El trabajo asume, en definitiva, que la responsabilidad de un sistema predictivo no termina con su entrega técnica: continúa en su uso institucional cotidiano, en la actualización periódica de sus auditorías de equidad y en la disposición permanente a revisarlo, corregirlo o retirarlo cuando los principios éticos lo aconsejen.

Glosario

Definiciones precisas de los términos técnicos e institucionales empleados a lo largo de la memoria, organizados por bloques temáticos para facilitar su consulta.

Indicadores académicos

Tasa de abandono (interrupción de estudios). Relación porcentual que mide el abandono definitivo de una titulación. Se calcula sobre la cohorte de personas estudiantes de nuevo ingreso que, según la duración oficial de la carrera, debieron finalizar sus estudios el curso anterior (x-1). El numerador incluye únicamente a quienes forman parte de dicha cohorte que no registran matrícula ni en el curso evaluado (x) ni en el curso inmediatamente anterior (x-1).

Tasa de rendimiento. Cociente entre el número de créditos superados por el alumnado de un estudio y el número de créditos matriculados. Para que el indicador sea representativo del grado de eficacia de la labor docente, se han de excluir de su cálculo los créditos adaptados, convalidados y reconocidos.

Tasa de éxito. Cociente entre el número de créditos superados por el alumnado de un estudio y el número de créditos presentados a examen. Complementa a la tasa de rendimiento en el sentido de analizar los resultados obtenidos en las pruebas de evaluación. No se consideran los créditos adaptados, convalidados ni reconocidos.

Tasa de graduación. Porcentaje del alumnado de una cohorte de nuevo ingreso en primero que finaliza la titulación en los años establecidos en el plan de estudios (n).

Tasa de evaluación. Cociente entre los créditos presentados a examen y los créditos matriculados.

Tipologías de abandono

Abandono «a priori» o premeditado. Corresponde a aquellas personas estudiantes que no llegan a presentarse a ningún examen y son expulsadas de la institución.

Abandono «a posteriori» o fracaso académico. Hace referencia al alumnado que intenta permanecer en la carrera, pero no consigue aprobar nada o no consigue superar los créditos mínimos de permanencia exigidos y finalmente es expulsado.

Abandono voluntario. Comprende a aquella persona estudiante que, aun superando los créditos de permanencia, decide abandonar los estudios iniciados.

Deserción voluntaria. Adopta la forma de renuncia a la carrera por parte de la persona estudiante o del abandono no informado a la institución de educación superior (Himmel, 2002).

Deserción involuntaria. Se produce como consecuencia de una decisión institucional, fundada en sus reglamentos vigentes, que obliga al alumnado a retirarse de los estudios. Puede estar fundamentada en un desempeño académico insuficiente o responder a razones disciplinarias.

Aprendizaje automático y modelos predictivos

AUC-ROC. Área bajo la curva ROC (Receiver Operating Characteristic). Mide la capacidad discriminativa del modelo de manera independiente del umbral de clasificación. Rango: 0,5 (azar) a 1,0 (perfecto).

AUC-PR. Área bajo la curva Precision-Recall. Especialmente informativa cuando las clases están desequilibradas, como ocurre en la predicción de abandono.

F1-Score. Media armónica entre precisión y recall. Más informativa que la exactitud cuando las clases están desbalanceadas (29,25 % abandono frente a 70,75 % no abandono en este TFM).

Brier score. Error cuadrático medio entre las probabilidades predichas y las etiquetas reales. Rango [0, 1], menor es mejor. Mide la calibración del modelo.

ECE (Expected Calibration Error). Diferencia esperada entre la confianza predicha y la precisión real, agrupada en bins de probabilidad. Cuanto menor, mejor calibrado está el modelo.

Disparate Impact (DI). Ratio entre la tasa de predicción positiva del grupo menos favorecido y la del grupo más favorecido. Valor ideal: cercano a 1,0. Por debajo de 0,8 se considera señal de discriminación estadística (regla del 80 %, EEOC 1978).

SHAP (SHapley Additive exPlanations). Método para explicar cuánto contribuye cada variable a la predicción para un caso concreto. Está basado en la teoría de juegos cooperativos (Shapley, 1953).

LIME (Local Interpretable Model-agnostic Explanations). Técnica de interpretabilidad local que aproxima el modelo complejo mediante un modelo lineal en el entorno de cada predicción individual.

DiCE (Diverse Counterfactual Explanations). Método que genera contrafactuales accionables: muestra qué cambios mínimos en el perfil de una persona estudiante revertirían la predicción de abandono.

Gradient Boosting. Familia de algoritmos que construye un ensamble de árboles de decisión secuencialmente, donde cada árbol corrige los errores del anterior. Modelos empleados en este TFM: LightGBM, XGBoost, CatBoost y GradientBoosting (scikit-learn).

AutoML. Conjunto de técnicas y herramientas que automatizan la selección y optimización de modelos de aprendizaje automático. En este TFM se emplean cinco frameworks: AutoGluon, PyCaret, H2O, LazyPredict y TabPFN v2.

Validación cruzada. Procedimiento para evaluar la capacidad de generalización de un modelo dividiendo los datos en k pliegues y entrenando k veces. Reduce la dependencia del rendimiento respecto a una partición concreta.

Falso positivo (FP). El modelo predice abandono pero la persona estudiante completa el grado. Consecuencia institucional: intervención innecesaria.

Falso negativo (FN). La persona estudiante abandona pero el modelo no lo detecta. Consecuencia institucional: persona estudiante en riesgo sin apoyo.

Fairness (equidad algorítmica). Conjunto de propiedades formales que evalúan si un modelo de aprendizaje automático produce decisiones equilibradas entre subgrupos definidos por atributos sensibles (sexo, rama de conocimiento, vía de acceso, condición de becario o becaria). En este TFM se evalúa mediante cuatro métricas: DPD, EOD, EqOpp y DIR (Hardt et al., 2016; Mehrabi et al., 2021).

Leakage (fuga de información). Situación en la que una variable predictora contiene, de forma directa o indirecta, información sobre la variable objetivo que no estaría disponible en el momento real de la predicción. Su presencia infla artificialmente las métricas de evaluación. En este TFM se aborda explícitamente mediante la auditoría D versus D_strict (sec. 3.5.4).

Kaplan-Meier. Estimador no paramétrico de la función de supervivencia que permite estudiar el tiempo hasta que ocurre un evento (en este caso, el abandono) tratando adecuadamente los casos censurados. Es el método base del análisis de supervivencia (Kaplan y Meier, 1958).

Log-rank test. Prueba estadística no paramétrica que compara dos o más curvas de supervivencia para determinar si las diferencias observadas entre grupos son estadísticamente significativas (por ejemplo, alumnado becado frente a no becado). Complementa habitualmente al estimador Kaplan-Meier.

Censura por la derecha. Fenómeno por el cual, en datos longitudinales, no se observa el evento de interés (abandono) para una parte del estudiantado simplemente porque el periodo de seguimiento concluyó antes de que pudieran abandonar. En este TFM afecta a las cohortes 2018-2020 (sec. 4.8 y 5.4) y motiva la incorporación del análisis de supervivencia como línea futura.

Demographic Parity Difference (DPD). Métrica de equidad que mide la diferencia entre las tasas de predicción positiva (predicción de abandono) en distintos subgrupos. Un valor cercano a 0 indica paridad demográfica. Penaliza disparidades agregadas, sin tener en cuenta la verdad subyacente. **Equal Opportunity Difference (EOD)** y **Equalized Odds Difference.** Métricas de equidad que evalúan si las tasas de verdaderos positivos (EOD) y, conjuntamente, de verdaderos positivos y falsos positivos (Equalized Odds) son comparables entre subgrupos. Son las métricas más recomendadas cuando los falsos negativos tienen un coste alto (Hardt et al., 2016).

Stacking. Técnica de ensamble que combina las predicciones de varios modelos base mediante un metamodelo entrenado sobre sus salidas. Fue el modelo ganador en una iteración previa del proyecto antes de su sustitución por LightGBM tras la auditoría sistemática de modelos (sec. 3.9).

Baseline. Modelo de referencia frente al cual se compara el rendimiento del modelo final. En este TFM, el baseline está constituido por el mejor modelo identificado durante la fase AutoML (CatBoost_BAG_L2, AUC = 0,937), superado por el modelo LightGBM final (sec. 4.4.2).

Pipeline. Secuencia ordenada de transformaciones (imputación, codificación, escalado) que se aplican a los datos antes de entrenar o evaluar el modelo. En este TFM, el pipeline de preprocesamiento se serializa como ColumnTransformer y se reutiliza tanto durante el entrenamiento como en la inferencia productiva.

Bagging y ensemble (ensamble). Técnicas que combinan las predicciones de múltiples modelos para mejorar la generalización. Bagging (Bootstrap Aggregating) entrena modelos en paralelo sobre subconjuntos aleatorios de los datos; el término ensemble es más general e incluye también boosting y stacking. Random Forest (Breiman, 2001) es el ejemplo arquetípico de bagging.

EBM (Explainable Boosting Machine). Familia de modelos de gradient boosting con la propiedad de ser intrínsecamente interpretables, ya que descomponen la predicción en contribuciones aditivas por variable. En este TFM se evalúa como alternativa interpretable durante la fase 5 (sec. 4.4).

Concept drift. Cambio en la distribución de los datos o en la relación entre las variables predictoras y el objetivo a lo largo del tiempo. Su presencia degrada progresivamente el rendimiento del modelo en producción y exige reentrenamientos periódicos.

Matriz de confusión. Tabla cuadrada que enfrenta las predicciones del modelo con las etiquetas reales, descomponiendo los aciertos y errores en cuatro categorías: verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos. Es la base para el cálculo de precisión, recall y F1.

Hiperparámetro. Parámetro de configuración de un algoritmo de aprendizaje automático que no se aprende durante el entrenamiento, sino que se fija previamente (por ejemplo, número de árboles, tasa de aprendizaje, profundidad máxima). En este TFM se optimizan mediante búsqueda con la librería Optuna (Anexo B).

Marco institucional y normativo

UJI. Universitat Jaume I de Castellón.

UOC. Universitat Oberta de Catalunya.

OPP. Oficina de Planificació i Prospectiva de la UJI. Proporciona los datos institucionales académicos.

UADTI. Unidad de Análisis y Desarrollo en Tecnologías de la Información de la UJI.

CEISH. Comité de Ética de Investigación en Seres Humanos de la UJI.

SGD. Sistema de Gestión Documental institucional, soportado en Confluence.

SIIU. Sistema Integrado de Información Universitaria del Ministerio de Universidades.

CRUE. Conferencia de Rectores de las Universidades Españolas.

SIUVP. Sistema de Información Universitario Valenciano Público.

SUE. Sistema Universitario Español.

SIA. Sistema d'Informació Acadèmica de la UJI (clasificación oficial 2025 de titulaciones).

RGPD. Reglamento General de Protección de Datos (Reglamento UE 2016/679).

AI Act. Reglamento UE 2024/1689 sobre inteligencia artificial. Los sistemas de IA aplicados a educación se clasifican como alto riesgo y requieren supervisión humana explícita.

ODS. Objetivos de Desarrollo Sostenible de la Agenda 2030 de Naciones Unidas. Este TFM se vincula especialmente con los ODS 4 (educación de calidad), 5 (igualdad de género) y 10 (reducción de desigualdades).

KDD. Knowledge Discovery in Databases. Proceso metodológico de cinco fases (selección, preprocesamiento, transformación, minería de datos, interpretación) que estructura el análisis.

EDM. Educational Data Mining. Disciplina que aplica técnicas de minería de datos al ámbito educativo.

Tecnologías y formatos

Streamlit. Framework de Python para construir aplicaciones web interactivas orientadas a la ciencia de datos sin necesidad de desarrollo frontend específico. Es la base de la aplicación desplegada del TFM (sec. 3.13).

Parquet. Formato de fichero columnar de almacenamiento eficiente para grandes volúmenes de datos tabulares, ampliamente utilizado en el ecosistema de ciencia de datos. Todos los datasets intermedios y finales del TFM se persisten en este formato.

GitHub. Plataforma de alojamiento y control de versiones basada en Git, utilizada como repositorio público del proyecto y como soporte para la documentación HTML (GitHub Pages).

Bibliografia

- Araque, F., Roldán, C., & Salguero, A. (2009). Factors influencing university drop out rates. *Computers & Education*, 53(3), 563-574. <https://doi.org/10.1016/j.compedu.2009.03.013>
- Aulck, L., Velagapudi, N., Blumenstock, J., & West, J. (2016). Predicting student dropout in higher education. *arXiv preprint arXiv:1606.06364*. <https://doi.org/10.48550/arXiv.1606.06364>
- Bellamy, R. K. E., Dey, K., Hind, M., Hoffman, S. C., Houde, S., Kannan, K., Lohia, P., Martino, J., Mehta, S., Mojsilović, A., Nagar, S., Ramamurthy, K. N., Richards, J., Saha, D., Sattigeri, P., Singh, M., Varshney, K. R., & Zhang, Y. (2018). AI Fairness 360: An extensible toolkit for detecting, understanding, and mitigating unwanted algorithmic bias. *arXiv preprint arXiv:1810.01943*. <https://doi.org/10.48550/arXiv.1810.01943>
- Bentéjac, C., Csörgő, A., & Martínez-Muñoz, G. (2021). A comparative analysis of gradient boosting algorithms. *Artificial Intelligence Review*, 54(3), 1937-1967. <https://doi.org/10.1007/s10462-020-09896-5>
- Bernardo, A. B., Cerezo, R., Rodríguez-Muñiz, L. J., Núñez, J. C., Tuero, E., & Esteban, M. (2015). Predicción del abandono universitario: variables explicativas y medidas de prevención. *Revista Fuentes*, 16, 63-84. <https://doi.org/10.12795/revistafuentes.2015.i16.03>
- Bird, S., Dudík, M., Edgar, R., Horn, B., Lutz, R., Milan, V., Sameki, M., Wallach, H., & Walker, K. (2020). *Fairlearn: A toolkit for assessing and improving fairness in AI* (Technical Report MSR-TR-2020-32). Microsoft Research.
- Braxton, J. M., Hirschy, A. S., & McClendon, S. A. (2004). *Understanding and reducing college student departure*. ASHE-ERIC Higher Education Report, 30(3). Jossey-Bass.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Cabrera, A. F., Nora, A., & Castañeda, M. B. (1993). College persistence: Structural equation modeling test of an integrated model of student retention. *The Journal of Higher Education*, 64(2), 123-139. <https://doi.org/10.2307/2943986>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794). ACM. <https://doi.org/10.1145/2939672.2939785>
- Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153-163. <https://doi.org/10.1089/big.2016.0047>
- Comisión Europea. (2019). *Ethics Guidelines for Trustworthy AI*. High-Level Expert Group on AI. Bruselas: Comisión Europea.

- Davis, J., & Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. En *Proceedings of the 23rd International Conference on Machine Learning* (pp. 233-240). ACM. <https://doi.org/10.1145/1143844.1143874>
- Díaz Rangel, M. F. (2014). *Modelo de predicción de la deserción estudiantil usando redes bayesianas* [Trabajo de grado]. Universidad de los Andes.
- Doshi-Velez, F., & Kim, B. (2017). Towards a rigorous science of interpretable machine learning. *arXiv preprint arXiv:1702.08608*. <https://doi.org/10.48550/arXiv.1702.08608>
- EEOC (Equal Employment Opportunity Commission). (1978). Uniform Guidelines on Employee Selection Procedures. *Federal Register*, 43(166), 38290-38315.
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37-54. <https://doi.org/10.1609/aimag.v17i3.1230>
- Feldman, M., Friedler, S. A., Moeller, J., Scheidegger, C., & Venkatasubramanian, S. (2015). Certifying and removing disparate impact. En *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 259-268). ACM. <https://doi.org/10.1145/2783258.2783311>
- Fernández-Mellizo, M. (2022). *Análisis del abandono de los estudiantes de grado en las universidades españolas*. Madrid: Ministerio de Universidades. https://www.universidades.gob.es/wp-content/uploads/2022/11/EAU-Informe_Ejecutivo_abandono_fin2_comenmtadoMinistro.pdf
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>
- Fundación BBVA & Ivie. (2018). *La tasa de abandono escolar temprano en España es un 80 % superior a la media europea*. <https://www.fbbva.es/noticias/la-tasa-abandono-escolar-temprano-espana-80-superior-la-media-europea>
- Fundación BBVA & Ivie. (2019). *Un 33 % de los alumnos no finaliza el grado que inició y un 21 % abandona sin terminar estudios universitarios*. <https://www.fbbva.es/noticias/un-33-de-los-alumnos-no-finaliza-el-grado-que-inicio-y-un-21-abandona>
- Fundación BBVA & Ivie. (2020). *U-Ranking 2019. Indicadores sintéticos de las universidades españolas*. Bilbao: Informe U-Ranking FBBVA-IVIE.
- Gámez-Granados, J. C., Esteban, A., Rodríguez-Lozano, F. J., & Zafra, A. (2023). An algorithm based on fuzzy ordinal classification to predict students' academic performance. *Applied Intelligence*, 53, 25089-25107. <https://doi.org/10.1007/s10489-023-04810-2>
- García de Fanelli, A. (2014). *Abandono de los estudios universitarios: dimensión, factores asociados y desafíos para la política pública*. CONICET. <https://ri.conicet.gov.ar/handle/11336/56050>
- Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (Vol. 29, pp. 3315-3323). Curran Associates.

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.^a ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2004). *Introducción a la minería de datos*. Pearson Educación.
- Himmel, E. (2002). Modelo de análisis de la deserción estudiantil en la educación superior. *Calidad en la Educación*, (17), 91-108.
http://www.cned.cl/public/secciones/seccionpublicaciones/doc/35/cse_articulo141.pdf
- Hollmann, N., Müller, S., Eggensperger, K., & Hutter, F. (2024). Accurate predictions on small data with a tabular foundation model. *Nature*, 637, 319-326. <https://doi.org/10.1038/s41586-024-08328-6>
- Humphrey, K. B. (2008). Bottom line: New sails for the recruitment, retention, and learning ship. *About Campus*, 13(2), 2-3. <https://doi.org/10.1002/abc.239>
- Kaplan, E. L., & Meier, P. (1958). Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282), 457-481.
<https://doi.org/10.2307/2281868>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. En *Advances in Neural Information Processing Systems* (Vol. 30, pp. 3146-3154). Curran Associates.
- Kizilcec, R. F., & Lee, H. (2022). Algorithmic fairness in education. En W. Holmes & K. Porayska-Pomsta (Eds.), *The Ethics of Artificial Intelligence in Education* (pp. 174-202). Routledge.
<https://doi.org/10.4324/9780429329067-10>
- Kleinberg, J., Mullainathan, S., & Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. En *Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS 2017)* (Vol. 67, pp. 43:1-43:23). Schloss Dagstuhl.
<https://doi.org/10.4230/LIPIcs.ITCS.2017.43>
- La Moncloa. (2022, 15 de marzo). *El Ministerio de Universidades presenta un informe sobre el abandono de los estudios universitarios y aporta medidas para reducirlo* [Comunicado de prensa]. Gobierno de España.
<https://www.lamoncloa.gob.es/serviciosdeprensa/notasprensa/universidades/Paginas/2022/150322-subirats-abandono-universitario.aspx>
- Lacave, C., Molina, A. I., & García-Saiz, D. (2016). Aplicación de técnicas de minería de datos al estudio del abandono universitario en titulaciones de Informática. *Actas del Simposio-Taller JENUI 2016*. Universidad de Castilla-La Mancha.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with

- explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56-67. <https://doi.org/10.1038/s42256-019-0138-9>
- Márquez-Vera, C., Cano, A., Romero, C., Noaman, A. Y. M., Fardoun, H. M., & Ventura, S. (2016). Early dropout prediction using data mining: A case study with high school students. *Expert Systems*, 33(1), 107-124. <https://doi.org/10.1111/exsy.12135>
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1-35. <https://doi.org/10.1145/3457607>
- Ministerio de Educación, Formación Profesional y Deportes. (s. f.). *Estadística del gasto público en educación*. <https://www.educacionfpydeportes.gob.es/servicios-al-ciudadano/estadisticas/economicas/gasto.html>
- Mishra, T., Kumar, D., & Gupta, S. (2014). Mining students' data for prediction performance. *2014 Fourth International Conference on Advanced Computing & Communication Technologies (ACCT)*, 255-262. <https://doi.org/10.1109/ACCT.2014.105>
- Mothilal, R. K., Sharma, A., & Tan, C. (2020). Explaining machine learning classifiers through diverse counterfactual explanations. *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT 20)**, 607-617. <https://doi.org/10.1145/3351095.3372850>
- Núñez Pérez, J. C., & Bernardo Gutiérrez, A. B. (2023). *Estudio de los factores de riesgo y protección del abandono universitario. Elaboración de una guía de buenas prácticas (ModAU-GBP)*. Universidad de Oviedo / Ministerio de Ciencia, Innovación y Universidades.
- Oficina de Cooperació al Desenvolupament i Solidaritat. (2025). *Objectius de Desenvolupament Sostenible*. Universitat Jaume I. <https://www.uji.es/serveis/ocds/base/ods/>
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135-1144. <https://doi.org/10.1145/2939672.2939778>
- Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). *Green AI*. Communications of the ACM, 63(12), 54-63. <https://doi.org/10.1145/3381831>
- Schwartz, R., Vassilev, A., Greene, K., Perine, L., Burt, A., & Hall, P. (2022). *Towards a standard for identifying and managing bias in artificial intelligence* (NIST Special Publication 1270). National Institute of Standards and Technology. <https://doi.org/10.6028/NIST.SP.1270>
- Shapley, L. S. (1953). A value for n-person games. En H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games, Volume II* (pp. 307-317). Princeton University Press.
- Tinto, V. (1975). Dropout from higher education: A theoretical synthesis of recent research. *Review of Educational Research*, 45(1), 89-125. <https://doi.org/10.3102/00346543045001089>
- Tinto, V. (1992). *El abandono en los estudios superiores: una nueva perspectiva de las causas del abandono y su tratamiento*. Cuadernos de Planeación Universitaria, núm. 2. México: UNAM.
- UNESCO. (2021). *Recommendation on the Ethics of Artificial Intelligence*. París: UNESCO.

- Unión Europea. (2016). Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (RGPD). *Diario Oficial de la Unión Europea*, L 119/1.
- Unión Europea. (2024). Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, sobre inteligencia artificial (AI Act). *Diario Oficial de la Unión Europea*.
- Verma, S., & Rubin, J. (2018). Fairness definitions explained. En *Proceedings of the International Workshop on Software Fairness (FairWare '18)* (pp. 1-7). ACM.
<https://doi.org/10.1145/3194770.3194776>
- Wang, P., & Zhou, G. (2021). A study of Chinese international student dropout: Acculturation experiences and challenges in a pre-university English language improvement program. *McGill Journal of Education*, 56(1), 52-70. <https://doi.org/10.7202/1087048ar>
- Witten, I. H., Frank, E., & Hall, M. A. (2011). *Data mining: Practical machine learning tools and techniques* (3.^a ed.). Morgan Kaufmann.